LIRE → ESSAYER → VÉRIFIER

Votre point de départ

1 · Installer R / choisir son système

2 · Écrire, enregistrer et relancer un premier fichier

3 · Voir le programme et la route des lectures

4 · Lire les maths et leurs traductions en R

5 · Faire les mini-exemples avant les TP

SUR GITHUB OU HORS LIGNE

Télécharger et extraire le ZIP pour les liens locaux. Sur GitHub, le README ouvre chaque PDF. Tous les supports obligatoires et données sont fournis ; aucun paquet R externe requis.

VOTRE PORTFOLIO INDIVIDUEL

Les quatre travaux pratiques

TP01 · Cours p.2–12

TP02 · Cours p.13–24

TP03 · Cours p.25–33

TP04 · Cours p.31–34

Mémo : commandes et notations

Corrigés, après une tentative

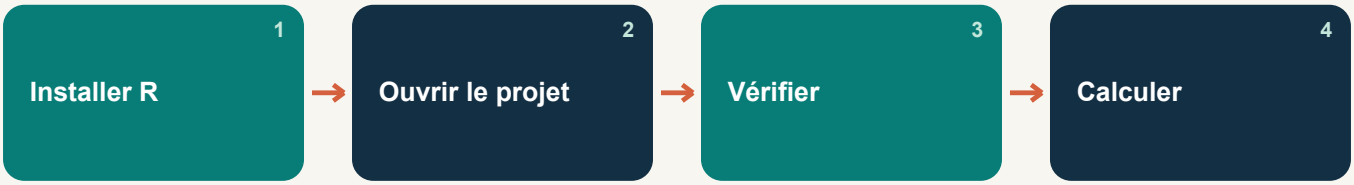
Défis facultatifs

UN RÉSULTAT VÉRIFIABLE

Votre contrôle de TP doit examiner vos objets, pas lancer les solutions. Conservez les quatre scripts, exports et note PDF. Le barème complet est accessible sans extension.

AVANT LE SAMEDI

Choisir son chemin



R est le moteur de calcul. RStudio est un éditeur facultatif. Git et un compte GitHub ne sont pas nécessaires : le téléchargement ZIP suffit. Le cours utilise seulement les bibliothèques livrées avec R.

- Préparer un ordinateur avec clavier, 1 Go libre pour les outils et les supports, et une connexion pour les téléchargements initiaux.
- Choisir la version stable de R sur CRAN. Les scripts visent R ≥ 4.1 ; la validation locale utilise R 4.6.1 sur macOS ARM64.
- Télécharger le dépôt : Code → Download ZIP. Extraire réellement l'archive, par exemple dans Documents/r-statistiques-18h. Ne pas travailler dans le ZIP.
- Ouvrir course.Rproj dans RStudio ; sinon ouvrir R et choisir le dossier extrait comme dossier de travail.

> **PREMIER SUCCÈS**
>
> Dans la console R : 2 + 2 doit afficher 4. Puis source("scripts/00_check_setup.R", encoding = "UTF-8"). Une erreur est une information à lire, pas un verdict sur votre niveau.

CHEMIN A · ENVIRONNEMENT NATIF

Windows : R d’abord

- Aller sur https://cran.r-project.org/bin/windows/base/ et télécharger l’installateur stable 64 bits. Utiliser le poste autorisé par votre établissement.
- Lancer l’installateur officiel. Si le poste est administré et bloque l’installation, demander au support avant le cours ; ne pas modifier ses protections.
- Facultatif : installer RStudio Desktop Open Source depuis https://docs.posit.co/ide/user/download.html ; choisir un installateur compatible avec votre Windows. La version actuelle documentée cible Windows 11.
- Sans RStudio : utiliser R GUI, menu Fichier → Changer le répertoire courant, puis choisir le dossier contenant course.Rproj.
- Dans RStudio : ouvrir course.Rproj ; suivre ensuite le guide Premiers pas. Exécuter une ligne avec Ctrl+Entrée, ou tout le script avec Source.

```
# Console R, pas PowerShell
getwd()
file.exists("data/noria_dirty.csv")
source("scripts/00_check_setup.R", encoding = "UTF-8")
```

WINDOWS 10 / POSTE ANCIEN

R et l’éditeur ont des exigences distinctes. Vérifier les pages officielles ; si R fonctionne mais que RStudio récent est incompatible, utiliser R GUI. WSL et Rtools ne sont pas requis pour ce cours.

CHEMIN B · APPLE SILICON OU INTEL

macOS : choisir la bonne puce

- Menu Apple → À propos de ce Mac : identifier Puce Apple ou Processeur Intel.
- Depuis https://cran.r-project.org/bin/macosx/ choisir le paquet compatible avec votre puce ET votre version de macOS. Le paquet ARM64 actuel exige macOS 14 ou plus.
- Installer le paquet officiel signé ; ouvrir R.app et saisir 2 + 2. Pas de compilateur ni de Homebrew nécessaire.
- Facultatif : installer RStudio Desktop Open Source compatible, puis ouvrir course.Rproj.
- Sans RStudio : R.app → Divers / Misc → Changer le répertoire de travail ; choisir le dossier du cours. Ouvrir les scripts dans un éditeur de texte et utiliser source() depuis R.

```
# Console R
R.version.string
source("scripts/00_check_setup.R", encoding = "UTF-8")
```

RACCOURCI ET FICHIERS

Dans RStudio : Cmd+Entrée exécute la ligne sélectionnée. Sur tous les systèmes, respecter les majuscules et utiliser des chemins relatifs avec / ; aucun chemin propre à l'enseignant.

CHEMIN C · UBUNTU LTS

Ubuntu : une installation minimale

Pour ce cours sans paquets externes, le paquet de votre distribution suffit s'il fournit R ≥ 4.1. Les commandes suivantes vont dans le Terminal Ubuntu, jamais dans la console R.

```
sudo apt update
sudo apt install r-base
R --version
R
```

Dans R, choisir le dossier extrait via setwd() une seule fois pour démarrer, par exemple setwd("~/Documents/r-statistiques-18h"). Les scripts du projet ne contiennent aucun setwd(). RStudio est facultatif : vérifier la compatibilité de son paquet .deb avec l'architecture du poste et l'Ubuntu installé.

```
# Console R
stopifnot(getRversion() >= "4.1.0")
source("scripts/00_check_setup.R", encoding = "UTF-8")
q(save = "no")
```

- Pour une installation CRAN plus récente : suivre exactement https://cran.r-project.org/bin/linux/ubuntu/ ; le choix du dépôt dépend de la version Ubuntu.
- Sur ARM64, vérifier la disponibilité de l'éditeur ; le moteur R en terminal suffit.
- Ne jamais coller une commande sudo dans R. Ne pas installer Hadoop pour les TPs.

> **APRÈS LE TÉLÉCHARGEMENT**
>
> Les quatre TP du cœur fonctionnent hors ligne. Aucun install.packages() n'est demandé.

PRÉPARATION · PAS DE CORRECTION À LANCER

Valider le premier pas, puis avancer

```
source("scripts/00_check_setup.R", encoding = "UTF-8")
2 + 2
file.exists("data/noria_dirty.csv")
```

ATTENDU

Le contrôle confirme que R et les fichiers sont présents ; 2 + 2 affiche 4, file.exists(...) affiche TRUE. Ce contrôle d'installation n'évalue pas vos réponses aux TP.

Faire le premier essai : écrire, enregistrer, relancer

Suivre les quatre étapes du week-end

DÉBOGAGE · 3 QUESTIONS

Se débloquer sans attendre

1 Où suis-je ? → 2 Quel objet ? → 3 Quel message ?

Symptôme	Action utile
cannot open file	getwd(), puis file.exists("data/noria_dirty.csv"). Ouvrir le projet extrait.
object not found	Exécuter les lignes précédentes ; vérifier orthographe et majuscules.
unexpected symbol	Vérifier guillemets, parenthèses et virgules ; utiliser des guillemets droits.
NA dans mean()	Compter les valeurs manquantes avant de décider na.rm = TRUE.
Aucune figure	Regarder results/ ; ouvrir les PDF générés.
R ne démarre pas	Vérifier puce/OS et installation officielle ; demander le poste de secours.

PLAN DE SECOURS EN CLASSE

Le formateur garde le ZIP et les installateurs compatibles sur support local. Travail en binôme provisoire, chacun avec son propre raisonnement et sa restitution. Une session de rattrapage technique précède la notation.

1 / PRÉPARER

Avant de calculer : retrouver ses fichiers

R est le logiciel qui calcule. RStudio est un atelier de travail autour de R. Vous pouvez suivre le cours avec R seul. Aucune expérience en programmation, aucun compte GitHub et aucun package supplémentaire ne sont nécessaires.

- Télécharger le ZIP du cours et l'extraire dans un dossier facile à retrouver, par exemple Documents/r-statistiques-18h. Ouvrir le dossier extrait, pas l'archive ZIP.
- Installer R depuis https://cran.r-project.org/ : Windows → base ; macOS → installateur adapté au Mac ; Ubuntu → instructions de la distribution. Le responsable vérifie l'installation avant la séance.
- Option conseillée : installer RStudio Desktop depuis https://posit.co/download/rstudio-desktop/ après R. Si un poste refuse cette installation, utiliser le chemin R seul page 3.
- Le dossier du cours contient course.Rproj, data, labs, scripts et pdf. Garder cette organisation : les scripts utilisent des chemins comme data/noria_dirty.csv.

Système	Ouvrir le moteur R seul
Windows	Menu Démarrer → R, puis choisir l'application R installée. Une fenêtre R Console apparaît.
macOS	Finder → Applications → R. La fenêtre R Console apparaît.
Ubuntu	Ouvrir Terminal, taper R puis Entrée. Le symbole > indique que R attend une instruction.

PREMIER REPÈRE

Tous les textes à lire sont dans les PDF. Les fichiers .R servent à exécuter le code et à conserver vos réponses. Une erreur de lancement ne dit rien de vos capacités en statistiques.

2 / FAIRE LA BOUCLE

RStudio : un premier fichier, un résultat

- Double-cliquer course.Rproj dans le dossier extrait. Dans RStudio, le grand panneau Console contient le symbole >. Le panneau Source en haut sert à écrire un fichier conservé.
- Choisir File → New File → R Script. File → Save As… : enregistrer premier_essai.R dans le dossier du cours. Sur un Mac, utiliser Cmd+S ; ailleurs Ctrl+S.
- Recopier les trois lignes ci-dessous. Sous TODO, écrire votre propre prédiction dans un commentaire, avant d'exécuter le calcul.

```
# TODO : écrire ma prédiction ci-dessous
# Je prédis : 8
print(4 + 4)
```

- Placer le curseur sur print(4 + 4), puis cliquer Run. La Console doit afficher [1] 8. Ne pas recopier [1] : ce repère indique la position du premier résultat affiché.
- Enregistrer. Choisir Session → Restart R. Le résultat reste enregistré dans le fichier, même si les objets en mémoire ont disparu.
- Dans la Console, taper la ligne ci-dessous puis Entrée. Tout le fichier s'exécute. Le résultat attendu est encore [1] 8.

```
source("premier_essai.R", encoding = "UTF-8")
```

VOTRE PREMIÈRE RÉUSSITE

Prédire → lancer une ligne → lire → enregistrer → redémarrer → relancer le fichier entier. Refaire cette boucle à chaque étape du cours. Run exécute une ligne ou une sélection ; source(...) exécute le fichier enregistré.

3 / CHEMIN DE SECOURS

Avec R seul : le même résultat

Utiliser ce chemin si RStudio manque ou ne démarre pas. Le fichier et les réponses sont les mêmes ; seule la manière de les ouvrir change.

Système	Créer et enregistrer le fichier .R
Windows	Dans R : File → New script. Écrire les trois lignes de la page 2, puis File → Save As… → premier_essai.R dans le dossier du cours.
macOS	Dans R : File → New Document. Écrire les trois lignes, puis enregistrer premier_essai.R dans le dossier du cours.
Ubuntu	Ouvrir l'éditeur de texte du système. Créer un document texte brut, écrire les trois lignes et enregistrer premier_essai.R dans le dossier du cours. Éviter le format traitement de texte et le suffixe .txt.

- Revenir dans la Console R. Exécuter setwd(dirname(file.choose())). Dans la boîte qui apparaît, sélectionner course.Rproj. R utilise alors le dossier du cours.
- Si Ubuntu demande un nom de fichier dans la Console, saisir le chemin complet de course.Rproj, par exemple /home/votre_nom/Documents/r-statistiques-18h/course.Rproj. Ne pas recopier votre_nom : utiliser votre vrai dossier.
- Exécuter getwd() pour vérifier le dossier, puis source("premier_essai.R", encoding = "UTF-8"). Attendu : [1] 8.

```
setwd(dirname(file.choose()))
getwd()
source("premier_essai.R", encoding = "UTF-8")
```

VÉRIFIER SANS MÉMOIRE CACHÉE

Fermer R ; si R propose d'enregistrer l'espace de travail, choisir Non / Don't Save. Rouvrir R, choisir de nouveau le dossier et relancer source(...). Le résultat doit être [1] 8. En séance, demander de l'aide si un menu diffère : cette vérification compte davantage que le nom exact du menu.

4 / DEVENIR AUTONOME

Lire la Console et commencer un TP

Repère	Ce qu'il signifie / que faire
>	R est prêt. Taper une instruction après ce symbole ; ne pas le copier dans le fichier .R.
+ au début	R attend la fin d'une instruction : souvent une parenthèse ou un guillemet manque. Appuyer sur Échap, puis corriger la ligne.
[1] 8	La première valeur du résultat affiché est 8. [1] n'est ni une erreur ni un code à recopier.
#	Le reste de la ligne est un commentaire lu par l'humain. R ne l'exécute pas. Écrire les réponses en phrases après #.
<-	Donner un nom à une valeur : delai <- 8. Ensuite print(delai) affiche cette valeur.
Source / Console	Le fichier Source conserve le travail ; la Console montre les calculs et messages de la session.

- RStudio : File → Open File… → labs/TP01_demarrer.R. R seul : ouvrir ce fichier avec l'éditeur utilisé page 3. Enregistrer une copie de travail en conservant son nom dans votre exemplaire du cours.
- Lire le PDF du TP avant de modifier le script. Chercher le premier TODO. Ajouter une prédiction ou une phrase de réponse juste dessous, sur une ligne commençant par #.
- Compléter seulement le code demandé. Lancer quelques lignes, comparer à sa prédiction, puis enregistrer. À la fin, redémarrer et exécuter tout le fichier depuis la racine : source("labs/TP01_demarrer.R", encoding = "UTF-8").
- Fichier introuvable : lire getwd() et vérifier le dossier extrait. Objet introuvable : lancer d'abord la ligne qui le crée. Valeur inattendue : regarder les données et l'unité avant de changer le code.

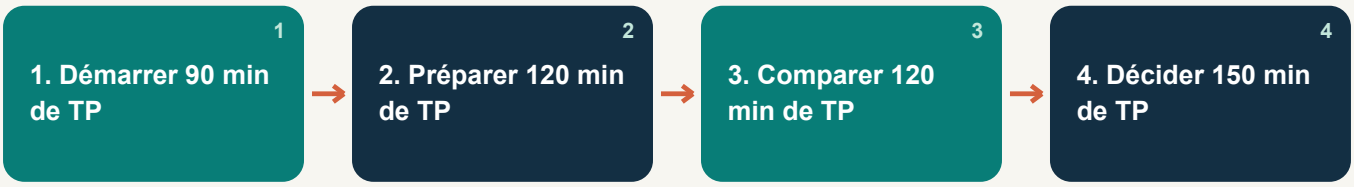
DEMANDER UNE AIDE UTILE

Montrer la ligne exacte, le message exact, le résultat attendu et ce qui s'est affiché. Conserver un essai dans le script. Le binôme peut expliquer ; chaque personne tape et enregistre son propre travail.

LE CONTRAT DU COURS

Une question concrète, quatre étapes

Noria teste deux façons de traiter les tickets, A et B. Vous cherchez si le délai moyen diffère, de combien et avec quelle incertitude. Les données sont simulées : elles servent à apprendre, sans prouver un gain réel dans une entreprise.



- Point de départ : savoir ouvrir un fichier et faire un calcul scolaire. Aucun langage informatique n'est supposé connu. Les mathématiques utiles sont reprises avec de petits nombres, avant le code.
- 240 tickets indépendants ont été simulés avec une affectation A/B randomisée et équilibrée. Le fichier brut contient 241 lignes après introduction d'anomalies. L'audit conduit à 236 tickets retenus : A = 117 et B = 119.
- 12 satisfactions manquent dans les données retenues. Elles ne retirent pas automatiquement les tickets de l'analyse des délais ; l'effectif utile dépend de la variable étudiée.
- Résultat principal : délai moyen B moins délai moyen A, en minutes, avec intervalle de confiance de Welch. Une valeur négative correspond à un délai moyen plus court sous B.

18 HEURES, RÉELLEMENT COMPTÉES

4 séances de 270 minutes = 1 080 minutes de contact pédagogique. Les pauses sont à ajouter hors de ces créneaux. Les quatre TP occupent 480 minutes dédiées ; les exercices de maths, démonstrations et contrôles occupent le reste. Ce parcours n'a pas encore fait l'objet d'un pilote en classe.

DEUX RYTHMES, UN MÊME OBJECTIF

Parcours accompagné : nombres plus petits, étapes visibles, aide du formateur. Parcours rapide : justification supplémentaire, contre-exemple ou contrôle indépendant. Les mêmes quatre livrables et le même barème s'appliquent ; finir une extension n'est pas requis.

INDEX · ÉNONCÉ, LECTURE, FICHIER

Une seule route pour les quatre TP

Étape	Lire dans le cours	Fichier
TP01	Cours p.2–12	labs/TP01_demarrer.R
TP02	Cours p.13–24	labs/TP02_preparer.R
TP03	Cours p.25–33	labs/TP03_comparer.R
TP04	Cours p.31–34	labs/TP04_projet.R

TP01 : ouvrir l’énoncé

TP02 : ouvrir l’énoncé

TP03 : ouvrir l’énoncé

TP04 : ouvrir l’énoncé

LIRE LES PDF TÉLÉCHARGÉS

Les liens de fichiers sont prévus pour le dossier extrait. Sur GitHub, utiliser aussi le README ; les noms et pages restent indiqués. Les mini-exemples précèdent les TP, les corrigés viennent après une tentative.

270 MIN / DU PAPIER AU SCRIPT

Séance 1 : prendre la main

Repère	Durée	Activité et résultat
00–20	20 min	Accueil et diagnostic sans note : fichiers, moyenne, unités et lecture de graphique.
20–50	30 min	Premier essai sur ordinateur : ouvrir, prédire, exécuter, enregistrer, redémarrer et relancer.
50–85	35 min	Maths à la main : moyenne de petits délais ; dire ce que mesure le résultat et dans quelle unité.
85–125	40 min	R pas à pas : vecteur, nom d'objet, sélection et fonctions simples ; annoncer le résultat avant Run.
125–215	90 min	TP01_demarrer.R : 70 min individuels, 9 min en triade, 11 min de retour et reprise.
215–240	25 min	Maths à la main : même moyenne, répartitions différentes ; prévoir l'effet d'une grande valeur.
240–261	21 min	Contrôle individuel : expliquer son calcul et relancer le script dans une session vide.
261–270	9 min	Billet de sortie : un résultat, son unité, une question précise pour la séance suivante.

AVANT D'OUVRIR LE CODE

Sur quatre délais, calculer une moyenne, dire son unité et prévoir comment une grande valeur la déplace. Ensuite seulement, vérifier avec R.

- À conserver : labs/TP01_demarrer.R complété avec prédictions, calculs et explications en commentaires.
- Accompagné : refaire le premier essai avec le formateur et calculer sur quatre valeurs. Rapide : expliquer pourquoi deux séries peuvent avoir la même moyenne avec des répartitions très différentes.
- Le contrôle porte sur un calcul compris et une relance réussie. La vitesse de frappe ne compte pas.

270 MIN / AUDITER AVANT DE RÉSUMER

Séance 2 : obtenir des données défendables

Repère	Durée	Activité et résultat
00–20	20 min	Rappel actif : rouvrir son travail, lire un message d'erreur, expliquer une sélection.
20–50	30 min	Maths à la main : médiane, quartiles et dispersion sur quelques valeurs ; esquisser le graphe.
50–90	40 min	Démonstration guidée : importer, contrôler les types, repérer doublons et valeurs impossibles.
90–110	20 min	Pont matrice/apply : 8 min de tableau à la main, puis 12 min de lecture et d'exécution R.
110–230	120 min	TP02_preparer.R : 90 min individuels, 9 min en triade, 21 min de retour et reprise.
230–252	22 min	Maths et lecture de graphes : relier dispersion, valeurs atypiques et résumé choisi.
252–270	18 min	Contrôle individuel : justifier une exclusion, une valeur manquante et un graphique.

PETITE PASSERELLE DE PROGRAMMATION

Une matrice est ici un petit tableau de nombres. On calcule un résumé par colonne à la main, puis avec apply. Une courte lecture de if, for et function relie condition, répétition et opération nommée. Ce pont ne devient pas un projet informatique supplémentaire. Cette reconnaissance appartient au cœur, sans point de barème distinct.

- À conserver : TP02_preparer.R, trace des exclusions et graphiques demandés. Retrouver 241 lignes brutes puis 236 retenues et expliquer chaque règle.
- Accompagné : comparer une ligne suspecte à la règle écrite avant de modifier le tableau. Rapide : tester un cas limite et montrer que la règle ne retire pas un cas légitime.
- L'écart-type décrit l'étalement des délais. Le graphique sert à voir ce qu'un seul nombre peut masquer. La satisfaction, ordinale, se décrit avec effectifs et médiane.

270 MIN / UNE DIFFÉRENCE ET SON INCERTITUDE

Séance 3 : comparer sans surinterpréter

Repère	Durée	Activité et résultat
00–20	20 min	Rappel actif : effectifs propres, délais par groupe et sens de la comparaison.
20–60	40 min	Maths à la main : petites répétitions d'échantillons ; distinguer dispersion et incertitude de la moyenne.
60–95	35 min	Démonstration Welch : définir B−A, calculer l'IC puis lire les éléments de l'objet résultat.
95–215	120 min	TP03_comparer.R : 90 min individuels, 9 min en triade, 21 min de retour et reprise.
215–240	25 min	Atelier de raisonnement : changer un effectif ou la dispersion ; prévoir l'effet sur l'IC.
240–261	21 min	Contrôle individuel : interpréter l'IC en minutes ; vérifier le sens B−A et les hypothèses.
261–270	9 min	Billet de sortie : une conclusion étayée et une limite, sans reformuler seulement une p-valeur.

DEUX QUESTIONS DIFFÉRENTES

La dispersion parle des tickets ; l'incertitude parle de l'estimation de la moyenne ou de la différence. Un intervalle de confiance accompagne une estimation ; il ne contient pas 95 % des tickets.

- À conserver : TP03_comparer.R, estimation B−A, IC à 95 % et phrases d'interprétation en minutes. Lire les attributs et les éléments de l'objet produit par le test pour retrouver ces résultats.
- Accompagné : écrire d'abord « B−A » et « minutes », puis suivre la lecture de l'IC. Rapide : expliquer le sens d'un IC qui recouvre zéro et ce qui changerait avec un effectif plus petit.
- Vérifier l'indépendance supposée et distinguer le scénario randomisé du cours d'une étude réelle. Un petit nombre de tickets retirés peut modifier l'équilibre initial : le signaler.

270 MIN / DU SCRIPT À UNE DÉCISION NUANCÉE

Séance 4 : mener et défendre l’analyse

Repère	Durée	Activité et résultat
00–20	20 min	Plan de projet : question, fichiers de départ, preuves attendues et critères du barème.
20–50	30 min	Maths et décision avant le code : lire deux IC fictifs, discuter gain utile et incertitude.
50–200	150 min	TP04_projet.R : 115 min individuels, 9 min de défense en triade, 26 min de retour et reprise.
200–235	35 min	Restitution collective : 5 exemples de 5 min, puis 10 min de synthèse ; tout le monde compare à sa note.
235–258	23 min	Contrôle final individuel : redémarrer, tout relancer et rendre les preuves du portfolio.
258–270	12 min	Auto-évaluation et suite : ce qui est acquis, ce qui reste fragile, extensions facultatives.

- Avant le code, lire deux résultats fictifs et discuter ce qui rend un gain utile. Pour le TP04, 5 minutes constituent un critère pédagogique fictif fixé avant de lire les résultats ; ce seuil ne provient pas d’une étude métier réelle.
- À conserver : TP04_projet.R, sorties utiles et note de décision en PDF. La note indique question, audit, effectifs, différence B−A, IC, conclusion et limites.
- Chaque personne défend sa conclusion pendant 3 minutes dans sa triade. Les restitutions collectives portent sur des exemples choisis ; elles ne permettent pas une soutenance individuelle devant toute la classe.
- Accompagné : utiliser la trame de note et faire vérifier le sens de la différence. Rapide : examiner un scénario qui rendrait la recommandation fragile ; aucun modèle de régression n’est requis.

UNE CONCLUSION ATTENDUE

Donner un nombre, une unité, un intervalle et une conséquence raisonnable. Distinguer ce qui est observé, ce qui est supposé et ce qu’il faudrait vérifier dans des données réelles.

VOTRE PORTFOLIO DU CŒUR

Travailler, s’entraider et rendre

Travail conservé	Part du barème
TP01_demarrer.R : premier calcul et interprétation	15 / 100
TP02_preparer.R : audit, dispersion et graphes	25 / 100
TP03_comparer.R : B−A, IC, hypothèses et interprétation	30 / 100
TP04_projet.R + note PDF : relance, décision et défense	30 / 100

- 480 minutes de TP dédiées : 365 minutes sont réservées à la production individuelle, soit 76 %. Chaque TP réserve au moins deux tiers de sa durée à ce travail.
- Triades : 3 personnes, 3 minutes de parole chacune, soit 9 minutes. La personne qui parle montre une preuve ; les deux autres vérifient le sens et posent une question. À deux, garder 6 minutes de parole et utiliser 3 minutes pour la reprise.
- Garder ses quatre scripts, leurs exports, la note finale PDF et results/TP04_sessionInfo.txt (versions de R et de la session). Les commentaires expliquent les choix. Redémarrer et relancer le script ; une capture d’écran ne suffit pas.
- Dire « je ne sais pas encore » avec une preuve précise est utile. Appeler le formateur si la même erreur résiste à deux essais ciblés. Les participants rapides approfondissent leur explication sans faire le travail des autres.

APRÈS LES 18 HEURES SEULEMENT

Le TP matrices approfondi, la régression ajustée, le bootstrap et MapReduce sont des extensions facultatives. RHadoop n’est pas mis en œuvre dans le cœur ni validé comme atelier pratique. Ces sujets ne sont ni des prérequis à la réussite ni des tâches à finir en urgence à la maison.

01 / Profil · 8 min

Votre point de départ

Répondez seul, sans recherche. « Je ne sais pas encore » est utile. Ce diagnostic ne classe pas les étudiants et ne compte pas dans l'évaluation.

- Donnez un pseudonyme de suivi ; aucune donnée personnelle n'est nécessaire.
- Évaluez votre aisance de 0 (découverte) à 3 (autonomie) : fichiers et dossiers ; programmation ; tableaux ; statistiques ; terminal.
- Quel outil avez-vous utilisé : Excel, SQL, Python, R, autre, aucun ? Donnez un exemple concret.
- Quelle difficulté anticipez-vous : écrire du code, lire une erreur, choisir une analyse, interpréter, prendre la parole ?
- Quel appui vous aide : mémo, exemple minimal, schéma, pair ? Ce choix peut changer.

> **CONTRAT D'APPRENTISSAGE**
>
> Chaque étudiant produit son script et son interprétation. Les échanges servent à expliquer et vérifier ; ils ne remplacent pas le travail personnel.

02 / Situations · 12 min

Raisonner avant de calculer

- 1. Les délais valent 10, 12, 14, 100 minutes. Quel indicateur décrit un délai « typique » ? Justifiez.
- 2. Un délai est absent. Est-il équivalent à zéro ? Que vérifier avant une moyenne ?
- 3. B a une moyenne plus basse que A sur 20 tickets. Cela prouve-t-il une amélioration ? Citez une information manquante.
- 4. p = 0,04 est-il la probabilité que B soit meilleur ? Reformulez ce que vous pensez savoir.
- 5. Un IC de B − A vaut [−12 ; 3] minutes. Quelle incertitude décrit-il ? Peut-on conclure que les workflows sont identiques ?
- 6. Deux partitions contiennent 2 et 8 tickets, de moyennes 10 et 20. La moyenne globale est-elle la moyenne simple des deux moyennes ? Expliquez.

SORTIE INDIVIDUELLE

Choisissez une question à reprendre et écrivez ce que vous souhaitez savoir faire dimanche soir. L'enseignant utilise ces réponses pour adapter points d'entrée et défis.

UN JEU SYNTHÉTIQUE · AUCUNE DONNÉE CLIENT

Le dictionnaire des tickets

Colonne	Type / unité	Règle
ticket_id	integer / identifiant	Un ticket unique attendu
workflow	catégorie A/B	Procédure affectée aléatoirement
resolution_minutes	numeric / minutes	Délai strictement positif et fini
complexity	numeric / échelle 1–5	Mesurée avant traitement
satisfaction	ordinal / note 1–5	NA possible ; ne pas confondre avec 0
team	catégorie	Atlas, Boreal, Cedre

noria_reference.csv contient 240 tickets synthétiques avant anomalies de transmission. noria_dirty.csv contient 241 lignes reçues. Le générateur est documenté dans scripts/02_generate_data.R ; il conserve une graine et un algorithme explicites pour reproduire les CSV.

> **L'UNITÉ COMPTE**
>
> Les tickets sont indépendants par construction dans cette simulation. Dans un vrai service, plusieurs tickets d'un même client ou agent pourraient être corrélés ; le modèle simple devrait alors être réexaminé.

RÈGLES ANNONCÉES AVANT LE TEST

Un audit reproductible

Étape	Traitement	Effectif
Brut	Aucune modification	241
Catégories	trimws() sur workflow et team	241
Doublon	ticket 17 : première occurrence conservée	240
Délai absent	IDs 21, 87, 154 exclus du délai	237
Délai impossible	ID203 négatif exclu du délai	236

- Les espaces concernent sept cellules : trois de workflow et quatre de team.
- Après traitement : A =117, B =119 ; douze satisfactions manquantes demeurent, à comptabiliser séparément.
- Conserver un journal d'exclusions. Ne jamais écraser le CSV brut.
- Les exclusions ont des raisons explicites mais leur effet sur l'inférence doit être discuté : une analyse sur cas complets suppose plus qu'un fichier sans erreur.

PAS DE FUITE DE VÉRITÉ

Le fichier de référence aide à vérifier le générateur et les tests. Il ne faut pas remplacer les valeurs absentes du fichier reçu avec cette « vérité » fictive pour prétendre résoudre un vrai problème de données manquantes.

RÉFÉRENCES · VÉRIFIÉES LE 23 OCTOBRE 2026

Lire les sources primaires

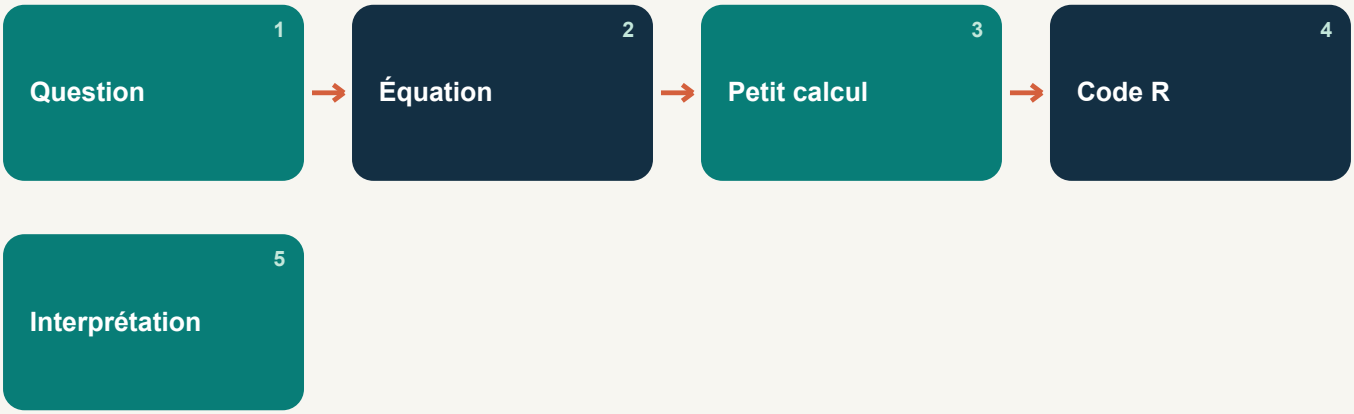
- R — introduction officielle : https://cran.r-project.org/doc/manuals/r-patched/R-intro.html
- Documentation installée : ?mean, ?matrix, ?apply, ?t.test, ?lm, ?attributes, ?sessionInfo.
- RStudio — guide et téléchargements : https://docs.posit.co/ide/user/download.html
- HDFS — architecture : https://hadoop.apache.org/docs/stable/hadoop-project-dist/hadoop-hdfs/HdfsDesign.html
- MapReduce — tutoriel Apache : https://hadoop.apache.org/docs/stable/hadoop-mapreduce-client/hadoop-mapreduce-client-core/MapReduceTutorial.html
- rmr2 — tutoriel historique : https://github.com/RevolutionAnalytics/rmr2/blob/master/docs/tutorial.md
- RHadoop — installation historique : https://github.com/RevolutionAnalytics/RHadoop/wiki/Installing-RHadoop-on-RHEL
- R en contexte professionnel : https://rconsortium.github.io/submissions-wg/

PORTÉE DE LA PRÉPARATION

Le plan du coordinateur reste une source privée. Les exercices et données de ce dépôt ont été créés pour le cours. Les références techniques sont des ressources externes, pas des garanties de compatibilité de toutes leurs versions.

NOTRE MÉTHODE · REGARDER, CALCULER, CODER, EXPLIQUER

La question vient avant la commande



Noria Services compare deux procédures A et B pour résoudre des tickets. Votre question : quel écart moyen de délai observe-t-on, et quelle incertitude reste-t-il ? Les données sont simulées ; votre raisonnement doit rester vérifiable.

- À chaque étape : nommer ce que l'on mesure et son unité.
- Calculer un exemple court à la main avant de lancer R.
- Prédire la sortie, puis expliquer l'écart éventuel.
- Écrire son propre script, sauvegarder et relancer depuis une session vide.

> **CE QUE L'ON SAURA LIVRER**
>
> Une table analysable, un audit, une figure lisible, une comparaison B − A avec intervalle et une recommandation d'une page. Le cœur ne demande ni cluster Hadoop ni modèle ajusté.

INTRODUCTION · CALCUL STATISTIQUE ET GRAPHIQUES

R : d’où vient cet outil ?

R est un langage et un environnement de calcul statistique et de graphiques, distribué comme logiciel libre. On y écrit des règles de calcul, on les applique à des données et on conserve une recette rejouable.

Repère	Ce qu’il signifie
Origine	Ross Ihaka et Robert Gentleman, département de statistique de l’Université d’Auckland
Inspiration	Le langage S, développé aux Bell Labs par John Chambers et ses collègues
1996	Les créateurs présentent R dans “A Language for Data Analysis and Graphics”
Depuis 1997	Une équipe R Core internationale contribue au développement
Aujourd’hui	Un projet collaboratif et extensible par des paquets

POURQUOI L’UTILISER ICI ?

R contient directement les opérations statistiques du cours : mean(), sd(), quantile(), t.test() et les graphiques. On peut comparer chaque commande à une équation et vérifier le résultat sur de petites valeurs.

Sources primaires : https://www.r-project.org/about.html ; https://www.r-project.org/contributors.html ; https://doi.org/10.1080/10618600.1996.10474713

INTRODUCTION · SA PLACE ET NOTRE CHOIX

Pourquoi apprendre R aujourd’hui ?

Besoin	Ce que R apporte
Décrire une situation	Résumés, distributions et graphiques
Quantifier l’incertitude	Estimations, intervalles, tests et modèles
Reproduire une analyse	Le script conserve les étapes et règles
Échanger avec un collègue	Données, code, versions et sorties traçables

R reste utilisé en recherche statistique et dans des métiers d’analyse spécialisés. Un exemple concret : le groupe R Submissions du R Consortium publie des pilotes de travaux cliniques et annonce en 2026 de nouveaux programmes d’analyse et des jeux synthétiques de référence. Ce cas illustre une activité professionnelle actuelle ; il ne mesure pas une part de marché.

> **R, RSTUDIO ET PAQUET**
>
> R effectue les calculs. RStudio est un éditeur pour écrire, exécuter et examiner le travail. Un paquet ajoute des fonctions ; les exercices obligatoires utilisent seulement ce qui est fourni avec R.

Source vérifiée le 23 octobre 2026 : https://r-consortium.org/posts/submissions-wg-2026/

VOCABULAIRE · LE MÊME LANGAGE POUR TOUS

Donnée, variable, observation : donner du sens

Mot	Définition concrète	Dans Noria
Donnée	Une valeur avec un sens et éventuellement une unité	70,2 minutes pour un ticket
Observation / individu	L'unité sur laquelle on recueille les variables	Un ticket ; pas une ligne dupliquée
Variable	Caractéristique mesurée ou décrite pour chaque unité	Délai, procédure, satisfaction
Population cible	Ensemble que la question veut décrire	Tickets du processus et contexte concernés
Échantillon	Unités effectivement observées pour analyser	Les 236 tickets retenus
Paramètre / estimation	Quantité de population / valeur calculée sur l'échantillon	Écart moyen cible / écart observé B−A

LA QUESTION GUIDE LE TABLEAU

Avant de coder : une ligne représente quoi ? Une colonne mesure quoi ? En quelle unité ? Comment les unités ont-elles été choisies ? La réponse conditionne les calculs possibles.

VOCABULAIRE · STATISTIQUE ET INFORMATIQUE

Une variable a un sens et un stockage

Sens statistique	Exemple	Stockage R possible
Quantitative continue	Durée en minutes	numeric
Quantitative discrète	Nombre de tickets	integer ou numeric
Qualitative nominale	Procédure A/B	character ou factor
Qualitative ordinale	Satisfaction 1–5	numeric codé ou ordered factor
Identifiant	ticket_id	integer / character ; calcul de moyenne sans sens ici

```
mesure <- 12.5
entier <- 3L
etiquette <- "A"
condition <- TRUE
class(mesure)
is.na(NA)
```

MANQUANT N'EST PAS ZÉRO

NA indique une information absente. Une note de satisfaction manquante ne devient ni 0 ni une preuve d'insatisfaction. Sa règle d'analyse doit être annoncée.

STRUCTURES · LA PREMIÈRE BRIQUE

Vecteur : une suite de valeurs du même type

Un vecteur numérique : 3 valeurs, un même type

x[1]	x[2]	x[3]
10	20	30

```
x <- c(10, 20, 30)
length(x)       # 3
x[1]            # 10 : index à partir de 1
x[x > 15]       # 20 30
x[2] <- 25      # remplacer la deuxième valeur
class(c(10, "20")) # character : conversion commune
```

LIRE LA SYNTAXE

c() rassemble des valeurs. [ ] sélectionne des positions. <- associe un nom à une valeur ou remplace une partie. Une opération comme x > 15 produit un vecteur TRUE/FALSE.

STRUCTURES · LIGNES ET COLONNES

Data frame : une table de variables

data.frame : une colonne par variable, une ligne par observation

	ticket_id : integer	workflow : character	resolution_minutes : numeric
ticket 1	1	A	10
ticket 2	2	B	20
ticket 3	3	A	30

```
d <- data.frame(ticket_id = 1:3,
  workflow = c("A", "B", "A"),
  resolution_minutes = c(10, 20, 30))
d$workflow                 # une colonne
d[2, ]                     # une ligne
d[d$workflow == "A", ]     # un filtre de lignes
str(d)
```

LA VIRGULE COMPTE

d[lignes, colonnes] sélectionne une table. Le vide après la virgule conserve toutes les colonnes. Chaque colonne est un vecteur ; leurs types peuvent différer.

QUESTION · Quelle durée entre dans le calcul ?

1 · Une ligne est-elle une observation valide ?

$$I = \{i : x_i \text{ est fini}, \; x_i > 0\}, \quad n = |I|$$

On définit les valeurs admises, puis on les compte.

x_i est la durée de la ligne i, en minutes ; I est l'ensemble des indices retenus ; |I| est son nombre d'éléments. Une valeur finie exclut NA, NaN et les infinis. Cette règle porte ici sur la durée, après contrôle des identifiants.

1 $x = (10, \text{NA}, -5, 30)$

Quatre lignes brutes ; durées en minutes.

2 $I = \{1, 4\}, \quad n = 2$

Les valeurs 10 et 30 satisfont la règle annoncée.

```
x <- c(10, NA, -5, 30)
valide <- is.finite(x) & x > 0
x_ok <- x[valide]       # 10 30
n <- sum(valide)        # 2
```

À INTERPRÉTER

n désigne les observations effectivement utilisées. length(x) vaut 4 et inclut la valeur manquante ; ce n'est pas l'effectif analysé. Une ligne dupliquée n'est pas une nouvelle observation indépendante.

QUESTION · Quel est le bon dénominateur ?

2 · Quelle proportion de tickets appartient à B ?

$$\hat{p}_B = \frac{n_B}{n}, \quad \text{pourcentage} = 100\hat{p}_B$$

Une part compare un nombre de tickets à une population clairement définie.

n_B est le nombre de tickets du groupe B ; n est le nombre total de tickets analysés dont le groupe est connu. p avec un chapeau est la proportion observée, sans unité ; son pourcentage s'exprime en %. Ici tous les groupes sont renseignés.

Ticket	workflow	Est-ce B ?
1	A	FALSE = 0
2	B	TRUE = 1
3	B	TRUE = 1
4	A	FALSE = 0

1 $$n_B = 0 + 1 + 1 + 0 = 2$$ On compte les B à l'aide d'un vecteur logique.

2 $$\hat{p}_B = 2/4 = 0{,}5$$ Deux B parmi quatre tickets : 50 %.

```
workflow <- c("A", "B", "B", "A")
connu <- !is.na(workflow)
est_B <- workflow[connu] == "B"
n_B <- sum(est_B)       # 2
p_B <- mean(est_B)      # 0.5
100 * p_B              # 50
```

PIÈGE

Toujours nommer le dénominateur : tous les tickets bruts, les tickets propres ou seulement les réponses connues ne donnent pas la même question. Ne pas coder une réponse manquante comme FALSE.

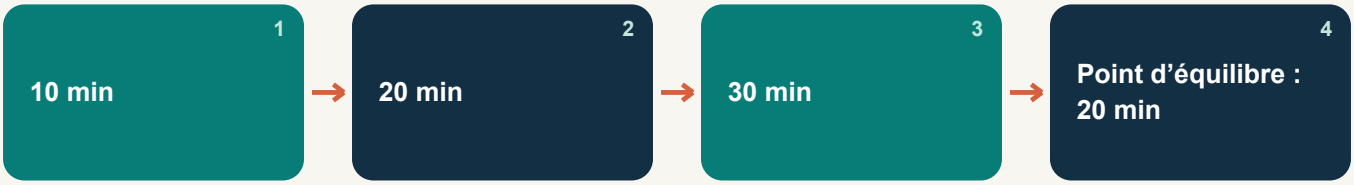
QUESTION · Quelle durée moyenne pour les tickets observés ?

3 · La moyenne : un point d’équilibre

$$\bar{x} = \frac{1}{n} \sum_{i=1}^{n} x_i$$

Additionner les durées retenues, puis partager en n parts égales.

x_i est la ie durée retenue, en minutes ; n est le nombre de durées retenues ; Σ se lit « somme de toutes les valeurs, de i = 1 à n » ; x avec une barre est la moyenne observée, en minutes. Les valeurs ont été validées avant ce calcul.



1 $$\sum_{i=1}^{3} x_i = 10 + 20 + 30 = 60$$

La somme des trois durées vaut 60 minutes.

2 $$\bar{x} = 60/3 = 20$$

La moyenne vaut 20 minutes.

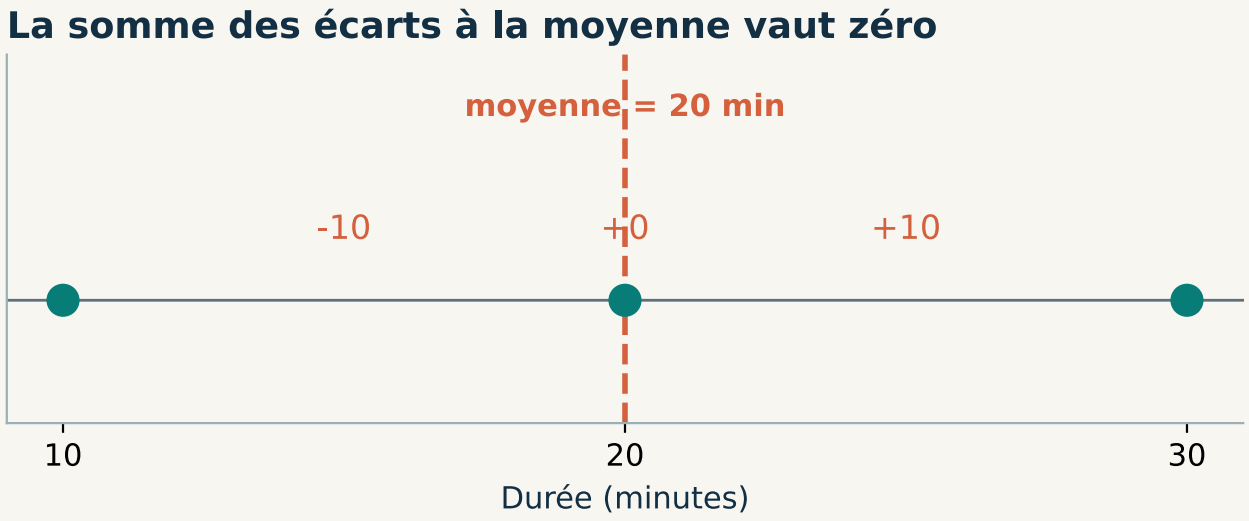
```
x <- c(10, 20, 30)
n <- length(x)
sum(x) / n      # 20
mean(x)         # 20
```

PIÈGE

La moyenne garde l’unité des données. Une grande durée la déplace : remplacer 30 par 300 donne 110 minutes. mean(..., na.rm = TRUE) ignore NA, mais ne détecte ni les valeurs négatives ni les doublons.

VOIR LE CALCUL

La moyenne comme équilibre



À LA MAIN

Pour 10, 20, 30 min, les écarts à 20 min sont −10, 0, +10 min. Leur somme vaut 0 ; une valeur très élevée déplacerait ce point d'équilibre.

QUESTION · Quelle durée sépare les données en deux moitiés ?

4 · La médiane : le milieu des valeurs triées

$$n = 2k + 1 : \quad m = x_{(k+1)}$$

Nombre impair : prendre la valeur centrale après tri.

$$n = 2k : \quad m = \frac{x_{(k)} + x_{(k+1)}}{2}$$

Nombre pair : faire la moyenne des deux valeurs centrales.

x_(j) désigne la valeur de rang j dans la liste triée ; n est l'effectif ; k est l'entier qui permet d'écrire n = 2k ou n = 2k + 1 ; m est la médiane, en minutes. La médiane peut ne pas être une valeur observée.

Valeurs triées	Positions centrales	Médiane
10, 20, 30	Position 2	20 min
10, 20, 30, 100	Positions 2 et 3	25 min

1 $n = 3 = 2 \times 1 + 1, \quad m = x_{(2)} = 20$

Trois valeurs : le milieu est une valeur observée.

2 $n = 4 = 2 \times 2, \quad m = (20 + 30)/2 = 25$

Quatre valeurs : le milieu est entre deux valeurs observées.

```
x <- c(30, 10, 20)
sort(x)                # 10 20 30
median(x)              # 20
median(c(x, 100))      # 25
```

PASSER AU JEU DU PROJET · AVANT LE TP02

Recevoir Noria sans modifier le fichier

Le CSV reçu contient des anomalies de transmission. Gardez-le intact. On va compter les lignes, vérifier les unités et annoncer les règles avant d'interpréter un résultat.

```
noria_dirty <- read.csv("data/noria_dirty.csv",
  stringsAsFactors = FALSE, na.strings = c("", "NA"))
dim(noria_dirty)
names(noria_dirty)
str(noria_dirty)
colSums(is.na(noria_dirty))
```

QUESTION AVANT LE NETTOYAGE

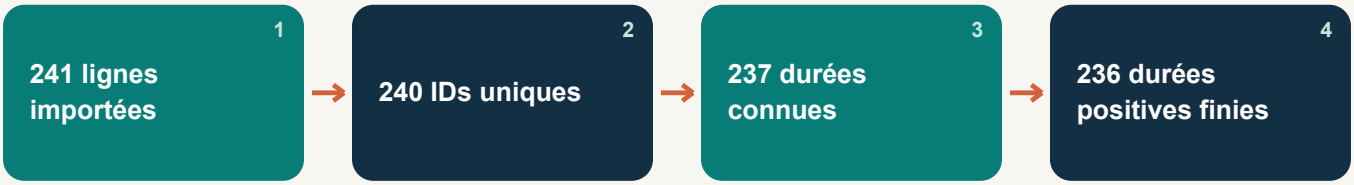
241 lignes ne signifient pas 241 tickets indépendants. Le dictionnaire du projet explique chaque variable ; le TP02 vous demande de conserver les preuves des corrections.

Exemple miniature : nettoyer et exporter

TP02 : préparer et décrire

QUESTION · Pourquoi Noria passe-t-il de 241 lignes à 236 tickets ?

5 · Compter les lignes, puis les tickets



$$n_{\text{analyse}} = 241 - 1 - 3 - 1 = 236$$

Un doublon de ligne, puis quatre tickets sans durée admissible.

L'origine synthétique comporte 240 tickets. Le fichier sale contient 241 lignes : le ticket 17 a été ajouté une seconde fois, à l'identique. Les IDs 21, 87 et 154 n'ont pas de durée ; l'ID 203 a une durée négative. Les espaces sont normalisés avant de comparer les groupes et les équipes.

1 $241 - 1 = 240$ — Retirer la copie exacte de l'ID 17 : on retrouve 240 tickets uniques.

2 $240 - 3 - 1 = 236$ — Exclure trois durées manquantes et une durée négative pour cette analyse.

```
d <- noria_dirty
d$workflow <- trimws(d$workflow)
d$team <- trimws(d$team)
stopifnot(sum(duplicated(d)) == 1)
d <- unique(d)
stopifnot(!anyDuplicated(d$ticket_id))
valide <- is.finite(d$resolution_minutes) &
          d$resolution_minutes > 0
clean <- d[valide, ]
nrow(clean)                  # 236
```

PIÈGE

On retire cinq lignes mais seulement quatre tickets distincts sont exclus. Les 12 NA de satisfaction restent : cette variable n'est pas nécessaire à la comparaison des durées. Sept cellules avec espaces sont corrigées (3 workflow, 4 team). Garder le fichier brut et le journal des règles.

QUESTION · Les durées sont-elles proches de leur moyenne ?

6 · Variance et écart-type : la dispersion des tickets

$$s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2, \qquad s = \sqrt{s^2}$$

R utilise n − 1 pour la variance et l'écart-type d'échantillon.

x_i : durée du ticket i ; $\bar{x}$: moyenne ; n : nombre de tickets, au moins 2 ; Σ additionne les carrés des écarts de tous les tickets. s² est la variance, en minutes carrées (min²). s est l'écart-type, en minutes. La division par n − 1 corrige l'estimation de variance liée à une moyenne estimée sur ces mêmes données.

x_i (min)	x_i − 20 (min)	Carré (min²)
10	−10	100
20	0	0
30	10	100

1 $$\bar{x} = 20, \qquad \sum_{i=1}^{3}(x_i - \bar{x})^2 = 200$$

Les écarts signés s'annulent ; leurs carrés mesurent l'éloignement.

2 $$s^2 = 200/(3-1) = 100$$

La variance d'échantillon vaut 100 min².

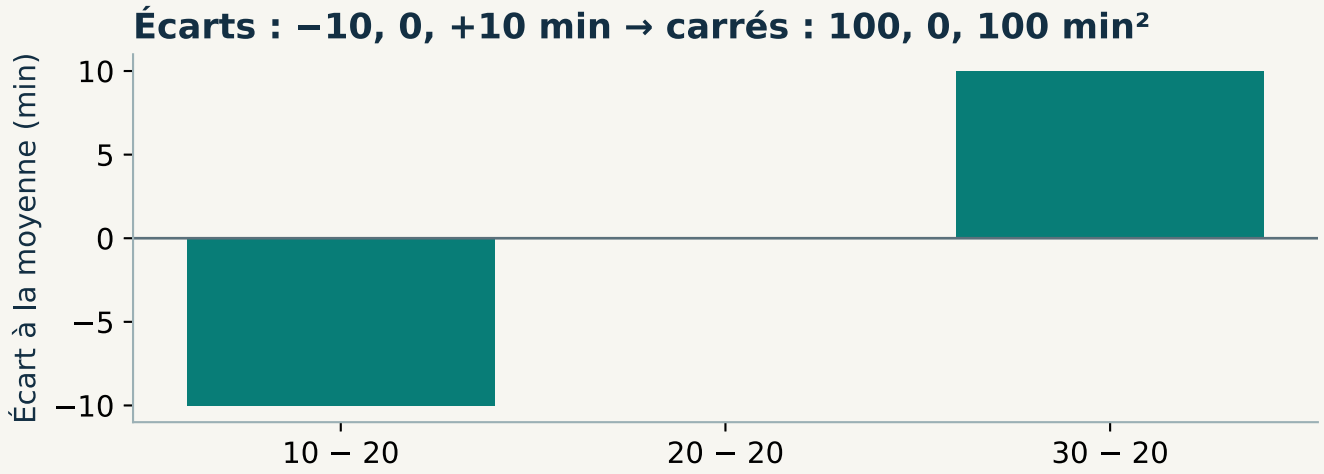
3 $$s = \sqrt{100} = 10$$

L'écart-type vaut 10 minutes.

```
x <- c(10, 20, 30)
sum((x - mean(x))^2) / (length(x) - 1) # 100
var(x)                                 # 100
sqrt(var(x))                           # 10
sd(x)                                  # 10
```

VOIR LES ÉCARTS

La dispersion se voit aussi



UNITÉ ET INTERPRÉTATION

Le carré d’un écart en minutes est en minutes². La racine carrée ramène l’écart-type en minutes. L’écart-type décrit la variabilité des tickets.

QUESTION · Où se situent les 25 %, 50 % et 75 % ?

7 · Quartiles et IQR : lire la moitié centrale

$$h = 1 + (n-1)p, \quad j = \lfloor h \rfloor, \quad g = h - j$$

Convention R type 7 : déterminer un rang et sa partie décimale.

$$Q(p) = (1-g)x_{(j)} + g x_{(j+1)}, \quad IQR = Q_3 - Q_1$$

Entre deux rangs, interpoler ; puis mesurer la largeur centrale.

Les n valeurs sont triées ; p est une proportion entre 0 et 1 ; h est un rang théorique ; j est le plus grand entier inférieur ou égal à h ; g est la part de chemin vers la valeur suivante. x_(j) est la valeur de rang j. Si g = 0, prendre directement x_(j). Aux extrémités, Q(0) est le minimum et Q(1) le maximum ; pour une seule valeur, tous les quantiles valent cette valeur. Q1 = Q(0,25) et Q3 = Q(0,75). Quartiles et IQR sont en minutes.

1 $x = (10, 20, 30), \quad p = 0.25 : \; h = 1 + 2(0.25) = 1.5$

Le premier quartile est à mi-chemin des rangs 1 et 2.

2 $Q_1 = 0.5(10) + 0.5(20) = 15$

Interpolation : Q1 = 15 minutes.

3 $Q_3 = 0.5(20) + 0.5(30) = 25, \quad IQR = 25 - 15 = 10$

Le troisième quartile vaut 25 ; l'écart interquartile vaut 10 minutes.

```
x <- c(10, 20, 30)
quantile(x, c(.25, .50, .75), type = 7) # 15 20 25
IQR(x, type = 7)                        # 10
```

CONVENTION À ANNONCER

Il n'existe pas une convention universelle de quartiles. R propose plusieurs méthodes ; type 7 est le défaut de quantile. Les charnières d'un boxplot peuvent différer. Un quartile interpolé n'est pas forcément observé ; l'IQR résiste mieux aux extrêmes que l'étendue.

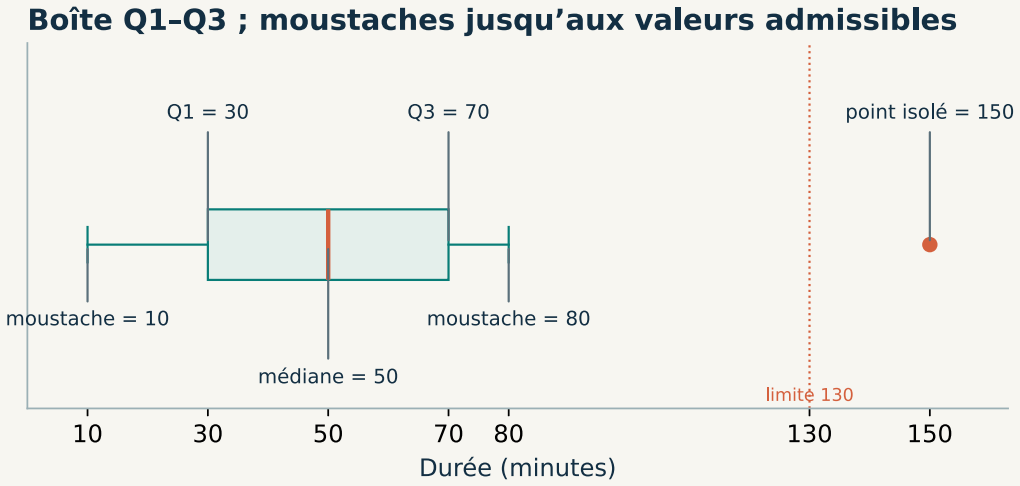
GRAPHIQUES · AVANT LE TP02

Lire une boîte sans inventer ses moustaches

Durées triées : 10, 20, 30, 40, 50, 60, 70, 80, 150 min. Pour ces neuf valeurs : Q1 = 30, médiane = 50, Q3 = 70 ; IQR = 40 min.

$$[Q_1 - 1.5\,IQR,\ \ Q_3 + 1.5\,IQR] = [-30,\ 130]$$

Les moustaches vont jusqu'aux valeurs observées dans ces limites : 10 et 80. Le point 150 est affiché séparément.




```
x <- c(10, 20, 30, 40, 50, 60, 70, 80, 150)
boxplot(x, horizontal = TRUE, xlab = "Durée (min)",
        main = "Neuf tickets : boîte et point isolé")
```

UN POINT À EXAMINER

Un point isolé n'est pas automatiquement une erreur à supprimer. La boîte de R utilise les charnières de Tukey, qui peuvent différer des quantiles de type 7 pour certains effectifs. Dans cet exemple à neuf valeurs, elles coïncident.

STRUCTURES · UN MÊME TYPE DANS TOUTES LES CASES

Matrice et array : des dimensions explicites

Matrice : 2 lignes × 3 colonnes

	col. 1	col. 2	col. 3
ligne 1	1	3	5
ligne 2	2	4	6

m[2, 1] = 2

m[ligne, colonne]

R remplit par colonnes par défaut.

```
m <- matrix(1:6, nrow = 2)
dim(m)              # 2 3
m[2, 1]             # 2
m_lignes <- matrix(1:6, nrow = 2, byrow = TRUE)
```

MATRICE

Une matrice est un tableau à deux dimensions, de type homogène. R remplit les colonnes par défaut ; byrow = TRUE demande un remplissage ligne par ligne. Une table de données à colonnes différentes reste un data.frame.

STRUCTURES · UNE DIMENSION SUPPLÉMENTAIRE

Array : plusieurs feuilles du même tableau

array : deux matrices empilées — dimensions 2 × 2 × 2

jour 1 : a[, , 1]

1	3
2	4

jour 2 : a[, , 2]

5	7
6	8

```
a <- array(1:8, dim = c(2, 2, 2))
dim(a)
a[, , 1]     # première feuille
a[2, 1, 2]   # 6
```

UNE IMAGE MENTALE

Un array peut représenter lignes × colonnes × jours. Une matrice est le cas à deux dimensions. Le cœur demande de reconnaître la structure ; écrire un traitement de grands tableaux multidimensionnels reste une extension.

STRUCTURES · CHOISIR L'OBJET SELON LA QUESTION

Liste, facteur et table : trois usages différents

Une list conserve des objets de formes et types différents

donnees	titre	valide
vecteur : 10, 20, 30	texte : "Noria"	logique : TRUE

```
objet <- list(donnees = c(10, 20, 30),
              titre = "Noria", valide = TRUE)
objet$donnees
objet[[1]]
groupe <- factor(c("A", "B", "A"), levels = c("A", "B"))
table(groupe)    # effectifs par catégorie
```

LES MOTS ÉVITENT LA CONFUSION

Une list conserve des objets hétérogènes. Un factor représente des catégories déclarées. table() calcule des effectifs. En français, “tableau” peut désigner une table de données ou un array : nommer précisément l'objet R.

PONT DE PROGRAMMATION · PETIT ET VÉRIFIABLE

Fonction, condition et boucle : une règle réutilisable

$$\bar{x}_{obs} = \frac{\sum_{i \in I} x_i}{|I|}$$

I contient les valeurs non manquantes ; vérifier les valeurs admissibles avant de résumer.

```
resumer <- function(x) {
  presents <- x[!is.na(x)]
  if (length(presents) == 0) return(c(n = 0, moyenne = NA))
  c(n = length(presents), moyenne = mean(presents))
}
resumer(c(10, NA, 30)) # n = 2 ; moyenne = 20
```

Une boucle répète une règle ; l'exemple guidé montre comment stocker chaque résultat. Les TP vous font tester une petite fonction, plutôt que développer un programme général.

Voir la boucle et ses résultats intermédiaires

QUESTION · Que calcule apply selon son deuxième argument ?

8 · Matrice : lignes, colonnes, calcul par axe

	Colonne A : durée 1	Colonne B : durée 2
Ligne 1	10	20
Ligne 2	30	40

$$\bar{x}_{i\cdot} = \frac{1}{c}\sum_{j=1}^{c} x_{ij}, \qquad \bar{x}_{\cdot j} = \frac{1}{r}\sum_{i=1}^{r} x_{ij}$$

Une moyenne par ligne utilise les c colonnes ; par colonne, les r lignes.

r est le nombre de lignes et c le nombre de colonnes ; x_ij est la valeur à la ligne i et colonne j. Σ additionne les valeurs de l'axe indiqué. Le point dans l'indice désigne l'axe résumé. Les quatre cellules sont ici des durées en minutes : les moyennes restent en minutes.

1 $\bar{x}_{1\cdot} = (10+20)/2 = 15, \quad \bar{x}_{2\cdot} = 35$ — Résumer chaque ligne : deux moyennes, 15 et 35 minutes.

2 $\bar{x}_{\cdot 1} = (10+30)/2 = 20, \quad \bar{x}_{\cdot 2} = 30$ — Résumer chaque colonne : 20 et 30 minutes.

```
m <- matrix(c(10, 20, 30, 40), nrow = 2, byrow = TRUE)
dim(m)              # 2 2
m[1, 2]             # 20
apply(m, 1, mean)   # 15 35 : lignes
apply(m, 2, mean)   # 20 30 : colonnes
```

PIÈGE

Une matrice R possède un type commun pour toutes ses cellules. Noria est un data.frame : utiliser apply sur toutes ses colonnes peut convertir les nombres en texte. Sélectionner d'abord un bloc numérique cohérent ; ne pas moyenner des identifiants ou des codes de catégories.

GRAPHIQUES · DES EFFECTIFS PAR INTERVALLE

Histogramme : compter avant de tracer

$$n_j = \sum_{i=1}^{n} \mathbf{1}\{a_j \le x_i < a_{j+1}\}$$

n_j compte les valeurs dans la classe j ; l'indicatrice vaut 1 si la condition est vraie, 0 sinon.

Cinq durées : 10, 20, 30, 40, 50 minutes. Compter les valeurs dans chaque classe avant d'exécuter hist().

Classe de cet exemple	Effectif
[0,20[	1
[20,40[	2
[40,60[	2

```
x <- c(10, 20, 30, 40, 50)
h <- hist(x, breaks = c(0, 20, 40, 60),
          right = FALSE, plot = FALSE)
h$counts   # 1 2 2
plot(h, xlab = "Durée (min)", ylab = "Effectif",
     main = "Cinq durées, trois classes")
```

LIRE LE GRAPHIQUE

Changer les bornes change l'apparence. Toujours indiquer unités et effectifs. Le boxplot résume centre/dispersion ; ses moustaches ne représentent pas forcément le minimum et le maximum.

QUESTION · B présente-t-il une durée moyenne différente de A ?

9 · Définir le sens de la différence

$$\hat{\Delta} = \bar{x}_B - \bar{x}_A$$

Une différence orientée : toujours B moins A.

x̄_A et x̄_B sont les moyennes observées dans les groupes A et B, en minutes. Δ avec un chapeau est leur différence estimée, en minutes. Δ sans chapeau désignera la différence des moyennes dans les populations visées. Le contraste reste B − A dans les calculs, graphiques et conclusions.

Groupe	Durées observées (min)	Moyenne (min)
A	10, 12, 14	12
B	8, 10, 12	10

1 $$\bar{x}_A = (10 + 12 + 14)/3 = 12$$ Calculer séparément la moyenne de A.

2 $$\bar{x}_B = (8 + 10 + 12)/3 = 10$$ Calculer séparément la moyenne de B.

3 $$\hat{\Delta} = 10 - 12 = -2$$ B a une moyenne observée inférieure de 2 minutes.

```
A <- c(10, 12, 14)
B <- c(8, 10, 12)
delta <- mean(B) - mean(A) # -2
```

PORTÉE

Une différence observée est une description. Un argument causal exige un protocole adapté, par exemple une répartition aléatoire des workflows. Pour une analyse de groupes indépendants, un ticket ne doit pas apparaître dans les deux groupes ; des mesures appariées demandent une autre analyse.

QUESTION · Que deviendrait la moyenne si nous reprenions un échantillon ?

10 · Dispersion des tickets ≠ précision de la moyenne

$$\widehat{SE}(\bar{x}) = \frac{s}{\sqrt{n}}$$

L'erreur standard estimée décrit la variation de la moyenne entre échantillons.

s est l'écart-type des durées entre tickets ; n est leur nombre ; SE signifie erreur standard. Tous deux sont en minutes, mais ils répondent à des questions différentes. La formule suppose des observations indépendantes et une variance de population finie. On ne voit qu'un échantillon ; s / √n estime cette variabilité hypothétique.

Grandeur	Question	Même dispersion, plus de tickets
s	À quel point les tickets diffèrent-ils ?	Pas nécessairement plus petit
SE de $\bar{x}$	À quel point la moyenne varie-t-elle ?	En général plus petit, comme 1/√n

1 $x = (10, 20, 30), \quad s = 10, \quad n = 3$

Les trois durées ont un écart-type de 10 minutes.

2 $$\widehat{SE}(\bar{x}) = 10/\sqrt{3} \simeq 5.77$$

La précision estimée de la moyenne s'exprime ici par 5,77 minutes.

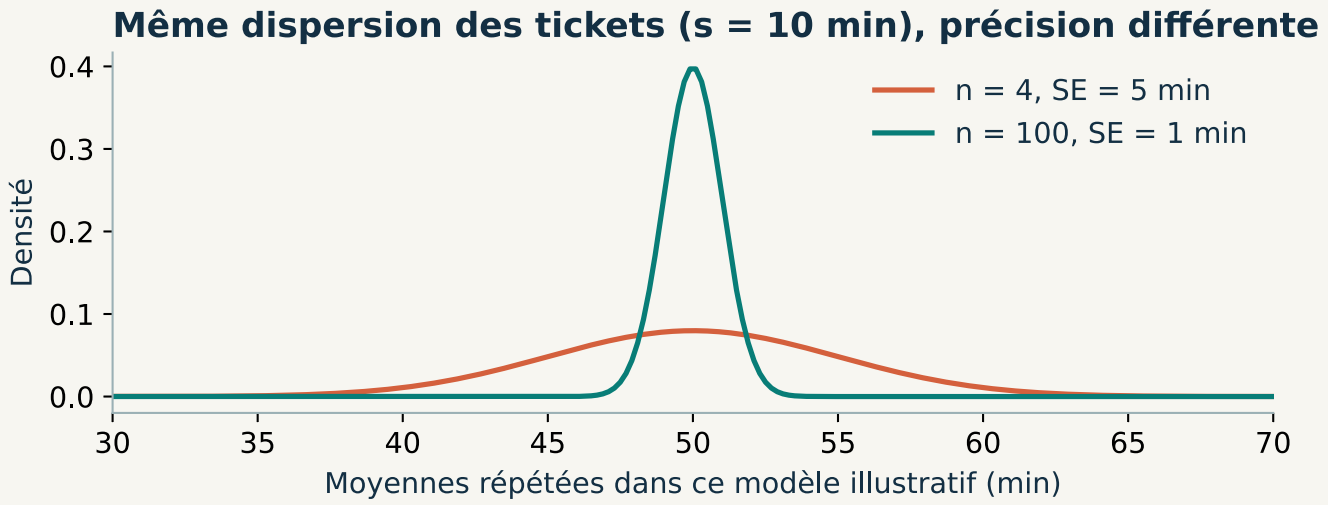
```
x <- c(10, 20, 30)
s <- sd(x)                  # 10
se_moyenne <- s / sqrt(length(x))
se_moyenne                  # 5.773503
```

PIÈGE

L'erreur standard ne dit pas où se situent 95 % des tickets. Recopier les mêmes tickets augmente artificiellement n sans ajouter d'information indépendante. Des tickets dépendants au sein d'une équipe peuvent nécessiter une méthode qui tient compte de ce regroupement.

SCHÉMA NORMAL · INDÉPENDANCE ET DISPERSION FIXÉE

Les moyennes deviennent plus précises



UNE ILLUSTRATION, PAS UNE PREUVE SUR NORIA

Le modèle illustratif suppose une dispersion fixe de 10 min et des observations indépendantes. Les moyennes sont plus resserrées avec n = 100 qu'avec n = 4. Les données manquantes ou dépendances demandent une autre réflexion.

QUESTION · Quelle est l'erreur standard de B − A ?

11 · Welch : combiner deux incertitudes

$$\widehat{SE}(\hat{\Delta}) = \sqrt{\frac{s_B^2}{n_B} + \frac{s_A^2}{n_A}}$$

Les variances estimées des deux moyennes indépendantes s'additionnent.

s_A² et s_B² sont les variances d'échantillon des durées (min²) ; n_A et n_B sont leurs effectifs. Chaque rapport s²/n estime une variance de moyenne en min². La racine carrée donne l'erreur standard de la différence, en minutes. Welch n'impose pas l'égalité des deux variances.

1 $A = (10, 12, 14), \quad B = (8, 10, 12)$

Deux groupes indépendants de trois durées.

2 $$s_A^2 = (4 + 0 + 4)/(3 - 1) = 4, \quad s_B^2 = 4$$

Chaque variance d'échantillon vaut 4 min².

3 $$\widehat{SE}(\hat{\Delta}) = \sqrt{4/3 + 4/3} = \sqrt{8/3} \simeq 1.633$$

L'erreur standard de la différence vaut environ 1,633 minute.

```
A <- c(10, 12, 14); B <- c(8, 10, 12)
vA <- var(A); vB <- var(B)
se_delta <- sqrt(vB / length(B) + vA / length(A))
se_delta                    # 1.632993
welch <- t.test(B, A, var.equal = FALSE)
unname(welch$stderr)        # même résultat
```

PIÈGE

On additionne les variances des moyennes, puis on prend la racine. Additionner directement deux écarts-types ne donne pas cette erreur standard. L'indépendance est une hypothèse de conception ; un test ne peut pas la créer.

QUESTION · L'écart observé serait-il surprenant si Δ = 0 ?

12 · Statistique t et p-valeur : mesurer l'incompatibilité

$$t_{\text{obs}} = \frac{\hat{\Delta} - 0}{\widehat{SE}(\hat{\Delta})}$$

Exprimer l'écart à zéro en nombre d'erreurs standards.

$$p = 2P(T_\nu \geq |t_{\text{obs}}| \mid H_0)$$

Pour le test bilatéral : additionner les deux queues de la loi de référence.

H0 affirme Δ = 0 dans la population ; t_obs est sans unité ; T_v suit une loi de Student de référence ; v (« nu ») est son nombre de degrés de liberté, ajusté par Welch. P désigne une probabilité calculée sous H0 et les hypothèses du modèle. La p-valeur est une probabilité d'écarts au moins aussi extrêmes, pas la probabilité que H0 soit vraie.

1 $$t_{\text{obs}} = (-2)/1.632993 \simeq -1.224745$$

La différence observée vaut environ −1,225 erreur standard.

2 $$\nu = 4, \quad p \simeq 0.287864$$

R fournit les degrés de liberté de Welch et la p-valeur bilatérale.

```
A <- c(10, 12, 14); B <- c(8, 10, 12)
w <- t.test(B, A, var.equal = FALSE)
t_obs <- unname(w$statistic)  # -1.224745
ddl <- unname(w$parameter)    # 4
2 * pt(-abs(t_obs), df = ddl) # 0.2878641
w$p.value                     # même résultat
```

À INTERPRÉTER

Avec un seuil fixé à 5 %, ce jouet ne conduit pas à rejeter H0. Cela ne prouve ni l'égalité des moyennes ni l'absence d'effet utile. Lire aussi l'effet et son intervalle. Pour de très petits groupes, la référence Student requiert des populations suffisamment normales ; inspecter les distributions et les valeurs extrêmes.

QUESTION · Quelles différences restent compatibles avec les données et le modèle ?

13 · Intervalle à 95 % : effet et précision sur la même ligne

$$IC_{95\%} = \left[\hat{\Delta} - t_{0.975,\,\nu}\widehat{SE},\ \ \hat{\Delta} + t_{0.975,\,\nu}\widehat{SE}\right]$$

Estimation ± marge : le multiplicateur vient de la loi de Student.

Δ̂ est la différence B − A en minutes ; SE est son erreur standard en minutes ; v est le nombre de degrés de liberté de Welch. t_0.975,v est le quantile laissant 97,5 % de la loi de Student à sa gauche, sans unité. Les 2,5 % restants de chaque côté forment un intervalle bilatéral à 95 %.

1 $$t_{0.975,\,4} \simeq 2.776445$$

Le multiplicateur est obtenu avec qt ; ce n'est pas toujours 1,96.

2 $$\text{marge} = 2.776445 \times 1.632993 \simeq 4.533916$$

La marge d'incertitude vaut environ 4,534 minutes.

3 $$IC_{95\%} = [-2 - 4.533916,\ \ -2 + 4.533916]$$

Intervalle : [−6,533916 ; 2,533916] minutes.

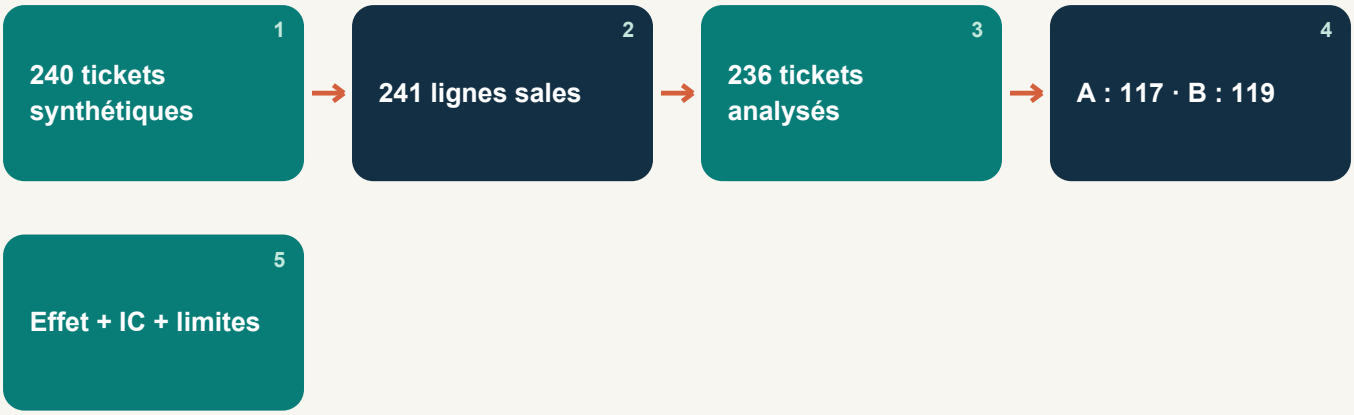
```
A <- c(10, 12, 14); B <- c(8, 10, 12)
w <- t.test(B, A, var.equal = FALSE, conf.level = .95)
delta <- mean(B) - mean(A)
tcrit <- qt(.975, df = unname(w$parameter))
delta + c(-1, 1) * tcrit * w$stderr
unname(w$conf.int)   # -6.533916  2.533916
```

INTERPRÉTATION

L'intervalle traverse zéro : les données restent compatibles avec une moyenne de B plus faible ou plus élevée. À long terme, la procédure couvre la vraie différence dans environ 95 % des répétitions sous ses hypothèses. Ce n'est ni un intervalle pour 95 % des tickets ni une probabilité de 95 % attribuée au paramètre fixe.

QUESTION · Que peut-on conclure sur B − A après les contrôles ?

14 · Noria : effet proche du seuil, précision à montrer



$$\hat{\Delta} = -4.5648, \quad IC_{95\%} = [-9.1476,\ 0.0181]$$

Différence B − A et bornes de son intervalle, toutes en minutes.

La différence conserve l'orientation B − A ; une valeur négative indique une durée moyenne plus faible pour B. n_A = 117 et n_B = 119 sont les effectifs analysés. Les bornes sont arrondies seulement pour l'affichage ; le test utilise la précision complète.

1 $$n_A + n_B = 117 + 119 = 236$$

Le total des deux groupes rejoint le journal de nettoyage.

2 $$(-9.1476 + 0.0181)/2 \simeq -4.5648$$

Vérification avec les bornes arrondies : leur centre retrouve l'estimation, à l'arrondi près.

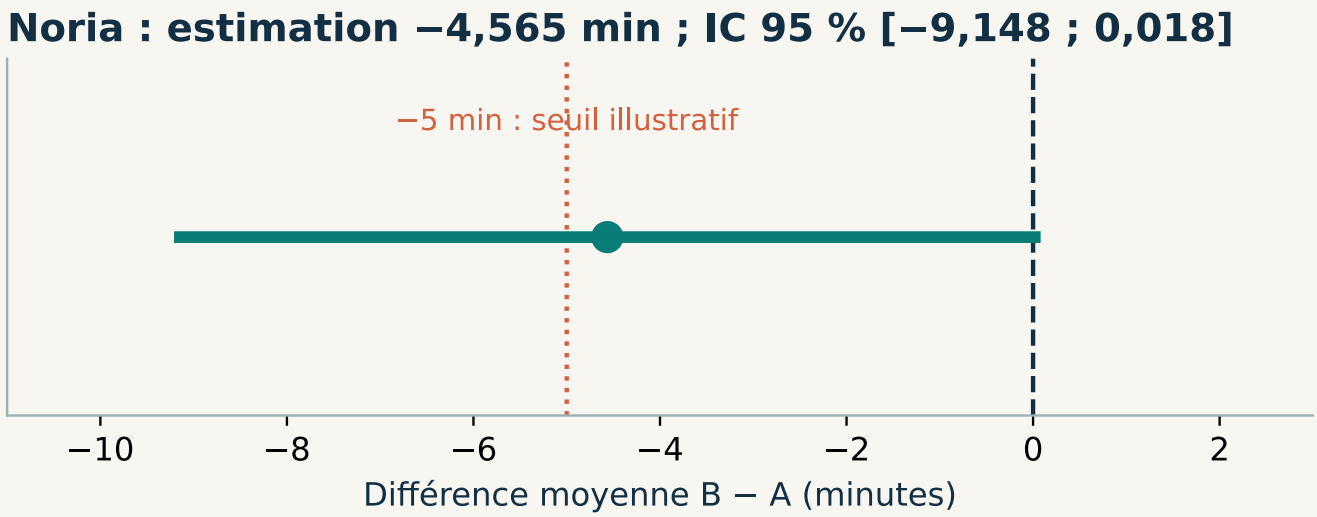
3 $$(0.0181 + 9.1476)/2 \simeq 4.5829$$

La demi-largeur de l'intervalle donne une marge d'environ 4,583 minutes.

```
A <- clean$resolution_minutes[clean$workflow == "A"]
B <- clean$resolution_minutes[clean$workflow == "B"]
stopifnot(length(A) == 117, length(B) == 119)
w <- t.test(B, A, var.equal = FALSE, conf.level = .95)
mean(B) - mean(A)     # -4.5647848883
unname(w$conf.int)    # -9.1476483068  0.0180785301
w$p.value             # 0.05090316485
```

LE ZÉRO ET LE SEUIL UTILE SONT DEUX QUESTIONS

Voir l’intervalle de Noria



INTERPRÉTER

L’IC contient légèrement zéro avant arrondi. Il contient aussi −5 min : ces données ne démontrent pas un gain minimal de 5 min. Une recommandation peut être de poursuivre l’essai.

OBJETS STATISTIQUES · EXTRAIRE LES QUANTITÉS DÉJÀ DÉFINIES

Le résultat du test est un objet à lire

```
class(w)
names(w)
attributes(w)
w$estimate
w$conf.int
w$p.value
resultat <- data.frame(
  delta = mean(B) - mean(A),
  bas = w$conf.int[1], haut = w$conf.int[2], p = w$p.value)
```

w est le résultat de t.test(B,A) créé à la page « Noria : effet proche du seuil ». $ accède à une composante nommée ; [1] et [2] sélectionnent les bornes. data.frame range les quantités dans une table, sans les ressaisir.

SAUVEGARDER UNE PREUVE

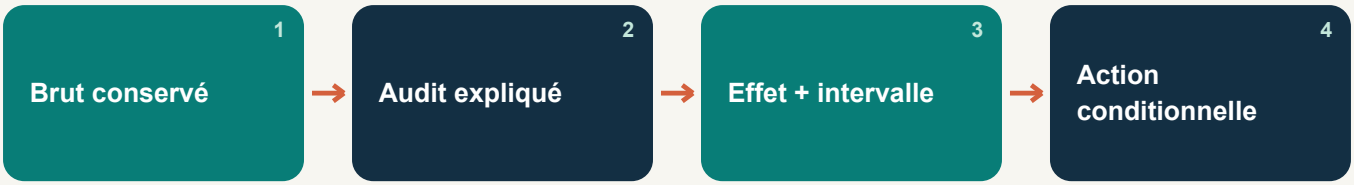
Avant write.csv(), créer le dossier. Avant un graphique PDF, ouvrir pdf() ; après le graphique, fermer dev.off(). L'exemple guidé montre le cycle complet.

Exemples d'export et de Welch

TP03 : comparer deux groupes

PROJET FINAL · QUATRE PREUVES, UNE QUESTION

Rendre une décision que l’on peut discuter



Dans la note PDF	Ce que le lecteur doit retrouver
Question	Population, unité, contraste B−A
Qualité	Effectifs avant/après et motifs d’exclusion
Résultat	Estimation, IC 95 % et nombres de tickets ; figures dans un PDF séparé
Décision	Ampleur utile, incertitude, limites et prochaine donnée

L’AUTONOMIE A UNE PREUVE

Fermer puis relancer R et exécuter le fichier enregistré. Votre résultat doit provenir du brut et de vos règles. Les fichiers des TP01–03 font partie du portfolio final ; les extensions ne donnent pas de points indispensables.

TP04 : projet individuel

Défis facultatifs, après le cœur

SOURCES PRIMAIRES · LIENS ET DOCUMENTATION LOCALE

Pour vérifier et continuer

- R, définition et objectifs : https://www.r-project.org/about.html
- R, créateurs et équipe : https://www.r-project.org/contributors.html
- Chambers, S, R and Data Science : https://journal.r-project.org/articles/RJ-2020-028/index.html
- Introduction officielle : https://cran.r-project.org/doc/manuals/r-patched/R-intro.html
- R en pratique industrielle en 2026 : https://r-consortium.org/posts/submissions-wg-2026/
- Dans votre installation : ?mean, ?median, ?var, ?sd, ?quantile, ?matrix, ?array, ?data.frame, ?list, ?t.test.

LIRE UNE AIDE EFFICACEMENT

Chercher l'argument utilisé et l'exemple minimal, puis le modifier. Le mémo et les mini-exemples du kit restent disponibles hors connexion.

Mémo de commandes et notations

Retour au parcours des quatre TP

01 / 03 · examples/mini_vecteurs.R · avant TP01

Du calcul papier à la sélection

Exécutez une ligne, annoncez la suivante, vérifiez. Les exemples sont intégralement résolus pour rendre le geste visible ; revenez ensuite au fichier de TP et à ses autres nombres.

$$\bar{x} = \frac{10+20+30}{3} = 20 \quad ; \quad p_{\geq 20} = \frac{2}{3} \quad ; \quad p_{NA} = \frac{1}{4}$$

Sur x=(10,NA,20,30), trois valeurs observées et quatre positions. La médiane vaut 20.

```
x <- c(10, NA, 20, 30)
length(x)
sum(!is.na(x))
mean(x)                    # NA
y <- x[!is.na(x)]
mean(y)                    # 20
median(y)                  # 20
mean(y >= 20)              # 2/3
mean(is.na(x))             # 1/4
```

Je lis	Je comprends
x <- ...	Créer un nom ; le réutiliser évite de retaper les données.
!is.na(x)	Un masque TRUE pour les valeurs présentes.
x[masque]	Extraire les positions dont le masque vaut TRUE.
na.rm = TRUE	Argument nommé : autoriser le calcul sur les valeurs présentes.

- Prévoir la sortie de mean(c(10,0,20,30)) : remplacer NA par zéro pose une autre question.
- Transfert TP01 : quelle expression faut-il modifier pour passer de ≥20 à ≥60 ? Le dénominateur reste-t-il le même ?

02 / 03 · examples/mini_nettoyage.R · avant TP02

Une table sale, une trace visible

id	groupe	minutes
1	" A "	10
2	"B"	20
2	"B"	20
3	"A"	NA
4	"B"	−5
5	"A"	30

Le script construit ces six lignes sans import. Il corrige une cellule de groupe, garde le premier doublon puis exclut une durée inconnue et une négative. Audit : 6→6→5→4→3. Trois tickets restent : 1, 2 et 5.

```
masque <- !is.na(mini_d$minutes)
mini_d <- mini_d[masque, , drop = FALSE]
# Le fichier complet montre une ligne d'audit après chaque règle.
dir.create("results", showWarnings = FALSE)
write.csv(mini_d, "results/mini_nettoyage_clean.csv",
  row.names = FALSE)
pdf("results/mini_nettoyage.pdf")
plot(mini_d$id, mini_d$minutes, ylab = "Minutes")
dev.off()
```

- Après nettoyage : A=(10,30), B=(20). Les deux moyennes valent 20 ; l'écart type de A vaut √200 ≈14,14, celui de B est NA car n=1.
- Le script complet écrit aussi mini_nettoyage_audit.csv et mini_nettoyage_stats.csv. Ouvrez les trois CSV et le PDF depuis results/.
- Transfert TP02 : les mêmes gestes s'appliquent aux six colonnes de Noria ; vos comptes d'audit et votre fonction restent à construire.

UNE LIMITE VISIBLE

Ce mini-jeu montre les gestes de nettoyage ; il est trop petit pour la comparaison A/B attendue dans le TP03. Ne le confondez pas avec les données de l'étude.

03 / 03 · mini_structures.R puis mini_welch.R

Fonction, structure, résultat de test

```
resumer <- function(x) {
  if (length(x) < 2) stop("Au moins deux valeurs")
  c(n=length(x), moyenne=mean(x), sd=sd(x))
}
resumer(c(10,20,30,40))
m <- matrix(c(10,20,30,40,50,60), nrow=2, byrow=TRUE)
apply(m, 1, mean)          # 20 et 50
for (i in seq_len(nrow(m))) {
  print(mean(m[i, ]))
}
```

Le fichier mini_structures.R nomme aussi les lignes/colonnes et inspecte une liste. apply(m,1,...) travaille par ligne ; 2 désigne les colonnes. La boucle montre le même calcul. Le transfert obligatoire au TP02 est seulement une fonction de résumé ; matrices et boucles ne sont pas exigées en inférence.

$$\widehat{\Delta} = 11 - 13 = -2 \quad ; \quad SE = \sqrt{\frac{20/3}{4} + \frac{20/3}{4}} \simeq 1{,}83$$

Mini-Welch : A=(10,12,14,16), B=(8,10,12,14). Les deux écarts types valent √(20/3).

```
test <- t.test(c(8,10,12,14), c(10,12,14,16))
class(test)               # "htest"
attributes(test)
names(test)
unname(test$conf.int)     # environ [-6.47 ; 2.47]
test$p.value              # environ 0.315
```

TRANSFERT TP03

Δ est négatif, mais cet IC contient zéro. Une liste de classe htest possède des composantes nommées. Lisez les noms puis extrayez : ne recopiez pas les nombres et ne concluez pas à une égalité.

AVANT TP02 · SANS RECOPIER LES NOMBRES

Passer d’une fonction à deux lignes de résumé

Le vecteur renvoyé par une fonction contient des nombres nommés. as.list() en fait une liste avec un élément par indicateur. data.frame() range ces indicateurs en colonnes ; rbind() rassemble les deux lignes.

```
resumer_mini <- function(x) {
  c(n=length(x), moyenne=mean(x), ecart_type=sd(x))
}
a <- c(10, 20, 30)
b <- c(20, 30, 40)
ra <- resumer_mini(a)
rb <- resumer_mini(b)
ligne_a <- data.frame(workflow="A", as.list(ra))
ligne_b <- data.frame(workflow="B", as.list(rb))
mini_resume <- rbind(ligne_a, ligne_b)
rownames(mini_resume) <- NULL
mini_resume
```

workflow	n	moyenne	ecart_type
A	3	20	10
B	3	30	10

TRANSFERT

Votre fonction ajoute les quartiles et la médiane. Elle peut renvoyer un vecteur numérique nommé ou une table d’une ligne dans l’ordre demandé. Le contrôle vérifie aussi le calcul sur un autre vecteur.

AVANT TP02 ET TP03 · LIRE LE SYMBOLE ~

Comparer les distributions de deux groupes

Deux groupes jouets : A = 10, 12, 14, 16 et B = 8, 10, 12, 14 minutes. Chaque ligne garde son groupe et sa durée ; le graphique doit comparer les distributions, pas seulement les moyennes.

```
mini_table <- data.frame(
  workflow = rep(c("A", "B"), each = 4),
  duree = c(10,12,14,16,8,10,12,14))
dir.create("results", showWarnings = FALSE)
pdf("results/mini_distributions.pdf", width=7, height=4)
boxplot(duree ~ workflow, data=mini_table,
  xlab="Workflow", ylab="Durée (min)",
  main="Deux groupes jouets")
hist(mini_table$duree, xlab="Durée (min)",
  main="Huit durées jouets")
dev.off()
```

Syntaxe	Ce qu'elle veut dire
duree ~ workflow	Lire : durée selon le groupe ; ce symbole décrit le graphique.
data = mini_table	Chercher ces deux colonnes dans cette table.
hist(mini_table$duree)	Une seule distribution ; la colonne numérique de toutes les lignes.

TRANSFERT

Dans Noria, remplacer duree par resolution_minutes et mini_table par votre clean. Relire les légendes de la boîte dans le cours. Le fichier mini_welch.R contient aussi cette démonstration.

AVANT TP03 · EXEMPLE JOUET

Dessiner un effet et son intervalle

$$\widehat{\Delta} = -2, \quad IC_{95\%} \simeq [-6.47, 2.47]$$

A = 10, 12, 14, 16 et B = 8, 10, 12, 14. Le zéro est une référence, pas une borne imposée.

```
a <- c(10,12,14,16)
b <- c(8,10,12,14)
w <- t.test(b, a)
delta <- mean(b) - mean(a)
ic <- unname(w$conf.int)
dir.create("results", showWarnings = FALSE)
pdf("results/mini_welch_intervalle.pdf", width=7, height=3)
plot(delta, 1, xlim=range(c(ic, 0)), ylim=c(.5, 1.5),
     yaxt="n", ylab="", xlab="B - A (minutes)", pch=19)
segments(ic[1], 1, ic[2], 1, lwd=2)
abline(v=0, lty=2)
dev.off()
```

TRANSFERT

Dans votre TP, extrayez les valeurs de VOTRE objet de test. Un point représente l'estimation ; un segment horizontal les deux bornes. Le fichier complet est examples/mini_welch.R.

AVANT TP04 · MISE EN PAGE FOURNIE

Mettre trois phrases dans un PDF

Le texte et le raisonnement vous appartiennent. Le fichier examples/mini_note_pdf.R fournit ecrire_note_pdf(lignes, chemin), une aide de mise en page. Il génère une seule page ou signale que le texte est trop long.

```
source("examples/mini_note_pdf.R", encoding="UTF-8")
phrases <- c("Sur trois durées : 10, 20, 30 minutes.",
  "Leur moyenne est 20 minutes.",
  "Cet exemple ne permet pas une décision sur une population.")
ecrire_note_pdf(phrases, "results/mini_note_personnelle.pdf")
```

TRANSFERT TP04

Réutilisez ecrire_note_pdf(recommandation4, "results/TP04_recommandation.pdf") après avoir rédigé vos phrases. Ouvrez le PDF, vérifiez titres et lisibilité, puis gardez les graphiques séparés. Le script miniature montre aussi plot.new(), strwrap() et text().

TP01 · 90 MIN · 70 INDIVIDUELLES / 9 TRIADE / 11 RETOUR

Commencer par les nombres

Cours p.2–12 : cours visuel

Voir le mini-exemple guidé

Ouvrir le fichier de travail

Ouvrez course.Rproj puis labs/TP01_demarrer.R. Travail individuel : chacun écrit son script ; un binôme peut expliquer une erreur. Aucun paquet à installer, aucun fichier du dossier R/ à charger.

```
durees <- c(42, NA, 35, 80, 55, NA, 20, 60)
```

- Sans R : comptez toutes les positions puis les valeurs présentes ; recopiez les valeurs présentes dans l'ordre croissant.
- Écrivez la somme, puis la division qui donne la moyenne des valeurs présentes. Pour la médiane, repérez les deux valeurs centrales et faites leur moyenne.
- Comptez les durées ≥ 60 parmi les durées observées. Comptez les NA parmi tous les tickets. Écrivez les deux fractions avant les décimales.

$$\bar{x} = \frac{\sum_{i=1}^{n} x_i}{n}$$

Ici n désigne les durées observées ; une durée inconnue ne vaut pas zéro.

$$p_{60} = \frac{n_{x \geq 60}}{n_{\text{observes}}} \qquad p_{NA} = \frac{n_{NA}}{n_{\text{total}}}$$

Deux questions, donc deux dénominateurs à justifier.

PONT GUIDÉ

Exécutez examples/mini_vecteurs.R ligne par ligne : 10, NA, 20, 30. Sa moyenne des valeurs présentes est 20 ; 2/3 atteignent 20 et 1/4 sont absentes. Transférez le geste, puis revenez à vos huit tickets.

02 / 03 · 40 min de programmation

Écrire puis vérifier chaque objet

Objet à compléter	Calcul à traduire
n_total ; n_valides	Nombre de positions ; nombre de valeurs présentes.
durees_valides	Extraire les valeurs non manquantes avec un masque logique.
moyenne ; mediane	Résumé de la durée, en minutes, en ignorant les NA selon la règle choisie.
proportion_60	Part des durées ≥ 60 parmi les durées observées.
proportion_manquantes	Part des tickets à durée inconnue.

```
# Gestes appris sur un autre vecteur :
x <- c(10, NA, 30)
x[!is.na(x)]
mean(x, na.rm = TRUE)
```

- Remplacez les NA du script par des expressions, pas par les nombres attendus. Affichez chaque objet pour confronter au calcul papier.
- Construisez resume_tp01 : une ligne, colonnes n_total, n_valides, moyenne, mediane, proportion_60, proportion_manquantes.
- Créez results/ puis exportez le tableau avec write.csv(..., row.names = FALSE). Une ligne ne doit pas devenir une colonne de numéros inutile.

> **LIRE UNE ERREUR**
>
> Le try() du script provoque une erreur d'objet inexistant. Affichez erreur_tp01 puis vérifiez inherits(erreur_tp01, "try-error"). try() sert ici à apprendre, pas à masquer des erreurs réelles.

03 / 03 · 10 min de contrôle + 10 min d'interprétation

Une preuve et trois phrases

```
source("checks/TP01.R", encoding = "UTF-8")
```

MESSAGE DE RÉUSSITE

TP01 : contrôles réussis. Un fichier de départ intact doit échouer : commencez par corriger le premier objet nommé, puis relancez le script et le contrôle.

- Livrez votre script personnel et results/TP01_resume.csv. Le contrôle compare aussi le contenu du CSV à l'objet en mémoire.
- Complétez interpretation_tp01 : 1) moyenne et médiane avec unité ; 2) les deux proportions et leurs dénominateurs ; 3) ce que NA signifie et pourquoi zéro changerait la réponse.
- Expliquez oralement une ligne d'indexation à votre voisin. Demandez-lui quelle question votre proportion mesure exactement.

Critère de réussite	À observer
Papier ↔ R	Les calculs manuels et les objets R concordent.
Valeurs manquantes	Six durées sont observées, mais huit tickets sont enregistrés.
Raisonnement	Les deux fractions ne prennent pas le même dénominateur.
Autonomie	La session peut être redémarrée et le script relancé de haut en bas.

SI VOUS ÊTES BLOQUÉ

Ouvrez 14_memo_R.pdf, page 1. Recopiez un exemple de trois nombres, observez sa sortie, puis adaptez un seul geste à la fois. Le contrôle automatique ne juge pas la qualité de vos phrases : relisez-les.

TP02 · 120 MIN · 90 INDIVIDUELLES / 9 TRIADE / 21 RETOUR

Du brut aux règles

Cours p.13–24 : cours visuel

Voir le mini-exemple guidé

Ouvrir le fichier de travail

Ouvrez labs/TP02_preparer.R depuis le projet. Le CSV Noria contient 241 lignes enregistrées et six colonnes. Une unité statistique est un ticket indépendant ; ticket_id est un identifiant, pas une mesure.

```
raw <- read.csv("data/noria_dirty.csv",
  na.strings = c("", "NA"), stringsAsFactors = FALSE,
  colClasses = c("integer", "character", "numeric",
    "numeric", "numeric", "character"))
str(raw)
names(raw)
```

Colonne	Sens / type d'analyse
ticket_id ; workflow	Identifiant entier ; catégorie A/B.
resolution_minutes	Mesure quantitative en minutes ; variable principale.
complexity ; satisfaction	Scores 1–5 ; satisfaction ordinale et parfois inconnue.
team	Catégorie Atlas/Boreal/Cedre.

- Sur papier, annoncez le sort des espaces, doublons, durées absentes et durées négatives. Une satisfaction absente justifie-t-elle de supprimer une durée valide ?
- Lancez examples/mini_nettoyage.R sur six lignes : observez le masque d[lignes, colonnes], la virgule, le dossier créé et le PDF fermé par dev.off(). Les règles du TP restent à écrire par vous.

> **POINT DE VIGILANCE**
>
> Conservez raw intact. Une conversion factor() peut cacher un libellé inconnu en le remplaçant par NA : vérifiez les modalités autorisées avant de convertir.

02 / 03 · 40 min de nettoyage

Auditer après chaque règle

Étape	Action et point de contrôle
import	241 → 241 ; aucun retrait.
espaces	trimws sur workflow et team ; 3 et 4 cellules modifiées ; 241 lignes.
doublons	Le ticket 17 est répété ; valeurs identiques ; conserver le premier ; 240 lignes.
durees_absentes	Tickets 21, 87, 154 ; conserver les identifiants et motifs ; 237 lignes.
durees_invalides	Ticket 203 : durée négative ; 236 lignes.
facteurs	Niveaux explicites ; 236 lignes, 117 A et 119 B ; 12 satisfactions absentes conservées.

```
# Exemple sur une autre table :
t <- data.frame(id = 1:3, valeur = c(10, NA, 30))
masque <- !is.na(t$valeur)
t[masque, , drop = FALSE]
```

- Construisez audit avec etape, n_avant, n_apres, n_exclues, n_cellules_modifiees. Une ligne après chaque règle, même sans retrait.
- Créez exclusions avec ticket_id et motif : duree_absente ou duree_invalide. Le doublon est déjà compté dans l'audit.
- Nommez ids_doublons, ids_absents, ids_invalides, n_espaces_workflow et n_espaces_team. Affectez le tableau final à clean, puis n_satisfaction_absente.

JUSTIFIER LES EXCLUSIONS

Pas d'imputation de durée : inventer une valeur modifierait la moyenne et la variance. Si un doublon a des versions conflictuelles, il faut enquêter ; la règle de Noria ne suffit plus.

03 / 03 · 30 min décrire + 20 min exporter et contrôler

Décrire et livrer les preuves

$$s = \sqrt{\frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n-1}}$$

Écart type échantillonnal : sd() ; unité identique à la durée. n doit être au moins 2.

$$h = 1 + (n-1)p$$

Quantile de type 7 : trier, puis interpoler au rang h. Pour 10,20,30,40 et p=0,25 : h=1,75, donc Q1=17,5.

- Complétez resumer_durees(x) : n, moyenne, ecart_type, q1, mediane, q3. Reprenez le geste fonction(x) de examples/mini_structures.R ; appelez la fonction sur les durées de A, puis de B.
- Construisez descriptifs, deux lignes A/B : workflow, n, moyenne, ecart_type, q1, mediane, q3. Précisez type = 7 dans quantile().
- Exportez TP02_clean.csv, TP02_audit.csv, TP02_exclusions.csv et TP02_descriptifs.csv dans results/, sans noms de lignes.
- Produisez TP02_graphiques.pdf : boxplot par workflow et histogramme global. Titres, axes et unité minutes ; puis dev.off().

```
source("checks/TP02.R", encoding = "UTF-8")
```

VALIDATION

Message : TP02 : contrôles réussis. Relisez aussi les graphiques : le contrôle vérifie le fichier, pas la lisibilité. Écrivez deux phrases sur les moyennes, la dispersion et l'effet possible des exclusions.

TP03 · 120 MIN · 90 INDIVIDUELLES / 9 TRIADE / 21 RETOUR

Poser la comparaison avant le test

Cours p.25–33 : cours visuel

Voir le mini-exemple guidé

Ouvrir le fichier de travail

Ouvrez labs/TP03_comparer.R. Le script lit en priorité VOTRE results/TP02_clean.csv. Si absent, data/noria_clean_reprise.csv sert de reprise : vous pouvez apprendre l'inférence, mais cela ne valide pas votre travail de nettoyage.

- Variable principale : durée de résolution, en minutes. Deux groupes de tickets indépendants, affectés au hasard dans cette simulation. Pas de paires avant/après.
- Définissez Δ = moyenne de B − moyenne de A. Une différence négative favorise B. H0 : les moyennes de population sont égales ; alternative bilatérale.
- Pourquoi Welch ? Il permet des variances de population différentes ; il n'exige pas leur égalité. Il n'annule ni dépendance ni biais de sélection.

$$\widehat{\Delta} = \bar{x}_B - \bar{x}_A \quad ; \quad SE = \sqrt{\frac{s_B^2}{n_B} + \frac{s_A^2}{n_A}}$$

SE mesure l'incertitude de l'estimation de différence, pas la dispersion des tickets individuels.

$$t = \frac{\widehat{\Delta} - 0}{SE}$$

Le test compare une différence observée à ce que permet la fluctuation sous H0.

CALCUL ET CODE SUR UN AUTRE CAS

Exécutez examples/mini_welch.R : A=(10,12,14,16), B=(8,10,12,14). Sur papier : moyennes 13 et 11, donc B−A=−2. Comparez à delta_mini, puis observez l'IC et p sans les confondre.

02 / 03 · 35 min coder + 25 min exporter

Un résultat est aussi un objet

```
# Patron appris sur le mini-exemple :
test <- t.test(x = b_mini, y = a_mini,
  var.equal = FALSE, conf.level = 0.95)
class(test)
attributes(test)
names(test)
unname(test$conf.int)
test$p.value
```

- Dans le TP, créez a et b par indexation de clean ; vérifiez les effectifs. Créez test_welch en passant x=b et y=a.
- Créez classe_test, attributs_test et noms_test en examinant l'objet. Expliquez pourquoi names() aide à choisir $conf.int et $p.value.
- Créez delta, ic95 et p_valeur, puis comparaison : contraste, delta_minutes, ic_bas, ic_haut, p_valeur. Le contraste doit être B - A.
- Observez erreur_attendue : try(t.test(c(1), c(2)), silent=TRUE). Le manque de données doit produire une erreur capturée.
- Exportez results/TP03_comparaison.csv. Produisez TP03_resultats.pdf : boîte par workflow puis point et IC horizontal de B−A, avec une ligne verticale à zéro et l'unité minutes.

TRANSFERT SIMPLE

Un htest est une liste plusieurs résultats nommés : plusieurs composantes avec des noms et une classe. Il ne faut ni retaper les nombres de la console ni récupérer un objet créé par un ancien script.

03 / 03 · 20 min contrôle et interprétation

Dire ce que les données permettent

$$IC_{95\%} = \widehat{\Delta} \pm t^{*} SE$$

À répétition sur de nouveaux échantillons selon les hypothèses, la procédure couvre la vraie différence dans 95 % des cas.

- Complétez interpretation_tp03 : 1) sens et taille du contraste avec unité ; 2) IC et p, en nommant l'incertitude ; 3) portée et limites, dont exclusions et caractère simulé.
- Si l'IC contient zéro, les données restent compatibles avec zéro et d'autres différences. Ce n'est pas une preuve d'égalité.
- p est une probabilité de résultat au moins aussi extrême sous H0 et les hypothèses du test ; ce n'est ni P(H0 vraie) ni la probabilité que B soit meilleur.
- Un seuil p=0,05 ne décide pas de l'intérêt métier. Comparez aussi l'intervalle à un gain utile annoncé à l'avance.

```
source("checks/TP03.R", encoding = "UTF-8")
```

VALIDATION

Message : TP03 : contrôles réussis. Livrez script, CSV, PDF et trois phrases. Votre conclusion doit changer si on inverse le contraste ; le sens de l'analyse ne doit pas dépendre de l'ordre alphabétique d'une formule.

QUESTION DE SORTIE

Une différence moyenne de −4 minutes avec IC [−9 ; +1] justifie-t-elle « B économise 4 minutes pour chaque ticket » ? Répondez en distinguant moyenne, tickets individuels et incertitude.

TP04 · 150 MIN · 115 INDIVIDUELLES / 9 TRIADE / 26 RETOUR

Planifier une analyse reproductible

Cours p.31–34 : cours visuel

Voir le mini-exemple guidé

Ouvrir le fichier de travail

Ouvrez labs/TP04_projet.R dans une session R redémarrée. Le départ est data/noria_dirty.csv ; aucun objet de TP précédent ne doit être requis. Vous pouvez réutiliser VOS fonctions en les recopiant explicitement et en les relisant.

- Sur papier : unité d'observation, variable principale et unité, contraste B−A, règles de nettoyage, hypothèses et livrables. Utilisez le seuil fictif de 5 minutes fixé par le protocole pédagogique ; ce n'est pas un seuil validé pour une entreprise réelle.
- Complétez nettoyer_projet(brut) : renvoyer list(data, audit, exclusions). Les fonctions vides du script échouent volontairement avec un message TODO.
- Conservez raw4 intact. Créez clean4, audit4 et exclusions4 ; audit après espaces, doublon, durée absente, durée invalide et conversion des facteurs.
- Dans audit4 : 241 lignes importées, 7 cellules de libellés corrigées, un doublon puis quatre durées exclues ; 236 tickets analysables. Expliquez le risque de biais créé par ces pertes.

Point de passage	Preuve attendue
Source	raw4 et les six colonnes initiales.
Nettoyage	audit4 avec comptes à chaque règle ; exclusions4 avec identifiants et motifs.
Fonctions	Contrats lisibles, noms d'arguments explicites, aucun chargement du pipeline de référence.

TRAÇABILITÉ

La reprise de TP03 n'est pas une preuve de nettoyage ici. Ce projet relie lui-même le fichier brut à ses sorties. Aucune régression, matrice ni simulation MapReduce n'est exigée.

02 / 03 · 30 min décrire + 25 min inférence

Décrire, comparer, visualiser

- Complétez decrire_projet(donnees) puis créez descriptifs4 : lignes A/B, colonnes workflow, n, moyenne, ecart_type, q1, mediane, q3 ; quantiles type 7.
- Créez test4 par Welch indépendant (x=B, y=A). Construisez comparaison4 : contraste, delta_minutes, ic_bas, ic_haut, p_valeur.
- Produisez results/TP04_graphiques.pdf : boîte par workflow et histogramme des durées valides, avec titre et unité. Fermez le PDF avec dev.off().
- Exportez TP04_audit.csv, TP04_exclusions.csv, TP04_descriptifs.csv et TP04_comparaison.csv, sans noms de lignes.

$$\widehat{\Delta} = \bar{x}_B - \bar{x}_A$$

Une valeur négative indique un gain moyen avec B. Elle ne promet pas un gain identique sur chaque ticket.

Position de l'IC par rapport à −5 min	zone_decision4
IC haut < −5	gain_etaye : gain utile étayé, sous les hypothèses.
Sinon, IC bas < −5	gain_possible : gain utile possible, mais non établi.
Sinon	gain_non_etaye : le gain utile n'est pas étayé.

INTERPRÉTER SANS AUTOMATISER LE JUGEMENT

Cette règle force à distinguer incertitude et utilité. La décision finale doit aussi nommer les limites des données et une action proportionnée : suivi, pilote ou étude complémentaire.

03 / 03 · 30 min recommandation et contrôle

Une page pour un décideur

- Écrivez recommandation4 en phrases personnelles : source et effectifs, pertes, estimation B−A, IC95 et p, seuil utile de 5 minutes.
- Donnez la décision conditionnelle liée à zone_decision4. Dites ce qui reste incertain, les hypothèses et les limites (exclusions, simulation, transport à la pratique).
- Proposez une prochaine action concrète et ce qu'elle mesurera. Évitez « p>0,05 donc identiques » et « l'IC95 donne 95 % de probabilité à l'effet observé ».
- Exportez results/TP04_recommandation.txt et TP04_recommandation.pdf : UNE page de texte lisible ; les graphiques restent dans leur PDF séparé.
- Pour mettre vos phrases en PDF, voir le gabarit de examples/mini_note_pdf.R et le dernier mini-exemple guidé.
- Créez session4 <- sessionInfo(), puis writeLines(capture.output(session4), "results/TP04_sessionInfo.txt").

```
source("checks/TP04.R", encoding = "UTF-8")
```

Évaluation	Attendu
Traçabilité et qualité des données	Brut préservé, audit fidèle, exclusions justifiées.
Analyse	Descriptifs cohérents, signe B−A, Welch, intervalle et p correctement extraits.
Décision	Seuil prévu, conclusion conditionnelle et limites expliquées.
Reproductibilité	Session neuve, script de haut en bas, CSV/PDF réels et lisibles.

VALIDATION FINALE

Le contrôle doit afficher TP04 : contrôles réussis. Il ne remplace pas une relecture humaine : ouvrez tous les fichiers, vérifiez la page de recommandation et préparez une défense orale de 3 minutes.

01 / 03 · avant et pendant TP01

Console, script, objets, vecteurs

Geste	Exemple / sens
Exécuter une ligne	Ctrl/Cmd + Entrée depuis l'éditeur ; lire la sortie dans la console.
Affecter un nom	x <- c(10, NA, 30) ; <- mémorise ; x affiche.
Comparer	x >= 20 ; == compare ; = nomme souvent un argument.
TRUE / FALSE / NA	Vrai / faux / inconnu ; noms sensibles à la casse.
Aide	?mean ; lire Usage et Arguments ; args(mean).
Inspecter	class(x), length(x), str(x), names(x), attributes(x).

```
x <- c(10, NA, 30)
valides <- x[!is.na(x)]
length(x)                 # 3 positions
length(valides)           # 2 observations
mean(x, na.rm = TRUE)     # 20
median(valides)           # 20
mean(valides >= 20)       # 1/2
mean(is.na(x))            # 1/3
```

- Un masque logique a la même longueur que le vecteur ; ! signifie « non ». Évitez x[x>20] avec des NA non traités.
- Une proportion obtenue par mean(condition) compte les TRUE divisés par les valeurs logiques considérées. Vérifiez d'abord son dénominateur.
- Les objets ne survivent pas obligatoirement à un redémarrage. Un script doit recréer ses entrées ; ne chargez pas un ancien .RData pour réparer une erreur.

ERREUR UTILE

« object not found » : relire le nom exact et exécuter sa création avant son usage. « unexpected symbol » : rechercher parenthèse, virgule ou guillemet manquant près de la ligne signalée.

02 / 03 · pendant TP02 et TP04

Tables, fonctions et fichiers

```
d <- data.frame(id = 1:3, minutes = c(10, NA, 30))
nrow(d)
names(d)
d$minutes
d[!is.na(d$minutes), , drop = FALSE]
# Avant la virgule : lignes ; après : colonnes.
resumer <- function(x) {
  c(n = length(x), moyenne = mean(x), sd = sd(x))
}
resumer(c(10,20,30))
```

Besoin	Fonction et précaution
Libellés	trimws() retire les espaces extérieurs ; contrôler les modalités avant factor(levels=...).
Doublons	duplicated(d$id) ; vérifier si les autres colonnes concordent.
Quartiles	quantile(x, c(.25,.75), type=7), valeurs valides et convention annoncée.
Lister / matrice	list(a=..., b=...) accepte plusieurs types ; matrix() est homogène ; apply(m,1,mean) résume les lignes.
Condition / répétition	if (condition) { ... } else { ... } ; for (i in seq_len(n)) { ... }.

```
dir.create("results", showWarnings = FALSE)
write.csv(d, "results/exemple.csv", row.names = FALSE)
d2 <- read.csv("results/exemple.csv",
  na.strings = c("", "NA"))
pdf("results/exemple.pdf")
plot(c(10,20,30), ylab = "Minutes")
dev.off()
```

FICHIER INTROUVABLE

getwd() doit montrer la racine contenant data/, labs/ et checks/. Ouvrez course.Rproj. « cannot open file » peut indiquer un dossier results/ absent ; créez-le avant l'export.

03 / 03 · pendant TP03 et TP04

Welch, graphiques et contrôles

```
a <- c(10,12,14,16)
b <- c(8,10,12,14)
test <- t.test(x=b, y=a, var.equal=FALSE)
class(test)
names(test)
delta <- mean(b)-mean(a)
ic <- unname(test$conf.int)
p <- test$p.value
```

Élément	À retenir
Contraste	x=B et y=A → B−A ; négatif favorise B si moins de minutes est mieux.
IC95	Incertitude sur la différence de moyennes ; pas une plage de durées individuelles.
p	Extrémité du résultat sous H0 et hypothèses ; pas probabilité que H0 soit vraie.
Boxplot / histogramme	Comparer les groupes / décrire une distribution ; indiquer l'unité sur les axes.
Erreurs attendues	try(..., silent=TRUE) garde un objet try-error ; réserver ce geste aux démonstrations prévues.

```
# Après VOTRE script :
source("checks/TP03.R", encoding = "UTF-8")
```

- Un message « À corriger » signale le premier objet ou fichier incohérent : corrigez sa création, relancez tout votre script puis le contrôle.
- « TP03 : contrôles réussis » prouve les calculs et les fichiers demandés, mais pas la qualité de votre interprétation ni la lisibilité d'un graphique.
- Avant de livrer : redémarrez R, exécutez le script de haut en bas, ouvrez les sorties. Gardez les limites visibles dans la recommandation.

CONTINUATION 2 · 03 / 03 · pendant TP03 et TP04

Welch, graphiques et contrôles · suite

AIDE GRADUÉE

1. Lire le message. 2. Afficher str() de l’objet. 3. Refaire le geste sur trois nombres. 4. Consulter un mini-exemple. 5. Demander à un pair d’expliquer, puis écrire soi-même.

COMMENT UTILISER CES CORRIGÉS

Vérifier sa démarche, pas seulement un chiffre

TP	Correction commentée	Contrôle étudiant
01	solutions/TP01_demarrer_solution.R	checks/TP01.R
02	solutions/TP02_preparer_solution.R	checks/TP02.R
03	solutions/TP03_comparer_solution.R	checks/TP03.R
04	solutions/TP04_projet_solution.R	checks/TP04.R

- Sauvegarder le premier essai et noter l'étape qui bloque.
- Comparer d'abord le petit calcul puis les objets et unités.
- Relancer son propre fichier depuis une session R vide.
- Les contrôles doivent échouer sur un starter non complété ; ils vérifient des objets et fichiers, pas la qualité de toutes les interprétations.

> **UNE AIDE EXPLICITE**
>
> Le CSV de reprise du TP03 permet de continuer à comparer des groupes. Il ne prouve pas que votre nettoyage du TP02 est réalisé.

Revoir les exemples miniatures

VECTEURS, ABSENCES ET CENTRE

TP01 : retrouver les mêmes nombres à la main

$$n_{total} = 8, \quad n_{obs} = 6, \quad n_{NA} = 2$$

Vecteur : 42, NA, 35, 80, 55, NA, 20, 60 ; durées en minutes.

$$\bar{x}_{obs} = \frac{42 + 35 + 80 + 55 + 20 + 60}{6} = \frac{292}{6} \simeq 48.667$$

On compte les six durées observées, pas les huit positions.

$$\text{mediane} = \frac{42 + 55}{2} = 48.5$$

Valeurs triées : 20, 35, 42, 55, 60, 80. Les positions centrales sont 3 et 4.

$$\hat{p}(X \geq 60) = \frac{2}{6} \simeq 33.33\%, \quad \hat{p}_{NA} = \frac{2}{8} = 25\%$$

Deux durées sur six atteignent 60 min ; deux positions sur huit sont manquantes.

CE QUE L'ON VEUT EXPLIQUER

Un masque logique contenant NA peut conserver des valeurs inconnues. La règle de validité et le dénominateur sont aussi importants que le résultat.

AUDIT ET DESCRIPTION

TP02 : chaque retrait a une justification

$$241 - 1 - 3 - 1 = 236$$

Une copie de ligne et quatre tickets sans délai admissible sont retirés.

Contrôle	Résultat
Espaces normalisés	3 workflow + 4 team
Doublon exact	ticket 17
Délais absents	21,87,154
Délai invalide	203
Répartition après règles	A 117 ; B 119
Satisfaction absente conservée	12

Groupe	Moyenne / min	Écart-type / min	Médiane / min
A	70,6547	17,9925	68,2
B	66,0899	17,7379	66,9

DISPERSION ET QUARTILES

Les quartiles de type 7 valent 59 et 82,2 pour A, 53,9 et 80,5 pour B. La fonction de résumé doit aussi fonctionner sur un autre vecteur, pas seulement restituer ces valeurs.

ANALYSE PRINCIPALE · WELCH B − A

TP03 : effet et incertitude ensemble

$$\widehat{\Delta} = 66.089916 - 70.654701 \simeq -4.564785 \text{ min}$$

Le signe négatif indique un délai moyen observé plus bas dans B.

$$IC_{95\%} \simeq [-9.147648,\ 0.018079] \text{ min}$$

Les deux bornes proviennent du même objet de test.

Quantité	Résultat
Effectifs	nA = 117, nB = 119
Statistique t	−1,96239
Degrés de liberté de Welch	233,77145
p bilatéral	0,0509032

INTERPRÉTATION

L'intervalle contient légèrement zéro. Cela ne démontre ni égalité ni absence d'effet. Il couvre des améliorations notables et une différence presque nulle. Le gain minimal de 5 min n'est pas établi.

L'intervalle fréquentiste décrit une procédure sous hypothèses ; il n'attribue pas 95 % de probabilité à un paramètre fixe. Indépendance, données manquantes et protocole restent à discuter.

UNE PAGE · PREUVES ET LIMITES

TP04 : une recommandation possible

Sur 236 tickets synthétiques analysables, B présente un délai moyen inférieur de 4,56 min à A, avec IC 95 % [−9,15 ; 0,02]. L'incertitude ne permet pas d'affirmer un gain minimal de 5 min fixé comme critère pédagogique.

Poursuivre un pilote indépendant et préciser les coûts/qualité est une décision cohérente. Les quatre exclusions de délai et l'indépendance des tickets doivent être discutées. Les résultats de cette simulation ne justifient pas un déploiement réel.

Preuve	Fichier du corrigé
Journal et exclusions	results/TP04_audit.csv ; TP04_exclusions.csv
Description et comparaison	TP04_descriptifs.csv ; TP04_comparaison.csv
Figures	TP04_graphiques.pdf
Note de décision	TP04_recommandation.pdf
Versions	results/TP04_sessionInfo.txt

PORTFOLIO NOTÉ

Conserver aussi les scripts et preuves des TP01–03 : le projet final synthétise, il ne remplace pas toutes les productions antérieures. Les extensions sont facultatives.