Votre mission

Une enquête complète, du CSV à la décision

Noria Services teste deux workflows A et B. Le scénario décrit une affectation randomisée et 240 tickets indépendants. Votre mission : évaluer la différence de délai de résolution, vérifier les données et défendre une conclusion proportionnée aux preuves.

- Données simulées : ticket_id, workflow (A/B), resolution_minutes, complexity (numérique, 1–5), satisfaction (ordinale, 1–5) et team.
- Un CSV volontairement imparfait impose un audit avant toute analyse.
- Résultat principal : moyenne B moins moyenne A, en minutes, avec intervalle de confiance.
- La satisfaction est ordinale : décrire les effectifs et la médiane, sans la traiter automatiquement comme une mesure continue.
- Chaque personne produit son propre script et une courte note de décision.

PRÉREQUIS

Savoir utiliser des fichiers et retrouver des statistiques déjà étudiées suffit. Aucune maîtrise de R n'est supposée. Les rappels statistiques sont intégrés.

PÉRIMÈTRE HADOOP

Vous étudierez Hadoop, HDFS, MapReduce et la place de RHadoop. La pratique utilise une simulation MapReduce en R local. Aucun cluster ni environnement RHadoop distribué n'est exécuté ; cette substitution pratique reste à valider par le coordinateur.

Organisation

Quatre séances et dix modules de projet

Séance	Travail principal	Modules mobilisés
Samedi matin • 270 min	Bases R, import et audit	0, 1 et 3
Samedi après-midi • 270 min	Nettoyage, matrices et exploration	2, 4 et 5
Dimanche matin • 270 min	Inférence, modèle et MapReduce	6, 7 et 8
Dimanche après-midi • 270 min	Projet autonome et défense	9 et reprise complète

Les numéros 0–9 identifient les modules du code ; les TP suivent un ordre pédagogique adapté. Les bases sont travaillées avant de relancer le pipeline complet dans son ordre.

Les 18 heures sont des heures pédagogiques : 4 × 270 minutes. Ajouter une pause de 15 minutes par séance et une pause déjeuner. Exemple : 08:00–12:45 et 13:45–18:30, les deux jours.

RYTHME

535 minutes sont réservées aux six TP, plus 20 minutes de diagnostic. Au moins 65 % de chaque TP sont consacrés au travail individuel autonome. Les extensions ne conditionnent jamais la réussite du noyau.

CARTE DU PROJET · REPÈRES, PAS PRÉREQUIS

Les dix modules de code

Module du code	Preuve produite
0 • Préparer	Configuration et utilitaires
1 • Importer	Données brutes et structure
2 • Nettoyer	Données propres et audit
3 • Programmer	Types, vecteurs, if et boucles
4 • Transformer	Matrices, apply et fonctions
5 • Explorer	Résumés et graphiques
6 • Comparer	Welch orienté B − A
7 • MapReduce	Simulation locale et vérification
8 • Modéliser	lm et diagnostics
9 • Reproduire	Orchestration, exports et décision

DEUX NUMÉROTATIONS

Les TP donnent l'ordre pédagogique. Les modules R donnent une organisation de code ; ils ne sont pas dix cours supplémentaires.

Modules 0, 1 et 3

Séance 1 — comprendre ce que R manipule

Commencer dans un dossier de projet. Lire les fichiers bruts sans les modifier. Garder toutes les décisions dans un script, puis relancer les instructions dans leur ordre.

Activité	Durée	Votre production
Diagnostic individuel	20 min	Six réponses, sans note
TP01_vectors.pdf	70 min	Script : types, indexation, résumés, if, boucle et fonction
TP02_cleaning.pdf • première partie	40 min	Import, dimensions, valeurs manquantes et doublons

- Noyau : construire un vecteur, sélectionner des éléments, calculer un résumé et expliquer l'effet de NA.
- Noyau : écrire une condition scalaire et une boucle qui collecte un résultat.
- Noyau : définir une fonction, préciser ses entrées et son résultat.
- Noyau : examiner class(), str(), names(), dim() et attributes() lorsque ces propriétés existent.
- Extension : rendre la fonction explicite sur les valeurs manquantes et vérifier une entrée invalide.

```
x <- c(12, 18, NA, 24)
mean(x)
mean(x, na.rm = TRUE)
resume <- function(x) {
  c(n = sum(!is.na(x)), moyenne = mean(x, na.rm = TRUE))
}
resume(x)
attributes(x)
```

POINT DE PASSAGE

Vous savez expliquer le type de chaque colonne, retrouver le fichier importé et distinguer une valeur absente d'une valeur égale à zéro. Le script doit fonctionner après redémarrage de R.

Modules 2, 4 et 5

Séance 2 — rendre les observations exploitables

Activité	Durée	Votre production
TP02_cleaning.pdf • suite	50 min	Nettoyage documenté et vérifications
TP03_matrices.pdf	75 min	Matrices, apply et exploration statistique

- Auditer avant de corriger : distinguer doublon, délai impossible, absence et espaces parasites.
- Retirer le doublon du ticket 17 selon une règle documentée ; conserver la trace du retrait.
- Pour l'analyse des délais, exclure les tickets 21, 87 et 154 sans délai et le ticket 203 au délai négatif.
- Après dédoublonnage : 240 tickets. Pour l'analyse des délais : 236 tickets. Ne pas supprimer un ticket uniquement parce que sa satisfaction manque.
- Créer une matrice numérique, inspecter dim(), transformer sa forme en conservant le nombre d'éléments et appliquer une fonction par ligne ou colonne.
- Décrire effectifs, valeurs manquantes, distributions et différences visuelles entre A et B.

```
m <- matrix(1:12, nrow = 3)
dim(m)
dim(m) <- c(4, 3)
apply(m, 2, mean)
```

POINT DE PASSAGE

Votre journal explique chaque exclusion. Les graphiques ont des axes et unités lisibles. Une différence visuelle n'est pas encore une preuve statistique.

EXTENSION

Comparer moyenne et médiane, construire une analyse par complexité et expliquer pourquoi une matrice mélangeant texte et nombres peut changer de type.

Modules 6, 7 et 8

Séance 3 — estimer, modéliser, examiner

Activité	Durée	Votre production
TP04_inference.pdf	100 min	Welch, objet htest, modèle lm et diagnostics
TP05_mapreduce.pdf	80 min	Simulation MapReduce et schéma Hadoop

- Fixer la comparaison B − A avant de calculer : une valeur négative indique un délai moyen inférieur avec B.
- Rapporter effectifs, moyennes, différence, intervalle de confiance et p-valeur ; commenter aussi l'ampleur métier.
- Vérifier l'ordre réel du contraste. Ne pas recopier le signe affiché par un test par formule sans examiner les groupes.
- Ajuster un modèle avec workflow, complexité et équipe, puis examiner résidus, variance et observations influentes.
- Explorer attributes(), class(), names() et les composantes utiles de htest et lm.
- Distinguer propriété d'objet, coefficient, prédiction et conclusion ; encapsuler un calcul répété dans une fonction.

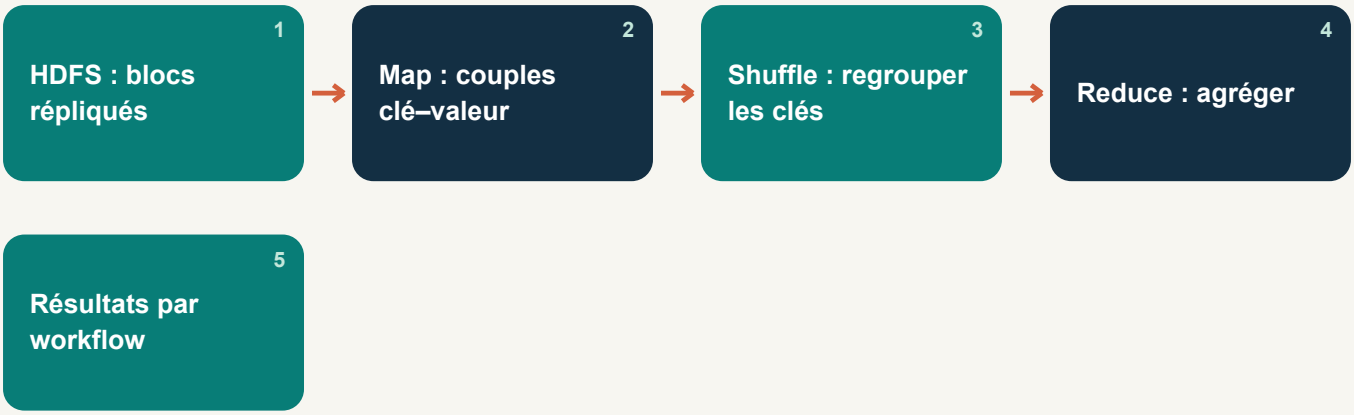
```
a <- d$resolution_minutes[d$workflow == 'A']
b <- d$resolution_minutes[d$workflow == 'B']
welch <- t.test(b, a)
welch$estimate
welch$conf.int
attributes(welch)
d$workflow <- factor(d$workflow, levels = c('A', 'B'))
modele <- lm(resolution_minutes ~ workflow + complexity + team, data = d)
summary(modele)
plot(modele)
```

PRUDENCE ATTENDUE

L'affectation est randomisée dans le scénario, mais l'indépendance et les données manquantes restent à discuter. Le coefficient ajusté et la différence brute répondent à des questions différentes. Aucune p-valeur ne remplace ces vérifications.

Module 7

Hadoop et RHadoop : comprendre la chaîne



Hadoop traite des données réparties sur plusieurs machines. HDFS organise leur stockage. MapReduce distribue les transformations et les agrégations. RHadoop désigne historiquement un ensemble d'outils reliant R à cet écosystème, notamment rhdfs et rmr2.

- Noyau : découper localement les tickets en partitions, puis émettre pour chaque workflow une somme des délais et un effectif.
- Regrouper les résultats intermédiaires par clé ; additionner sommes et effectifs ; calculer moyenne = somme totale / effectif total.
- Comparer le résultat à une agrégation directe en R, avec une tolérance numérique explicite.
- Montrer qu'une moyenne de moyennes non pondérée peut être fausse lorsque les partitions ont des tailles différentes.
- Identifier ce qui manquerait sur un vrai cluster : stockage HDFS, ordonnanceur, tâches distribuées, transferts réseau, reprise après échec et dépendances compatibles.

LIMITE DU TP

split(), lapply() et Reduce() tournent ici dans R sur une seule machine. Cette activité illustre MapReduce ; elle ne constitue pas une exécution Hadoop ou RHadoop et ne mesure pas le passage à l'échelle.

EXTENSION

Changer la taille des partitions, introduire une partition vide et proposer des vérifications qui gardent la même moyenne finale.

Séance 4 • Module 9 et pipeline complet

Votre dossier final et les critères de réussite

TP06_capstone.pdf réserve 120 minutes à un projet individuel. Utiliser les corrections comme référence, puis reconstruire sa propre chaîne de décisions. Le dossier doit se relancer et se comprendre sans explication orale supplémentaire.

- Livrer : script principal, données nécessaires, journal de nettoyage, figures et tableaux, note de décision courte et sessionInfo().
- La note présente B − A avec son unité, son intervalle de confiance, les limites et une recommandation conditionnelle.
- Défense en triades : chacun présente trois minutes, répond à une question et conserve une réponse écrite individuelle commune à tous.
- Les passages publics tournants servent à apprendre ; ils ne donnent aucun bonus de note.

Critère	Points
Reproductibilité et organisation	10
Audit et nettoyage justifiés	20
Bases R, fonctions, matrices et apply	15
Exploration et graphiques	10
Welch, contraste et interprétation	15
lm, propriétés et diagnostics	10
MapReduce et limites Hadoop/RHadoop	10
Décision et défense individuelle écrite	10
Total	100

NOYAU ET EXTENSION

Le noyau suffit pour viser tous les points. L'extension approfondit la robustesse ; elle ne compense pas une erreur centrale. Le formateur évalue les décisions et leur compréhension, même si la syntaxe provient d'un exemple corrigé.