LEADERS UNIVERSITY

MASTER · STATISTIQUE APPLIQUÉE

Statistiques avec R

À votre rythme

Comprendre. Calculer. Décider.

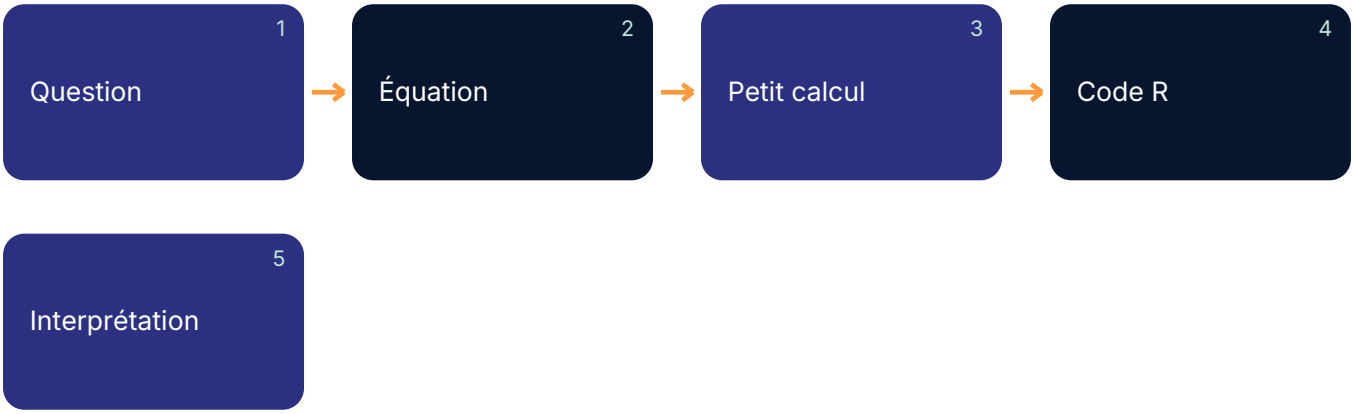
À votre rythme, avec un coach au point de besoin.

18 h accompagnées | 4 TP individuels | Maths → R → décision



NOTRE MÉTHODE · REGARDER, CALCULER, CODER, EXPLIQUER

La question vient avant la commande



Noria Services compare deux procédures A et B pour résoudre des tickets. Votre question : quel écart moyen de délai observe-t-on, et quelle incertitude reste-t-il ? Les données sont simulées ; votre raisonnement doit rester vérifiable.

- À chaque étape : nommer ce que l'on mesure et son unité.
- Calculer un exemple court à la main avant de lancer R.
- Prédire la sortie, puis expliquer l'écart éventuel.
- Écrire son propre script, sauvegarder et relancer depuis une session vide.

> CE QUE L'ON SAURA LIVRER
>
> Une table analysable, un audit, une figure lisible, une comparaison B − A avec intervalle et une recommandation d'une page. Le cœur ne demande ni cluster Hadoop ni modèle ajusté.

INTRODUCTION · CALCUL STATISTIQUE ET GRAPHIQUES

R : d'où vient cet outil ?

R est un langage et un environnement de calcul statistique et de graphiques, distribué comme logiciel libre. On y écrit des règles de calcul, on les applique à des données et on conserve une recette rejouable.

Repère	Ce qu'il signifie
Origine	Ross Ihaka et Robert Gentleman, département de statistique de l'Université d'Auckland
Inspiration	Le langage S, développé aux Bell Labs par John Chambers et ses collègues
1996	Les créateurs présentent R dans "A Language for Data Analysis and Graphics"
Depuis 1997	Une équipe R Core internationale contribue au développement
Aujourd'hui	Un projet collaboratif et extensible par des paquets

POURQUOI L'UTILISER ICI ?

R contient directement les opérations statistiques du cours : mean(), sd(), quantile(), t.test() et les graphiques. On peut comparer chaque commande à une équation et vérifier le résultat sur de petites valeurs.

Sources primaires : https://www.r-project.org/about.html ; https://www.r-project.org/contributors.html ; https://doi.org/10.1080/10618600.1996.10474713

INTRODUCTION · SA PLACE ET NOTRE CHOIX

Pourquoi apprendre R aujourd'hui ?

Besoin	Ce que R apporte
Décrire une situation	Résumés, distributions et graphiques
Quantifier l'incertitude	Estimations, intervalles, tests et modèles
Reproduire une analyse	Le script conserve les étapes et règles
Échanger avec un collègue	Données, code, versions et sorties traçables

R reste utilisé en recherche statistique et dans des métiers d'analyse spécialisés. Un exemple concret : le groupe R Submissions du R Consortium publie des pilotes de travaux cliniques et annonce en 2026 de nouveaux programmes d'analyse et des jeux synthétiques de référence. Ce cas illustre une activité professionnelle actuelle ; il ne mesure pas une part de marché.

> R, RSTUDIO ET PAQUET
>
> R effectue les calculs. RStudio est un éditeur pour écrire, exécuter et examiner le travail. Un paquet ajoute des fonctions ; les exercices obligatoires utilisent seulement ce qui est fourni avec R.

Source vérifiée le 23 octobre 2026 : https://r-consortium.org/posts/submissions-wg-2026/

REPÈRES PROFESSIONNELS · EXEMPLES DOCUMENTÉS

R : des outils et des métiers

R est un outil de travail actuel dans des équipes spécialisées. Voici des exemples précis, sans prétendre décrire tous les métiers ni mesurer une part de marché.

Posit / RStudio

RStudio est un éditeur pour R. Son édition Open Source est gratuite ; elle reste facultative pour ce parcours.

Pfizer · statistiques

Le R Consortium décrit un R Centre of Excellence chez Pfizer : reproductibilité, automatisation et analyse statistique.

Swiss Re · actuariat

Le R Consortium décrit l'adoption de R et d'outils ouverts ainsi qu'une plateforme interne fondée sur Posit.

CE QUE L'ON PRÉPARE ICI

Un collègue doit pouvoir relire vos règles, relancer le script, retrouver les versions et comprendre estimation et incertitude. Le projet Noria construit ces habitudes sur un cas synthétique.

Logos d'identification des outils et exemples, sans affiliation à la formation. Sources vérifiées le 23 octobre 2026 : https://posit.co/products/open-source/rstudio/ ; https://r-consortium.org/about/governance

VOCABULAIRE · LE MÊME LANGAGE POUR TOUS

Donnée, variable, observation : donner du sens

Mot	Définition concrète	Dans Noria
Donnée	Une valeur avec un sens et éventuellement une unité	70,2 minutes pour un ticket
Observation / individu	L'unité sur laquelle on recueille les variables	Un ticket ; pas une ligne dupliquée
Variable	Caractéristique mesurée ou décrite pour chaque unité	Délai, procédure, satisfaction
Population cible	Ensemble que la question veut décrire	Tickets du processus et contexte concernés
Échantillon	Unités effectivement observées pour analyser	Les 236 tickets retenus
Paramètre / estimation	Quantité de population / valeur calculée sur l'échantillon	Écart moyen cible / écart observé B−A

LA QUESTION GUIDE LE TABLEAU

Avant de coder : une ligne représente quoi ? Une colonne mesure quoi ? En quelle unité ? Comment les unités ont-elles été choisies ? La réponse conditionne les calculs possibles.

VOCABULAIRE · STATISTIQUE ET INFORMATIQUE

Une variable a un sens et un stockage

Sens statistique	Exemple	Stockage R possible
Quantitative continue	Durée en minutes	numeric
Quantitative discrète	Nombre de tickets	integer ou numeric
Qualitative nominale	Procédure A/B	character ou factor
Qualitative ordinale	Satisfaction 1–5	numeric codé ou ordered factor
Identifiant	ticket_id	integer / character ; calcul de moyenne sans sens ici

```
mesure <- 12.5
entier <- 3L
etiquette <- "A"
condition <- TRUE
class(mesure)
is.na(NA)
```

MANQUANT N'EST PAS ZÉRO

NA indique une information absente. Une note de satisfaction manquante ne devient ni 0 ni une preuve d'insatisfaction. Sa règle d'analyse doit être annoncée.

STRUCTURES · LA PREMIÈRE BRIQUE

Vecteur : une suite de valeurs du même type

Un vecteur numérique : 3 valeurs, un même type

x[1]	x[2]	x[3]
10	20	30

```
x <- c(10, 20, 30)
length(x)        # 3
x[1]             # 10 : index à partir de 1
x[x > 15]        # 20 30
x[2] <- 25       # remplacer la deuxième valeur
class(c(10, "20")) # character : conversion commune
```

LIRE LA SYNTAXE

c() rassemble des valeurs. [ ] sélectionne des positions. <- associe un nom à une valeur ou remplace une partie. Une opération comme x > 15 produit un vecteur TRUE/FALSE.

STRUCTURES · LIGNES ET COLONNES

Data frame : une table de variables

data.frame : une colonne par variable, une ligne par observation

	ticket_id : integer	workflow : character	resolution_minutes : numeric
ticket 1	1	A	10
ticket 2	2	B	20
ticket 3	3	A	30

```
d <- data.frame(ticket_id = 1:3,
  workflow = c("A", "B", "A"),
  resolution_minutes = c(10, 20, 30))
d$workflow                 # une colonne
d[2, ]                     # une ligne
d[d$workflow == "A", ]     # un filtre de lignes
str(d)
```

LA VIRGULE COMPTE

d[lignes, colonnes] sélectionne une table. Le vide après la virgule conserve toutes les colonnes. Chaque colonne est un vecteur ; leurs types peuvent différer.

QUESTION · Quelle durée entre dans le calcul ?

1 · Une ligne est-elle une observation valide ?

$$I = \{i : x_i \text{ est fini}, \; x_i > 0\}, \quad n = |I|$$

On définit les valeurs admises, puis on les compte.

x_i est la durée de la ligne i, en minutes ; I est l'ensemble des indices retenus ; |I| est son nombre d'éléments. Une valeur finie exclut NA, NaN et les infinis. Cette règle porte ici sur la durée, après contrôle des identifiants.

1 $x = (10, \text{NA}, -5, 30)$

Quatre lignes brutes ; durées en minutes.

2 $I = \{1, 4\}, \quad n = 2$

Les valeurs 10 et 30 satisfont la règle annoncée.

```
x <- c(10, NA, -5, 30)
valide <- is.finite(x) & x > 0
x_ok <- x[valide]       # 10 30
n <- sum(valide)        # 2
```

À INTERPRÉTER

n désigne les observations effectivement utilisées. length(x) vaut 4 et inclut la valeur manquante ; ce n'est pas l'effectif analysé. Une ligne dupliquée n'est pas une nouvelle observation indépendante.

QUESTION · Quel est le bon dénominateur ?

2 · Quelle proportion de tickets appartient à B ?

$$\hat{p}_B = \frac{n_B}{n}, \quad \text{pourcentage} = 100\hat{p}_B$$

Une part compare un nombre de tickets à une population clairement définie.

n_B est le nombre de tickets du groupe B ; n est le nombre total de tickets analysés dont le groupe est connu. p avec un chapeau est la proportion observée, sans unité ; son pourcentage s'exprime en %. Ici tous les groupes sont renseignés.

Ticket	workflow	Est-ce B ?
1	A	FALSE = 0
2	B	TRUE = 1
3	B	TRUE = 1
4	A	FALSE = 0

1 $$n_B = 0 + 1 + 1 + 0 = 2$$ On compte les B à l'aide d'un vecteur logique.

2 $$\hat{p}_B = 2/4 = 0{,}5$$ Deux B parmi quatre tickets : 50 %.

```
workflow <- c("A", "B", "B", "A")
connu <- !is.na(workflow)
est_B <- workflow[connu] == "B"
n_B <- sum(est_B)       # 2
p_B <- mean(est_B)      # 0.5
100 * p_B              # 50
```

PIÈGE

Toujours nommer le dénominateur : tous les tickets bruts, les tickets propres ou seulement les réponses connues ne donnent pas la même question. Ne pas coder une réponse manquante comme FALSE.

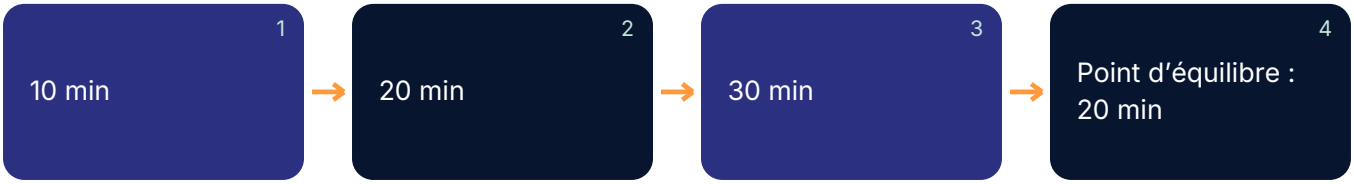
QUESTION · Quelle durée moyenne pour les tickets observés ?

3 · La moyenne : un point d'équilibre

$$\bar{x} = \frac{1}{n} \sum_{i=1}^{n} x_i$$

Additionner les durées retenues, puis partager en n parts égales.

x_i est la i^e durée retenue, en minutes ; n est le nombre de durées retenues ; Σ se lit « somme de toutes les valeurs, de i = 1 à n » ; x avec une barre est la moyenne observée, en minutes. Les valeurs ont été validées avant ce calcul.



1 $$\sum_{i=1}^{3} x_i = 10 + 20 + 30 = 60$$

La somme des trois durées vaut 60 minutes.

2 $$\bar{x} = 60/3 = 20$$

La moyenne vaut 20 minutes.

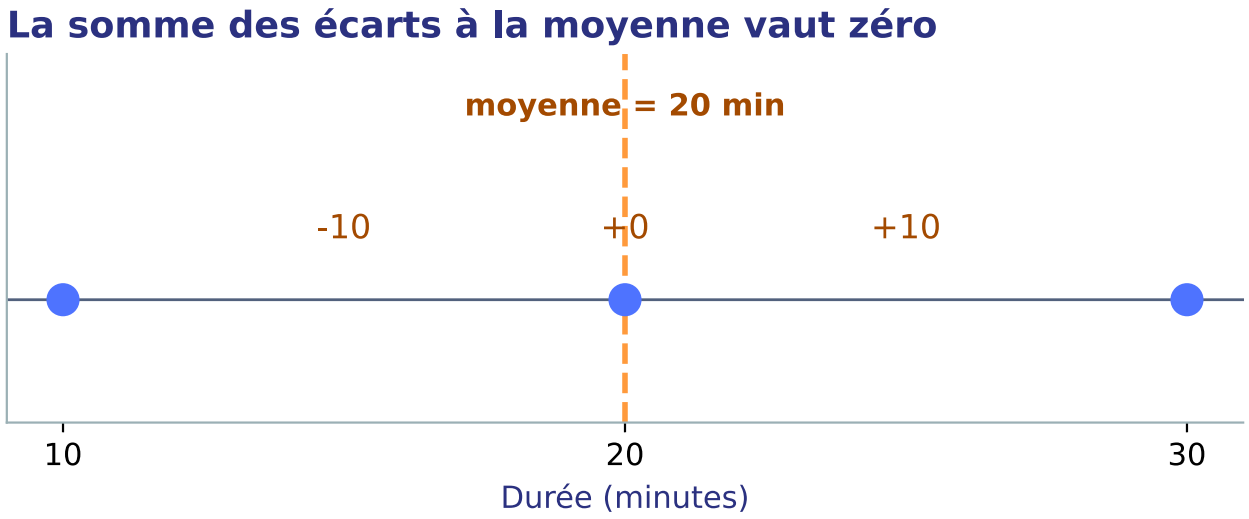
```
x <- c(10, 20, 30)
n <- length(x)
sum(x) / n      # 20
mean(x)         # 20
```

PIÈGE

La moyenne garde l'unité des données. Une grande durée la déplace : remplacer 30 par 300 donne 110 minutes. mean(..., na.rm = TRUE) ignore NA, mais ne détecte ni les valeurs négatives ni les doublons.

VOIR LE CALCUL

La moyenne comme équilibre



À LA MAIN

Pour 10, 20, 30 min, les écarts à 20 min sont −10, 0, +10 min. Leur somme vaut 0 ; une valeur très élevée déplacerait ce point d'équilibre.

QUESTION · Quelle durée sépare les données en deux moitiés ?

4 · La médiane : le milieu des valeurs triées

$$n = 2k + 1 : \quad m = x_{(k+1)}$$

Nombre impair : prendre la valeur centrale après tri.

$$n = 2k : \quad m = \frac{x_{(k)} + x_{(k+1)}}{2}$$

Nombre pair : faire la moyenne des deux valeurs centrales.

x_(j) désigne la valeur de rang j dans la liste triée ; n est l'effectif ; k est l'entier qui permet d'écrire n = 2k ou n = 2k + 1 ; m est la médiane, en minutes. La médiane peut ne pas être une valeur observée.

Valeurs triées	Positions centrales	Médiane
10, 20, 30	Position 2	20 min
10, 20, 30, 100	Positions 2 et 3	25 min

1 $n = 3 = 2 \times 1 + 1, \quad m = x_{(2)} = 20$ Trois valeurs : le milieu est une valeur observée.

2 $n = 4 = 2 \times 2, \quad m = (20 + 30)/2 = 25$

Quatre valeurs : le milieu est entre deux valeurs observées.

```
x <- c(30, 10, 20)
sort(x)                 # 10 20 30
median(x)               # 20
median(c(x, 100))       # 25
```

PASSER AU JEU DU PROJET · AVANT LE TP02

Recevoir Noria sans modifier le fichier

Le CSV reçu contient des anomalies de transmission. Gardez-le intact. On va compter les lignes, vérifier les unités et annoncer les règles avant d'interpréter un résultat.

```
noria_dirty <- read.csv("data/noria_dirty.csv",
  stringsAsFactors = FALSE, na.strings = c("", "NA"))
dim(noria_dirty)
names(noria_dirty)
str(noria_dirty)
colSums(is.na(noria_dirty))
```

QUESTION AVANT LE NETTOYAGE

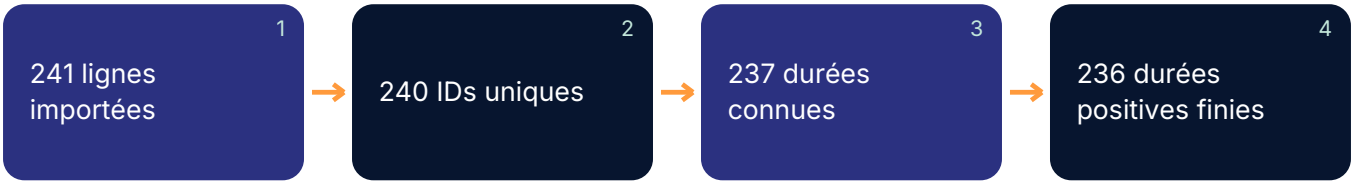
241 lignes ne signifient pas 241 tickets indépendants. Le dictionnaire du projet explique chaque variable ; le TP02 vous demande de conserver les preuves des corrections.

Exemple miniature : nettoyer et exporter >

TP02 : préparer et décrire >

QUESTION · Pourquoi Noria passe-t-il de 241 lignes à 236 tickets ?

5 · Compter les lignes, puis les tickets



$$n_{\text{analyse}} = 241 - 1 - 3 - 1 = 236$$

Un doublon de ligne, puis quatre tickets sans durée admissible.

L'origine synthétique comporte 240 tickets. Le fichier sale contient 241 lignes : le ticket 17 a été ajouté une seconde fois, à l'identique. Les IDs 21, 87 et 154 n'ont pas de durée ; l'ID 203 a une durée négative. Les espaces sont normalisés avant de comparer les groupes et les équipes.

1 $$241 - 1 = 240$$

Retirer la copie exacte de l'ID 17 : on retrouve 240 tickets uniques.

2 $$240 - 3 - 1 = 236$$

Exclure trois durées manquantes et une durée négative pour cette analyse.

```
d <- noria_dirty
d$workflow <- trimws(d$workflow)
d$team <- trimws(d$team)
stopifnot(sum(duplicated(d)) == 1)
d <- unique(d)
stopifnot(!anyDuplicated(d$ticket_id))
valide <- is.finite(d$resolution_minutes) &
          d$resolution_minutes > 0
clean <- d[valide, ]
nrow(clean)                  # 236
```

PIÈGE

On retire cinq lignes mais seulement quatre tickets distincts sont exclus. Les 12 NA de satisfaction restent : cette variable n'est pas nécessaire à la comparaison des durées. Sept cellules avec espaces sont corrigées (3 workflow, 4 team). Garder le fichier brut et le journal des règles.

QUESTION · Les durées sont-elles proches de leur moyenne ?

6 · Variance et écart-type : la dispersion des tickets

$$s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2, \qquad s = \sqrt{s^2}$$

R utilise n − 1 pour la variance et l'écart-type d'échantillon.

x_i : durée du ticket i ; $\bar{x}$: moyenne ; n : nombre de tickets, au moins 2 ; Σ additionne les carrés des écarts de tous les tickets. s^2 est la variance, en minutes carrées (min²). s est l'écart-type, en minutes. La division par n − 1 corrige l'estimation de variance liée à une moyenne estimée sur ces mêmes données.

x_i (min)	x_i − 20 (min)	Carré (min²)
10	−10	100
20	0	0
30	10	100

1 $$\bar{x} = 20, \qquad \sum_{i=1}^{3}(x_i - \bar{x})^2 = 200$$

Les écarts signés s'annulent ; leurs carrés mesurent l'éloignement.

2 $$s^2 = 200/(3-1) = 100$$

La variance d'échantillon vaut 100 min².

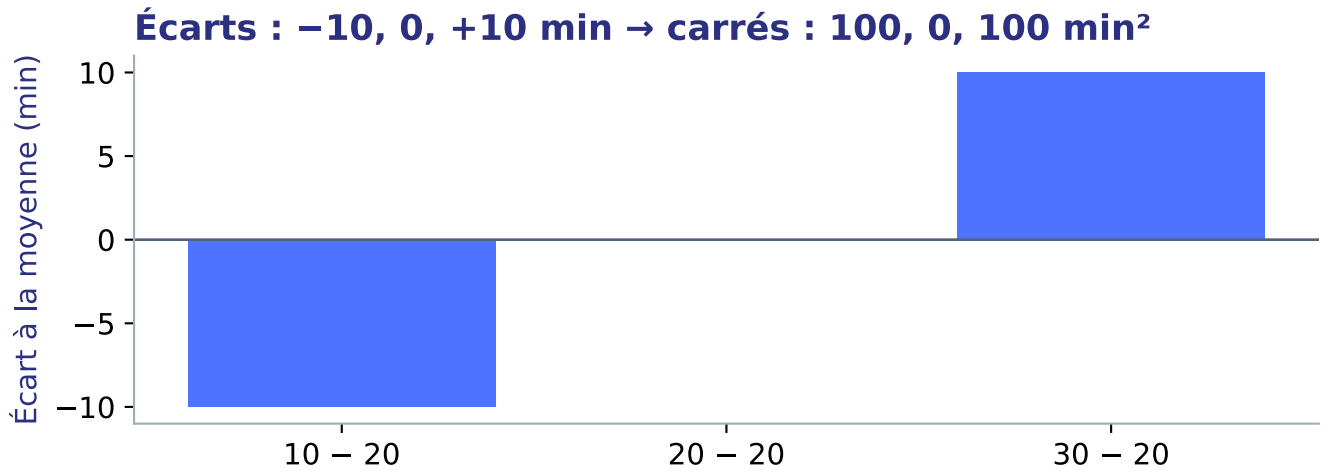
3 $$s = \sqrt{100} = 10$$

L'écart-type vaut 10 minutes.

```
x <- c(10, 20, 30)
sum((x - mean(x))^2) / (length(x) - 1) # 100
var(x)                                 # 100
sqrt(var(x))                           # 10
sd(x)                                  # 10
```

VOIR LES ÉCARTS

La dispersion se voit aussi



UNITÉ ET INTERPRÉTATION

Le carré d'un écart en minutes est en minutes². La racine carrée ramène l'écart-type en minutes. L'écart-type décrit la variabilité des tickets.

QUESTION · Où se situent les 25 %, 50 % et 75 % ?

7 · Quartiles et IQR : lire la moitié centrale

$$h = 1 + (n-1)p, \quad j = \lfloor h \rfloor, \quad g = h - j$$

Convention R type 7 : déterminer un rang et sa partie décimale.

$$Q(p) = (1-g)x_{(j)} + g x_{(j+1)}, \quad IQR = Q_3 - Q_1$$

Entre deux rangs, interpoler ; puis mesurer la largeur centrale.

Les n valeurs sont triées ; p est une proportion entre 0 et 1 ; h est un rang théorique ; j est le plus grand entier inférieur ou égal à h ; g est la part de chemin vers la valeur suivante. x_(j) est la valeur de rang j. Si g = 0, prendre directement x_(j). Aux extrémités, Q(0) est le minimum et Q(1) le maximum ; pour une seule valeur, tous les quantiles valent cette valeur. Q1 = Q(0,25) et Q3 = Q(0,75). Quartiles et IQR sont en minutes.

1 $x = (10, 20, 30), \quad p = 0.25 : \; h = 1 + 2(0.25) = 1.5$

Le premier quartile est à mi-chemin des rangs 1 et 2.

2 $Q_1 = 0.5(10) + 0.5(20) = 15$

Interpolation : Q1 = 15 minutes.

3 $Q_3 = 0.5(20) + 0.5(30) = 25, \quad IQR = 25 - 15 = 10$

Le troisième quartile vaut 25 ; l'écart interquartile vaut 10 minutes.

```
x <- c(10, 20, 30)
quantile(x, c(.25, .50, .75), type = 7) # 15 20 25
IQR(x, type = 7)                        # 10
```

CONVENTION À ANNONCER

Il n'existe pas une convention universelle de quartiles. R propose plusieurs méthodes ; type 7 est le défaut de quantile. Les charnières d'un boxplot peuvent différer. Un quartile interpolé n'est pas forcément observé ; l'IQR résiste mieux aux extrêmes que l'étendue.

GRAPHIQUES · AVANT LE TP02

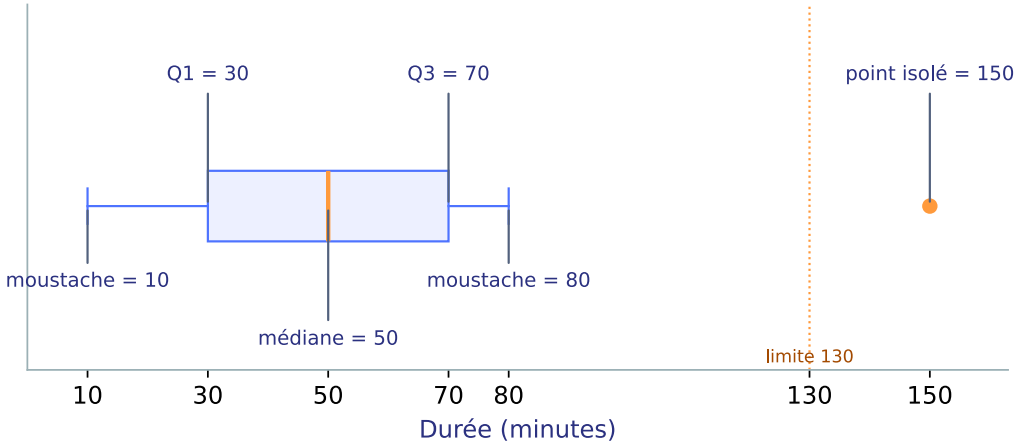
Lire une boîte sans inventer ses moustaches

Durées triées : 10, 20, 30, 40, 50, 60, 70, 80, 150 min. Pour ces neuf valeurs : Q1 = 30, médiane = 50, Q3 = 70 ; IQR = 40 min.

$$[Q_1 - 1.5\,IQR,\ \ Q_3 + 1.5\,IQR] = [-30,\ 130]$$

Les moustaches vont jusqu'aux valeurs observées dans ces limites : 10 et 80. Le point 150 est affiché séparément.

Boîte Q1–Q3 ; moustaches jusqu'aux valeurs admissibles




```
x <- c(10, 20, 30, 40, 50, 60, 70, 80, 150)
boxplot(x, horizontal = TRUE, xlab = "Durée (min)",
        main = "Neuf tickets : boîte et point isolé")
```

UN POINT À EXAMINER

Un point isolé n'est pas automatiquement une erreur à supprimer. La boîte de R utilise les charnières de Tukey, qui peuvent différer des quantiles de type 7 pour certains effectifs. Dans cet exemple à neuf valeurs, elles coïncident.

STRUCTURES · UN MÊME TYPE DANS TOUTES LES CASES

Matrice et array : des dimensions explicites

Matrice : 2 lignes × 3 colonnes

	col. 1	col. 2	col. 3
ligne 1	1	3	5
ligne 2	2	4	6

m[2, 1] = 2

m[ligne, colonne]

R remplit par colonnes par défaut.

```
m <- matrix(1:6, nrow = 2)
dim(m)               # 2 3
m[2, 1]              # 2
m_lignes <- matrix(1:6, nrow = 2, byrow = TRUE)
```

MATRICE

Une matrice est un tableau à deux dimensions, de type homogène. R remplit les colonnes par défaut ; byrow = TRUE demande un remplissage ligne par ligne. Une table de données à colonnes différentes reste un data.frame.

STRUCTURES · UNE DIMENSION SUPPLÉMENTAIRE

Array : plusieurs feuilles du même tableau

array : deux matrices empilées — dimensions 2 × 2 × 2

jour 1 : a[, , 1]

1	3
2	4

jour 2 : a[, , 2]

5	7
6	8

```
a <- array(1:8, dim = c(2, 2, 2))
dim(a)
a[, , 1]     # première feuille
a[2, 1, 2]   # 6
```

UNE IMAGE MENTALE

Un array peut représenter lignes × colonnes × jours. Une matrice est le cas à deux dimensions. Le cœur demande de reconnaître la structure ; écrire un traitement de grands tableaux multidimensionnels reste une extension.

STRUCTURES · CHOISIR L'OBJET SELON LA QUESTION

Liste, facteur et table : trois usages différents

Une list conserve des objets de formes et types différents

donnees	titre	valide
vecteur : 10, 20, 30	texte : "Noria"	logique : TRUE

```
objet <- list(donnees = c(10, 20, 30),
              titre = "Noria", valide = TRUE)
objet$donnees
objet[[1]]
groupe <- factor(c("A", "B", "A"), levels = c("A", "B"))
table(groupe)    # effectifs par catégorie
```

LES MOTS ÉVITENT LA CONFUSION

Une list conserve des objets hétérogènes. Un factor représente des catégories déclarées. table() calcule des effectifs. En français, “tableau” peut désigner une table de données ou un array : nommer précisément l'objet R.

PONT DE PROGRAMMATION · PETIT ET VÉRIFIABLE

Fonction, condition et boucle : une règle réutilisable

$$\bar{x}_{obs} = \frac{\sum_{i \in I} x_i}{|I|}$$

I contient les valeurs non manquantes ; vérifier les valeurs admissibles avant de résumer.

```
resumer <- function(x) {
  presents <- x[!is.na(x)]
  if (length(presents) == 0) return(c(n = 0, moyenne = NA))
  c(n = length(presents), moyenne = mean(presents))
}
resumer(c(10, NA, 30)) # n = 2 ; moyenne = 20
```

Une boucle répète une règle ; l'exemple guidé montre comment stocker chaque résultat. Les TP vous font tester une petite fonction, plutôt que développer un programme général.

Voir la boucle et ses résultats intermédiaires >

QUESTION · Que calcule apply selon son deuxième argument ?

8 · Matrice : lignes, colonnes, calcul par axe

	Colonne A : durée 1	Colonne B : durée 2
Ligne 1	10	20
Ligne 2	30	40

$$\bar{x}_{i\cdot} = \frac{1}{c}\sum_{j=1}^{c} x_{ij}, \qquad \bar{x}_{\cdot j} = \frac{1}{r}\sum_{i=1}^{r} x_{ij}$$

Une moyenne par ligne utilise les c colonnes ; par colonne, les r lignes.

r est le nombre de lignes et c le nombre de colonnes ; x_ij est la valeur à la ligne i et colonne j. Σ additionne les valeurs de l'axe indiqué. Le point dans l'indice désigne l'axe résumé. Les quatre cellules sont ici des durées en minutes : les moyennes restent en minutes.

1 $\bar{x}_{1\cdot} = (10+20)/2 = 15, \quad \bar{x}_{2\cdot} = 35$ — Résumer chaque ligne : deux moyennes, 15 et 35 minutes.

2 $\bar{x}_{\cdot 1} = (10+30)/2 = 20, \quad \bar{x}_{\cdot 2} = 30$ — Résumer chaque colonne : 20 et 30 minutes.

```
m <- matrix(c(10, 20, 30, 40), nrow = 2, byrow = TRUE)
dim(m)              # 2 2
m[1, 2]             # 20
apply(m, 1, mean)   # 15 35 : lignes
apply(m, 2, mean)   # 20 30 : colonnes
```

PIÈGE

Une matrice R possède un type commun pour toutes ses cellules. Noria est un data.frame : utiliser apply sur toutes ses colonnes peut convertir les nombres en texte. Sélectionner d'abord un bloc numérique cohérent ; ne pas moyenner des identifiants ou des codes de catégories.

GRAPHIQUES · DES EFFECTIFS PAR INTERVALLE

Histogramme : compter avant de tracer

$$n_j = \sum_{i=1}^{n} \mathbf{1}\{a_j \leq x_i < a_{j+1}\}$$

n_j compte les valeurs dans la classe j ; l'indicatrice vaut 1 si la condition est vraie, 0 sinon.

Cinq durées : 10, 20, 30, 40, 50 minutes. Compter les valeurs dans chaque classe avant d'exécuter hist().

Classe de cet exemple	Effectif
[0,20[	1
[20,40[	2
[40,60[	2

```
x <- c(10, 20, 30, 40, 50)
h <- hist(x, breaks = c(0, 20, 40, 60),
          right = FALSE, plot = FALSE)
h$counts   # 1 2 2
plot(h, xlab = "Durée (min)", ylab = "Effectif",
     main = "Cinq durées, trois classes")
```

LIRE LE GRAPHIQUE

Changer les bornes change l'apparence. Toujours indiquer unités et effectifs. Le boxplot résume centre/dispersion ; ses moustaches ne représentent pas forcément le minimum et le maximum.

QUESTION · B présente-t-il une durée moyenne différente de A ?

9 · Définir le sens de la différence

$$\hat{\Delta} = \bar{x}_B - \bar{x}_A$$

Une différence orientée : toujours B moins A.

x̄A et x̄B sont les moyennes observées dans les groupes A et B, en minutes. Δ avec un chapeau est leur différence estimée, en minutes. Δ sans chapeau désignera la différence des moyennes dans les populations visées. Le contraste reste B − A dans les calculs, graphiques et conclusions.

Groupe	Durées observées (min)	Moyenne (min)
A	10, 12, 14	12
B	8, 10, 12	10

1 $\bar{x}_A = (10 + 12 + 14)/3 = 12$ — Calculer séparément la moyenne de A.

2 $\bar{x}_B = (8 + 10 + 12)/3 = 10$ — Calculer séparément la moyenne de B.

3 $\hat{\Delta} = 10 - 12 = -2$ — B a une moyenne observée inférieure de 2 minutes.

```
A <- c(10, 12, 14)
B <- c(8, 10, 12)
delta <- mean(B) - mean(A) # -2
```

PORTÉE

Une différence observée est une description. Un argument causal exige un protocole adapté, par exemple une répartition aléatoire des workflows. Pour une analyse de groupes indépendants, un ticket ne doit pas apparaître dans les deux groupes ; des mesures appariées demandent une autre analyse.

QUESTION · Que deviendrait la moyenne si nous reprenions un échantillon ?

10 · Dispersion des tickets ≠ précision de la moyenne

$$\widehat{SE}(\bar{x}) = \frac{s}{\sqrt{n}}$$

L'erreur standard estimée décrit la variation de la moyenne entre échantillons.

s est l'écart-type des durées entre tickets ; n est leur nombre ; SE signifie erreur standard. Tous deux sont en minutes, mais ils répondent à des questions différentes. La formule suppose des observations indépendantes et une variance de population finie. On ne voit qu'un échantillon ; s / √n estime cette variabilité hypothétique.

Grandeur	Question	Même dispersion, plus de tickets
s	À quel point les tickets diffèrent-ils ?	Pas nécessairement plus petit
SE de $\bar{x}$	À quel point la moyenne varie-t-elle ?	En général plus petit, comme 1/√n

1 $x = (10, 20, 30), \quad s = 10, \quad n = 3$ — Les trois durées ont un écart-type de 10 minutes.

2 $\widehat{SE}(\bar{x}) = 10/\sqrt{3} \simeq 5.77$ — La précision estimée de la moyenne s'exprime ici par 5,77 minutes.

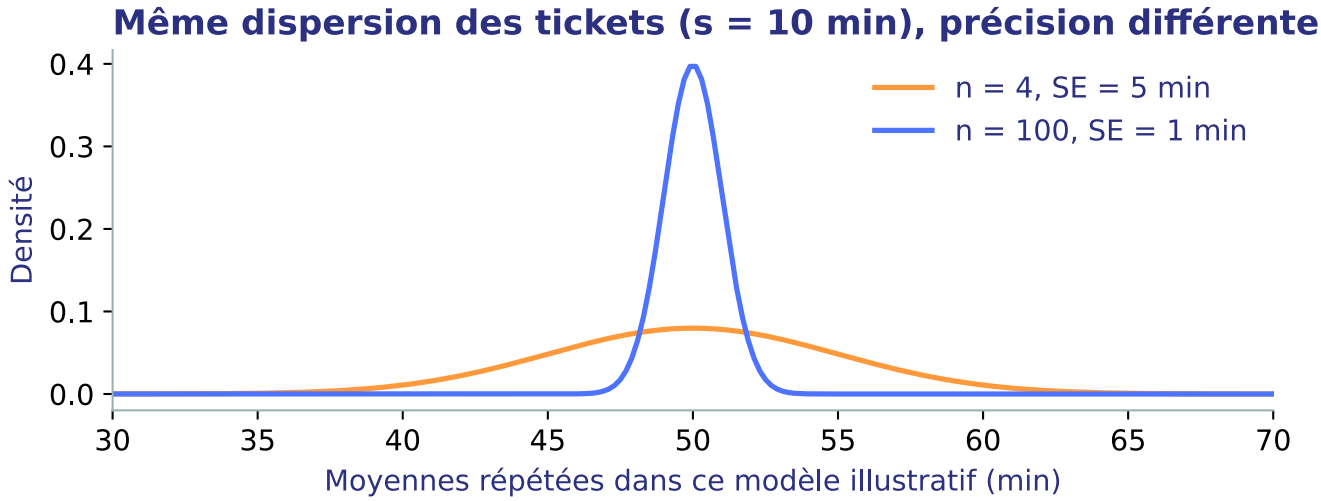
```
x <- c(10, 20, 30)
s <- sd(x)                  # 10
se_moyenne <- s / sqrt(length(x))
se_moyenne                  # 5.773503
```

PIÈGE

L'erreur standard ne dit pas où se situent 95 % des tickets. Recopier les mêmes tickets augmente artificiellement n sans ajouter d'information indépendante. Des tickets dépendants au sein d'une équipe peuvent nécessiter une méthode qui tient compte de ce regroupement.

SCHÉMA NORMAL · INDÉPENDANCE ET DISPERSION FIXÉE

Les moyennes deviennent plus précises



UNE ILLUSTRATION, PAS UNE PREUVE SUR NORIA

Le modèle illustratif suppose une dispersion fixe de 10 min et des observations indépendantes. Les moyennes sont plus resserrées avec n = 100 qu'avec n = 4. Les données manquantes ou dépendances demandent une autre réflexion.

QUESTION · Quelle est l'erreur standard de B − A ?

11 · Welch : combiner deux incertitudes

$$\widehat{SE}(\hat{\Delta}) = \sqrt{\frac{s_B^2}{n_B} + \frac{s_A^2}{n_A}}$$

Les variances estimées des deux moyennes indépendantes s'additionnent.

s_A² et s_B² sont les variances d'échantillon des durées (min²) ; n_A et n_B sont leurs effectifs. Chaque rapport s²/n estime une variance de moyenne en min². La racine carrée donne l'erreur standard de la différence, en minutes. Welch n'impose pas l'égalité des deux variances.

1 $A = (10, 12, 14), \quad B = (8, 10, 12)$

Deux groupes indépendants de trois durées.

2 $$s_A^2 = (4 + 0 + 4)/(3 - 1) = 4, \quad s_B^2 = 4$$

Chaque variance d'échantillon vaut 4 min².

3 $$\widehat{SE}(\hat{\Delta}) = \sqrt{4/3 + 4/3} = \sqrt{8/3} \simeq 1.633$$

L'erreur standard de la différence vaut environ 1,633 minute.

```
A <- c(10, 12, 14); B <- c(8, 10, 12)
vA <- var(A); vB <- var(B)
se_delta <- sqrt(vB / length(B) + vA / length(A))
se_delta                    # 1.632993
welch <- t.test(B, A, var.equal = FALSE)
unname(welch$stderr)         # même résultat
```

PIÈGE

On additionne les variances des moyennes, puis on prend la racine. Additionner directement deux écarts-types ne donne pas cette erreur standard. L'indépendance est une hypothèse de conception ; un test ne peut pas la créer.

QUESTION · L'écart observé serait-il surprenant si Δ = 0 ?

12 · Statistique t et p-valeur : mesurer l'incompatibilité

$$t_{\text{obs}} = \frac{\hat{\Delta} - 0}{\widehat{SE}(\hat{\Delta})}$$

Exprimer l'écart à zéro en nombre d'erreurs standards.

$$p = 2P(T_\nu \geq |t_{\text{obs}}| \mid H_0)$$

Pour le test bilatéral : additionner les deux queues de la loi de référence.

H0 affirme Δ = 0 dans la population ; t_obs est sans unité ; T_v suit une loi de Student de référence ; v (« nu ») est son nombre de degrés de liberté, ajusté par Welch. P désigne une probabilité calculée sous H0 et les hypothèses du modèle. La p-valeur est une probabilité d'écarts au moins aussi extrêmes, pas la probabilité que H0 soit vraie.

1 $$t_{\text{obs}} = (-2)/1.632993 \simeq -1.224745$$

La différence observée vaut environ −1,225 erreur standard.

2 $$\nu = 4, \quad p \simeq 0.287864$$

R fournit les degrés de liberté de Welch et la p-valeur bilatérale.

```
A <- c(10, 12, 14); B <- c(8, 10, 12)
w <- t.test(B, A, var.equal = FALSE)
t_obs <- unname(w$statistic)  # -1.224745
ddl <- unname(w$parameter)    # 4
2 * pt(-abs(t_obs), df = ddl) # 0.2878641
w$p.value                     # même résultat
```

À INTERPRÉTER

Avec un seuil fixé à 5 %, ce jouet ne conduit pas à rejeter H0. Cela ne prouve ni l'égalité des moyennes ni l'absence d'effet utile. Lire aussi l'effet et son intervalle. Pour de très petits groupes, la référence Student requiert des populations suffisamment normales ; inspecter les distributions et les valeurs extrêmes.

QUESTION · Quelles différences restent compatibles avec les données et le modèle ?

13 · Intervalle à 95 % : effet et précision sur la même ligne

$$IC_{95\%} = \left[\hat{\Delta} - t_{0.975,\,\nu}\widehat{SE},\ \ \hat{\Delta} + t_{0.975,\,\nu}\widehat{SE}\right]$$

Estimation ± marge : le multiplicateur vient de la loi de Student.

Δ̂est la différence B − A en minutes ; SE est son erreur standard en minutes ; v est le nombre de degrés de liberté de Welch. t_0.975,v est le quantile laissant 97,5 % de la loi de Student à sa gauche, sans unité. Les 2,5 % restants de chaque côté forment un intervalle bilatéral à 95 %.

1 $$t_{0.975,\,4} \simeq 2.776445$$

Le multiplicateur est obtenu avec qt ; ce n'est pas toujours 1,96.

2 $$\text{marge} = 2.776445 \times 1.632993 \simeq 4.533916$$

La marge d'incertitude vaut environ 4,534 minutes.

3 $$IC_{95\%} = [-2 - 4.533916,\ \ -2 + 4.533916]$$

Intervalle : [−6,533916 ; 2,533916] minutes.

```
A <- c(10, 12, 14); B <- c(8, 10, 12)
w <- t.test(B, A, var.equal = FALSE, conf.level = .95)
delta <- mean(B) - mean(A)
tcrit <- qt(.975, df = unname(w$parameter))
delta + c(-1, 1) * tcrit * w$stderr
unname(w$conf.int)   # -6.533916  2.533916
```

INTERPRÉTATION

L'intervalle traverse zéro : les données restent compatibles avec une moyenne de B plus faible ou plus élevée. À long terme, la procédure couvre la vraie différence dans environ 95 % des répétitions sous ses hypothèses. Ce n'est ni un intervalle pour 95 % des tickets ni une probabilité de 95 % attribuée au paramètre fixe.

QUESTION · Que peut-on conclure sur B − A après les contrôles ?

14 · Noria : effet proche du seuil, précision à montrer

1 240 tickets synthétiques → 2 241 lignes sales → 3 236 tickets analysés → 4 A : 117 · B : 119

5 Effet + IC + limites

$$\hat{\Delta} = -4.5648, \quad IC_{95\%} = [-9.1476,\ 0.0181]$$

Différence B − A et bornes de son intervalle, toutes en minutes.

La différence conserve l'orientation B − A ; une valeur négative indique une durée moyenne plus faible pour B. n_A = 117 et n_B = 119 sont les effectifs analysés. Les bornes sont arrondies seulement pour l'affichage ; le test utilise la précision complète.

1 $$n_A + n_B = 117 + 119 = 236$$

Le total des deux groupes rejoint le journal de nettoyage.

2 $$(-9.1476 + 0.0181)/2 \simeq -4.5648$$

Vérification avec les bornes arrondies : leur centre retrouve l'estimation, à l'arrondi près.

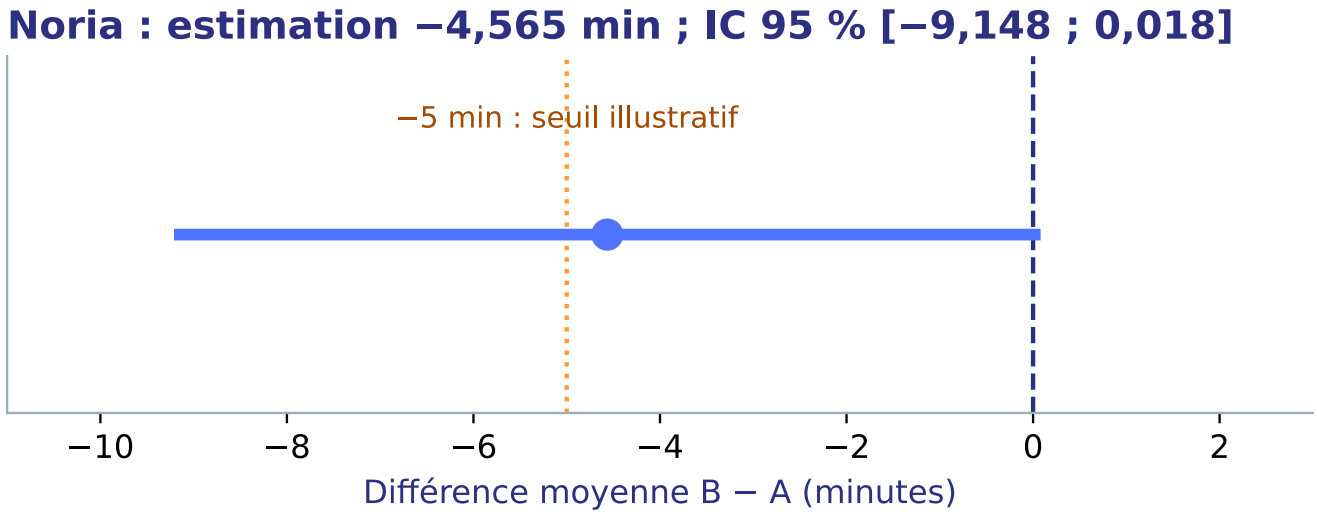
3 $$(0.0181 + 9.1476)/2 \simeq 4.5829$$

La demi-largeur de l'intervalle donne une marge d'environ 4,583 minutes.

```
A <- clean$resolution_minutes[clean$workflow == "A"]
B <- clean$resolution_minutes[clean$workflow == "B"]
stopifnot(length(A) == 117, length(B) == 119)
w <- t.test(B, A, var.equal = FALSE, conf.level = .95)
mean(B) - mean(A)     # -4.5647848883
unname(w$conf.int)    # -9.1476483068  0.0180785301
w$p.value             # 0.05090316485
```

LE ZÉRO ET LE SEUIL UTILE SONT DEUX QUESTIONS

Voir l’intervalle de Noria



INTERPRÉTER

L’IC contient légèrement zéro avant arrondi. Il contient aussi −5 min : ces données ne démontrent pas un gain minimal de 5 min. Une recommandation peut être de poursuivre l’essai.

OBJETS STATISTIQUES · EXTRAIRE LES QUANTITÉS DÉJÀ DÉFINIES

Le résultat du test est un objet à lire

```
class(w)
names(w)
attributes(w)
w$estimate
w$conf.int
w$p.value
resultat <- data.frame(
  delta = mean(B) - mean(A),
  bas = w$conf.int[1], haut = w$conf.int[2], p = w$p.value)
```

w est le résultat de t.test(B,A) créé à la page « Noria : effet proche du seuil ». $ accède à une composante nommée ; [1] et [2] sélectionnent les bornes. data.frame range les quantités dans une table, sans les ressaisir.

SAUVEGARDER UNE PREUVE

Avant write.csv(), créer le dossier. Avant un graphique PDF, ouvrir pdf() ; après le graphique, fermer dev.off(). L'exemple guidé montre le cycle complet.

Exemples d'export et de Welch >

TP03 : comparer deux groupes >

PROJET FINAL · QUATRE PREUVES, UNE QUESTION

Rendre une décision que l'on peut discuter

1 Brut conservé → 2 Audit expliqué → 3 Effet + intervalle → 4 Action conditionnelle

Dans la note PDF	Ce que le lecteur doit retrouver
Question	Population, unité, contraste B−A
Qualité	Effectifs avant/après et motifs d'exclusion
Résultat	Estimation, IC 95 % et nombres de tickets ; figures dans un PDF séparé
Décision	Ampleur utile, incertitude, limites et prochaine donnée

L'AUTONOMIE A UNE PREUVE

Fermer puis relancer R et exécuter le fichier enregistré. Votre résultat doit provenir du brut et de vos règles. Les fichiers des TP01–03 font partie du portfolio final ; les extensions ne donnent pas de points indispensables.

TP04 : projet individuel >

Défis facultatifs, après le cœur >

SOURCES PRIMAIRES · LIENS ET DOCUMENTATION LOCALE

Pour vérifier et continuer

- R, définition et objectifs : https://www.r-project.org/about.html
- R, créateurs et équipe : https://www.r-project.org/contributors.html
- Chambers, S, R and Data Science : https://journal.r-project.org/articles/RJ-2020-028/index.html
- Introduction officielle : https://cran.r-project.org/doc/manuals/r-patched/R-intro.html
- R en pratique industrielle en 2026 : https://r-consortium.org/posts/submissions-wg-2026/
- Dans votre installation : ?mean, ?median, ?var, ?sd, ?quantile, ?matrix, ?array, ?data.frame, ?list, ?t.test.

LIRE UNE AIDE EFFICACEMENT

Chercher l'argument utilisé et l'exemple minimal, puis le modifier. Le mémo et les mini-exemples du kit restent disponibles hors connexion.

Mémo de commandes et notations >

Retour au parcours des quatre TP >