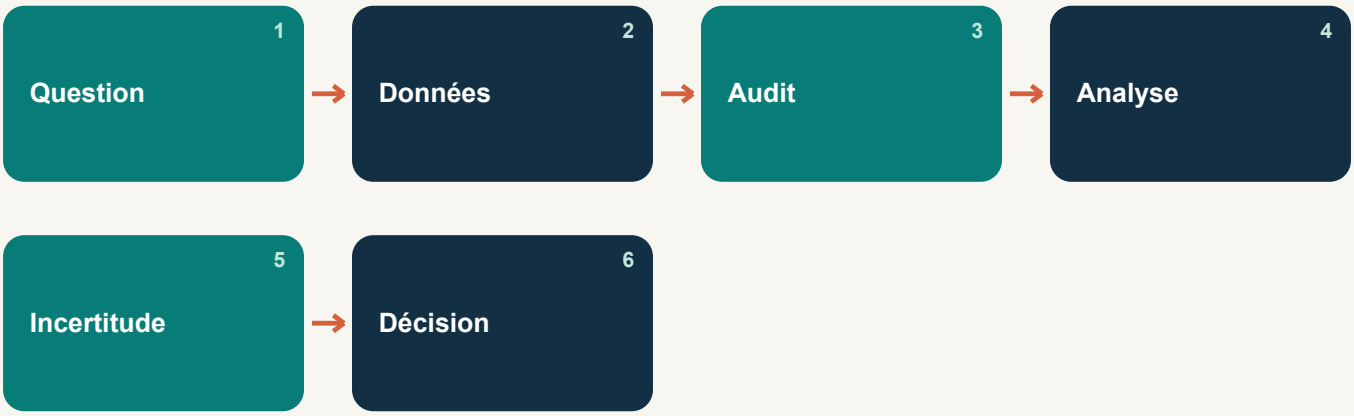
PROJET 0 → 9 · MISSION

Une question qui mérite une analyse

Noria Services teste deux procédures A et B de traitement des tickets. Affectation simulée aléatoire équilibrée : 120 tickets par groupe avant exclusions. La direction demande : B réduit-elle le délai moyen, et de combien ? Vous devez fournir une analyse relançable et discutable.



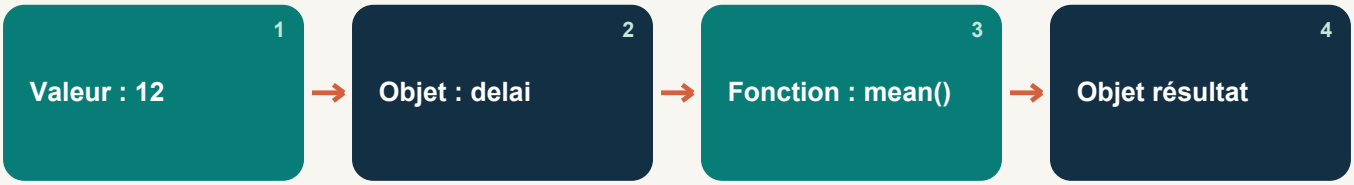
Nous savons	Nous devons vérifier
240 tickets simulés et indépendants	Qualité du fichier reçu
A/B affecté aléatoirement dans le générateur	Effet des exclusions et des valeurs manquantes
Délai en minutes, complexité avant traitement	Sens de B − A et pertinence opérationnelle

CONTRAT SCIENTIFIQUE

Ce sont des données synthétiques, pas une étude réelle ni une preuve commerciale. Le générateur contient un effet ; l'exercice porte sur l'estimation et ses limites.

01 · OBJET, FONCTION, RÉSULTAT

R est un atelier de calcul




```
# <- donne un nom à une valeur
delai <- c(12, 18, 30)
mean(delai)
length(delai)
class(delai)
?mean
```

- La console répond immédiatement. Le script garde une recette relançable.
- Une fonction reçoit des arguments nommés : mean(x = delai).
- R distingue Delai et delai. # commence un commentaire ignoré lors du calcul.
- Avant d'exécuter : prédire le type et la taille du résultat.

À VOUS · 90 SECONDES

Remplacer 30 par 120. Quel résumé bouge le plus : mean() ou median() ? Expliquer en une phrase.

02 · TYPE ET STRUCTURE

Les types changent le sens

Valeur	Type / classe	Sens
12.5	numeric	Mesure quantitative
3L	integer	Entier
"A"	character	Texte
TRUE	logical	Condition vraie
factor(c("A", "B"))	factor	Catégorie
NA	manquant	Information absente

```
x <- c(10, 20, "30")
class(x)          # character : coercition
as.numeric(x)     # conversion à contrôler
str(data.frame(groupe = c("A", "B"), n = 1:2))
```

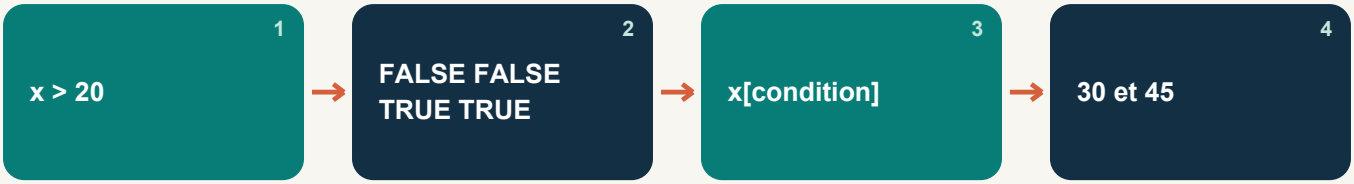
PIÈGE CONCRET

Un identifiant numérique reste un identifiant : la moyenne de ticket_id ne décrit pas une performance. Satisfaction 1–5 est ordinale ; ses distances ne sont pas garanties égales.

03 · CRÉER ET INDEXER

Un vecteur, plusieurs questions

```
x <- c(12, 18, 30, 45)
x[1]                  # R commence à 1
x[c(1, 4)]
x[x > 20]             # filtre logique
sum(x > 20)           # compte TRUE
mean(x > 20)          # proportion
seq(0, 60, by = 15)
rep(c("A", "B"), each = 2)
```



TRACEZ AVANT DE LANCER

Écrire les quatre valeurs de x > 20 sur papier. Puis comparer x[2] et x[-2] : position choisie ou retirée ? Le TP01 vous demande de construire votre propre exemple.

04 · DÉNOMINATEUR VISIBLE

NA ne veut pas dire zéro

```
x <- c(10, NA, 30)
mean(x)                    # NA
is.na(x)
sum(is.na(x))              # 1
mean(x, na.rm = TRUE)       # 20 sur 2 mesures
x[!is.na(x) & x > 15]
```

Choix	Conséquence
Remplacer NA par 0	Change la mesure et la moyenne
Retirer NA	Change la population analysée
Afficher n et n manquants	Rend le choix vérifiable

SI TOUT MANQUE

mean(c(NA_real_, NA_real_), na.rm = TRUE) donne NaN. Une fonction professionnelle définit ce cas explicitement et garde le nombre d'observations.

05 · IF, FOR ET VECTORISATION

Décider, répéter, puis simplifier

```r
x <- c(12, 75, 35)
if (mean(x) > 40) {
  message("Moyenne au-dessus du seuil")
} else {
  message("Moyenne au plus égale au seuil")
}
for (i in seq_along(x)) {
  print(x[i] > 40)
}
x > 40   # même question, tout le vecteur
```

if() attend une seule condition TRUE/FALSE, sans NA. Une boucle est utile pour comprendre une suite d'étapes. Une opération vectorielle exprime directement une même question sur plusieurs valeurs.

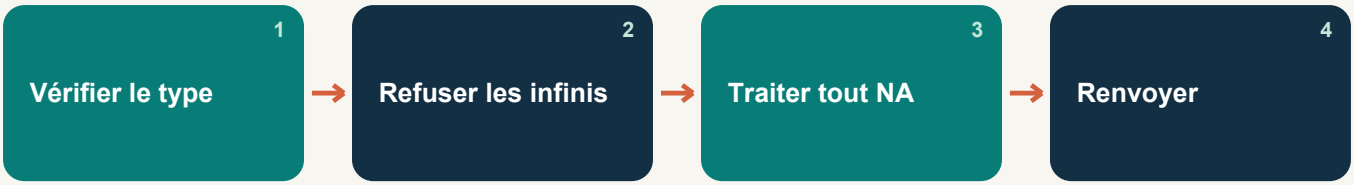
ERREUR À EXPLIQUER

Pourquoi if (x > 40) est-il incorrect ici ? Écrire une version qui répond à « au moins un délai dépasse 40 » avec any().

06 · ENTRÉE, SORTIE, CAS LIMITE

Une fonction est un contrat

```
safe_mean <- function(x) {
  if (!is.numeric(x)) stop("x doit être numérique")
  if (any(!is.finite(x) & !is.na(x))) stop("Inf interdit")
  if (all(is.na(x))) return(NA_real_)
  mean(x, na.rm = TRUE)
}
safe_mean(c(10, NA, 30))
safe_mean(numeric(0))
```



MÊME CONTRAT QUE LE KIT

Le vide ou un vecteur tout NA renvoie NA_real_. Les infinis déclenchent une erreur ; une mesure infinie doit être investiguée. Le contrat se vérifie aussi avec des entrées incorrectes.

07 · DIMENSIONS ET ORDRE

Une matrice organise un vecteur

```
v <- 1:6
m <- matrix(v, nrow = 2)
m                          # colonnes d'abord
m_lignes <- matrix(v, nrow = 2, byrow = TRUE)
dim(m)                     # 2 3
dim(m) <- c(3, 2)           # mêmes 6 valeurs
m[2, 1]
```

Défaut : par colonnes	byrow = TRUE
1 3 5	1 2 3
2 4 6	4 5 6

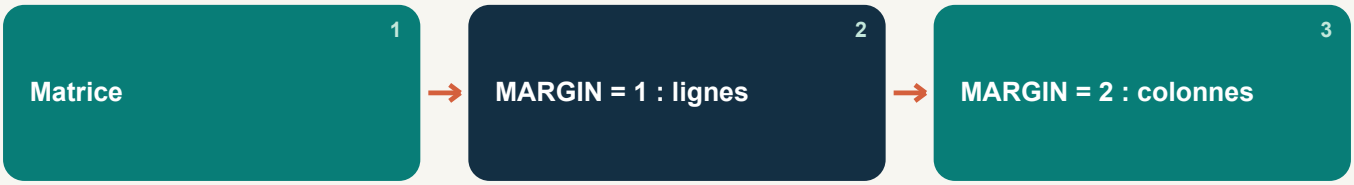
AVANT D'EXÉCUTER

Dessiner m après dim(m) <- c(3, 2). Modifier les dimensions ne réordonne pas le vecteur sous-jacent ; le nombre de cases doit rester 6.

08 · LIGNES OU COLONNES

apply() suit une direction

```
m <- matrix(1:6, nrow = 2)
apply(m, 1, sum)       # lignes : 9, 12
apply(m, 2, sum)       # colonnes : 3, 7, 11
colMeans(m)
rowSums(m)
```



Une matrice a un type homogène. Un data.frame autorise des colonnes de types différents. apply() sur un data.frame mêlant texte et nombres peut convertir toute la table en texte.

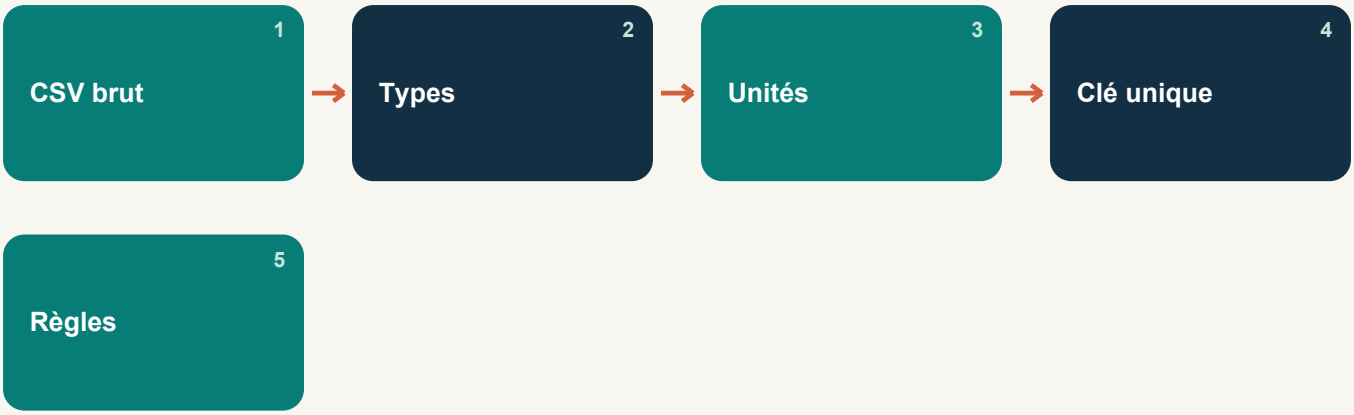
PRATIQUE SÛRE

Sélectionner explicitement les colonnes numériques avant as.matrix() et apply(). Pour une liste ou des colonnes hétérogènes, lapply() et vapply() évitent cette coercition globale.

09 · UNE LIGNE = UN TICKET

Importer une table sans deviner

```
d <- read.csv("data/noria_dirty.csv",
              stringsAsFactors = FALSE,
              na.strings = c("", "NA"))
dim(d)
head(d)
str(d)
summary(d)
colSums(is.na(d))
```



AVANT LA MOYENNE

Nommer l'unité d'observation, la population cible, l'unité du délai et la clé ticket_id. Un fichier qui s'ouvre sans erreur peut encore contenir des doublons et des valeurs impossibles.

10 · CHAQUE PERTE A UNE RAISON

Auditer avant d’exclure



- Harmoniser les espaces des catégories workflow et team : sept cellules concernées au total.
- Le ticket 17 est dupliqué à l’identique : garder sa première occurrence et noter la règle. Un doublon contradictoire demanderait une investigation.
- Les tickets 21, 87 et 154 ont un délai absent ; le ticket 203 a un délai négatif. Les exclure de l’analyse du délai selon la règle annoncée.
- Ne pas jeter une ligne pour sa seule satisfaction manquante : le délai peut rester analysable.

> **UNE EXCLUSION N’EST PAS UNE RÉPARATION**
>
> Les 236 tickets valides constituent une analyse sur cas complets pour le délai. Comparer les exclusions par groupe et discuter le risque de biais ; ne pas écrire que les données sont « propres donc sans biais ».

10 BIS · AVANT TOUT GRAPHIQUE OU TEST

La table analysable est un choix

Après avoir écrit vos règles dans le TP02, le code de référence permet de les comparer. d contient encore le brut de la page d'import ; nous gardons le brut et créons un objet distinct pour l'analyse.

```
brut <- d
source("R/00_utils.R", encoding = "UTF-8")
source("R/02_clean.R", encoding = "UTF-8")
nettoye <- clean_noria(brut)
nettoye$audit
nettoye$exclusions
d <- nettoye$data
stopifnot(nrow(d) == 236)
```

CONVENTION POUR LA SUITE

Tous les exemples suivants utilisent d nettoyé, avec workflow A/B, team normalisé et délai strictement positif. Le fichier CSV brut reste intact.

11 · DISTRIBUTION, PAS DÉCORATION

Le graphique doit répondre

Question	Graphique	Ce que l'on inspecte
Quelle forme ?	Histogramme du délai	Asymétrie, valeurs extrêmes, échelle
A diffère de B ?	Boîtes + points par groupe	Centre, dispersion, recouvrement, n
Complexité liée au délai ?	Nuage de points	Pente, non-linéarité, groupes
Le modèle manque quelque chose ?	Résidus vs ajustés / QQ	Structure, variance, queues

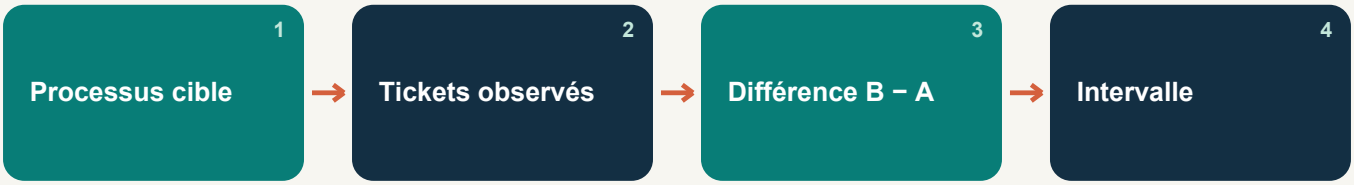
```
hist(d$resolution_minutes, xlab = "Délai (min)",
     main = "Distribution des délais")
boxplot(resolution_minutes ~ workflow, data = d,
        ylab = "Délai (min)")
```

TOUJOURS LÉGENDER

Unité sur chaque axe, titre qui dit ce qui est représenté, effectifs dans la légende ou la table. Éviter les axes trompeurs et une moyenne seule sans dispersion.

12 · POPULATION, ÉCHANTILLON, EFFET

Du hasard à l’incertitude



Une différence observée change d’un échantillon à l’autre. L’erreur standard mesure l’incertitude d’un estimateur ; l’écart-type décrit la dispersion des observations. Ce sont deux questions différentes.

- B − A < 0 signifie un délai moyen plus faible pour B. Un effet « favorable » doit être défini avant de regarder les résultats.
- Un IC à 95 % décrit une procédure qui couvre le paramètre dans 95 % des répétitions, sous ses hypothèses. Il n’attribue pas 95 % de probabilité au paramètre fixe.
- Un seuil opérationnel de 5 minutes sera discuté comme exemple pédagogique, pas comme exigence réelle de Noria.

> **TROIS VERDICTS POSSIBLES**
>
> Évidence d’une différence ; absence d’évidence suffisante ; bénéfice opérationnel incertain. Aucun n’équivaut automatiquement à « déployer ».

13 · CONTRASTE ANNONCÉ B − A

Welch : comparer deux moyennes

```
a <- d$resolution_minutes[d$workflow == "A"]
b <- d$resolution_minutes[d$workflow == "B"]
test <- t.test(x = b, y = a,
               alternative = "two.sided",
               conf.level = 0.95)
mean(b) - mean(a)
test$conf.int
test$p.value
```

- H0 : différence moyenne B − A = 0. Welch ne suppose pas des variances égales.
- Tickets indépendants, mesures comparables, moyenne pertinente, distributions/valeurs influentes à examiner. Une affectation aléatoire n'efface pas un biais dû aux exclusions.
- La p-valeur est calculée sous H0 et le modèle ; elle n'est pas P(H0 vraie). Un test non significatif ne prouve pas l'équivalence.

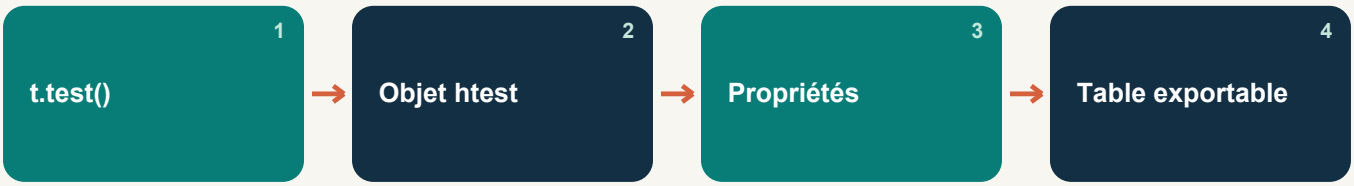
SENS DU RÉSULTAT

La formule t.test(delai ~ workflow) utilise l'ordre des niveaux ; elle peut afficher A − B. Ici x = b, y = a évite l'ambiguïté.

14 · CLASS, ATTRIBUTES, MÉTHODES

Le résultat statistique est un objet

```
class(test)          # "htest"
names(test)
attributes(test)
str(test, max.level = 1)
test$estimate
unname(test$conf.int)
# Préférer une propriété à une capture console
write.csv(data.frame(p = test$p.value),
          "results/test_exemple.csv", row.names = FALSE)
```



POUR LES MODÈLES

lm() produit un objet de classe lm. Les méthodes coef(), confint(), fitted() et residuals() décrivent sa structure sans copier à la main le texte imprimé.

15 · AJUSTER SUR LA COMPLEXITÉ

La régression ajoute une question

```
d$workflow <- factor(d$workflow, levels = c("A", "B"))
modele <- lm(resolution_minutes ~ workflow + complexity + team,
             data = d)
coef(modele)
confint(modele)
summary(modele)
attributes(modele)
```

workflowB estime la différence B − A à complexité et équipe égales, dans ce modèle additif. complexity suppose une variation linéaire du délai entre niveaux 1–5 : hypothèse à discuter.

- Complexité et équipe sont prétraitement. La satisfaction est après traitement : ne pas l'ajouter mécaniquement comme contrôle.
- Welch est l'analyse principale. Le modèle ajusté est secondaire, fixé par le protocole du cours avant calcul ; rapporter les deux résultats, quelle que soit leur p-valeur.
- L'IC d'un coefficient est conditionné au modèle et à ses hypothèses.

> **AU-DELÀ DU COEFFICIENT**
>
> Un modèle ajusté aide à décrire ; il ne garantit ni causalité dans un autre contexte, ni validité pour de futurs clients.

16 · DIAGNOSTICS ET LIMITES

Un bon modèle accepte la critique

```
par(mfrow = c(1, 2))
plot(fitted(modele), residuals(modele),
     xlab = "Délai ajusté (min)", ylab = "Résidu (min)")
abline(h = 0, lty = 2)
qqnorm(residuals(modele))
qqline(residuals(modele))
par(mfrow = c(1, 1))
```

Signal	Question suivante
Courbe dans les résidus	La relation est-elle non linéaire ?
Éventail	La variance change-t-elle avec le niveau ?
Point très influent	Erreur de mesure ou cas réel à documenter ?
Même client répété	L'indépendance des tickets est-elle plausible ?

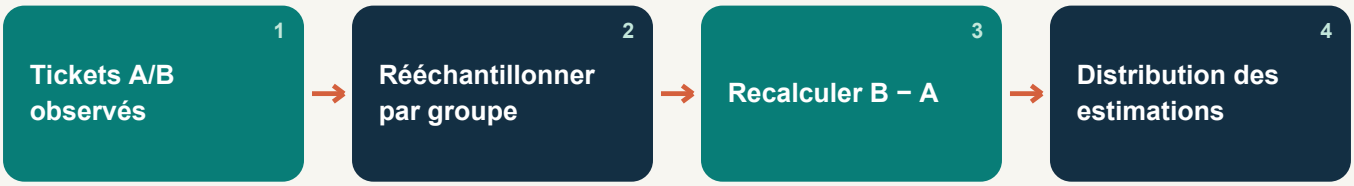
INTERPRÉTATION HONNÊTE

Un graphique rassurant ne prouve pas une hypothèse. En cas de doute : décrire la fragilité, tester une sensibilité annoncée, ou restreindre la conclusion.

17 · BOOTSTRAP RAISONNÉ

Extension : refaire le tirage

```
set.seed(42)
delta <- replicate(1000, {
  mean(sample(b, length(b), replace = TRUE)) -
    mean(sample(a, length(a), replace = TRUE))
})
quantile(delta, c(0.025, 0.975))
```

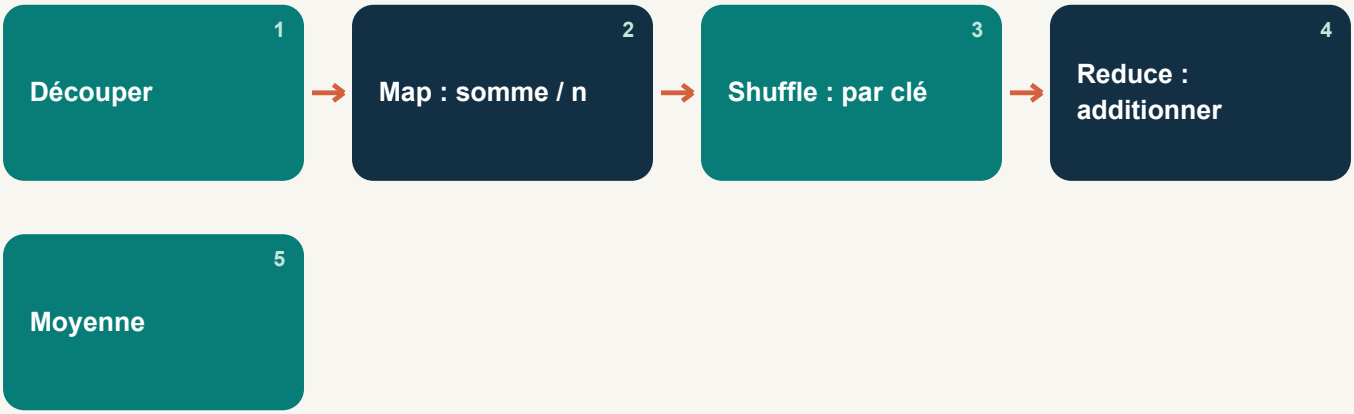


Ce bootstrap non paramétrique respecte deux groupes indépendants ; son IC percentile est une approximation. Il ne corrige ni dépendance entre tickets, ni données manquantes informatives, ni échantillon non représentatif.

> **OPTION AVANCÉE, HORS NOYAU**
>
> Comparer l'IC bootstrap à Welch, conserver la graine et expliquer pourquoi un désaccord mérite une enquête plutôt qu'un choix opportuniste.

18 · CALCUL DÉCOMPOSABLE

MapReduce commence sur papier



Partition	Somme	n	Moyenne
P1 : 10, 20	30	2	15
P2 : 90	90	1	90
Ensemble	120	3	40

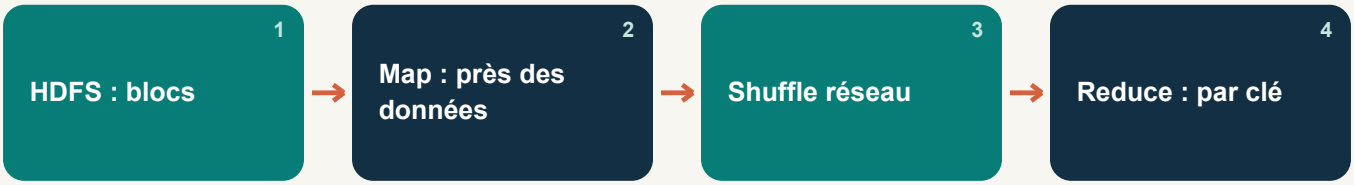
```
# La moyenne des moyennes est fausse ici
mean(c(15, 90))            # 52.5
(30 + 90) / (2 + 1)        # 40
```

À PRÉSERVER

Transporter des sommes et des effectifs, pas seulement des moyennes. Les additions se combinent ; une médiane locale n’est pas suffisante pour retrouver la médiane globale.

19 · STOCKAGE, ORCHESTRATION, CALCUL

Hadoop n’est pas une fonction R



Composant	Responsabilité
HDFS NameNode	Métadonnées du système de fichiers
HDFS DataNodes	Stockage des blocs et réplication
YARN	Allocation des ressources / ordonnancement
MapReduce	Traitement distribué en tâches map et reduce
RHadoop	Famille historique d’interfaces R, dont rhdfs et rmr2

CE QUE LE TP PROUVE

Le TP05 vérifie l’algorithme en mémoire dans un processus R. Il ne teste ni HDFS, ni parallélisme, ni reprise après panne, ni déploiement RHadoop. Un cluster est inutile pour nos 241 lignes.

20 · PASSERELLE VERS LE PLAN OFFICIEL

Lire une API RHadoop historique

Le schéma ci-dessous est du pseudocode inspiré des primitives de rmr2, pas un script à exécuter dans ce dépôt. Un véritable environnement RHadoop devrait fournir paquets, versions compatibles, HDFS et configuration cluster.

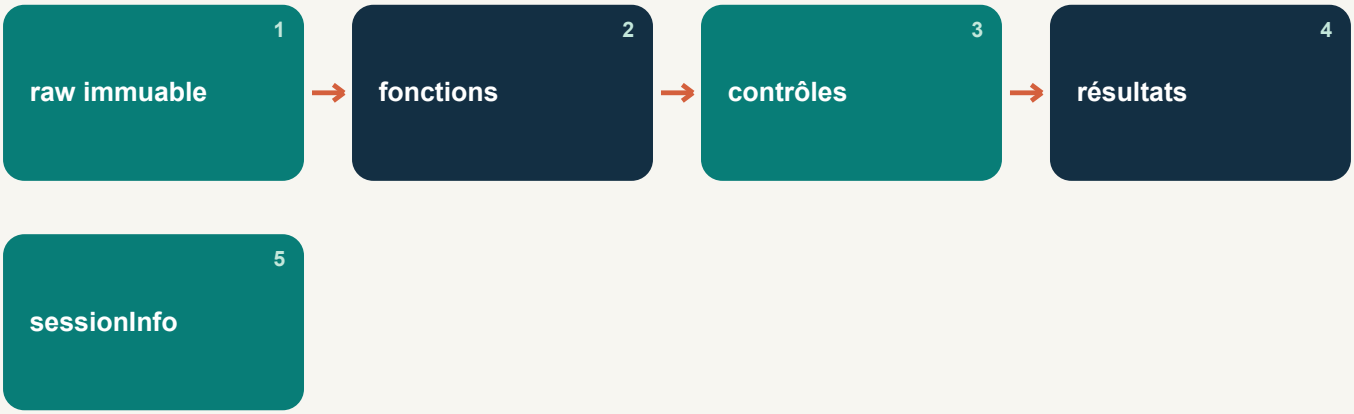
```
# PSEUDOCODE : environnement RHadoop séparé
mapreduce(
  input = "hdfs:///tickets",
  map = function(key, rows) {
    # émettre (workflow, somme_delai, effectif)
  },
  reduce = function(workflow, values) {
    # additionner les sommes et effectifs
  }
)
# finaliser : total_delai / total_effectif
```

- Repérer dans la documentation rmr2 : mapreduce(), keyval(), to.dfs(), from.dfs().
- Relier chaque primitive aux étapes du TP05, puis nommer les garanties que notre simulation ne teste pas.

> **ADAPTATION À VALIDER**
>
> La mise en œuvre RHadoop réelle demandée par le plan n'est pas réalisée ici. Le formateur doit faire approuver la substitution pratique locale ; les notions Hadoop/HDFS restent traitées.

21 · REPRODUCTIBILITÉ À PETITE ÉCHELLE

Livrer comme un collègue fiable



- Relancer depuis une session vide ; utiliser des chemins relatifs et garder les données originales.
- Enregistrer les exclusions et unités, pas seulement le dernier graphique.
- Garder les graines des simulations et les versions avec sessionInfo().
- Comparer une implémentation différente : calcul direct contre MapReduce.
- Pour un projet futur avec paquets : versions contrôlées, renv, revue de code et automatisation deviennent utiles. Ici la dépendance minimale est un choix pédagogique.

> **GIT EST UNE EXTENSION**
>
> Un commit explique une décision et permet de comparer. Ne jamais publier données personnelles, secrets, captures de comptes ou noms d'étudiants dans un dépôt public. Un ZIP local reste un livrable valable.

22 · LE PROJECTEUR EST À VOUS

Votre résultat tient en une page

Bloc	Preuve attendue
Question	Population, mesure, contraste B − A
Qualité	Effectifs avant/après et causes d’exclusion
Résultat	Estimation, IC, graphique et dénominateurs
Interprétation	Ampleur, incertitude, hypothèses
Décision	Recommandation conditionnelle et prochaine donnée utile

Restitution : trois minutes par personne en triades. Un pair joue le décideur, un autre le relecteur. Chaque étudiant répond aussi individuellement à une question commune ; la visibilité à l’oral public n’ajoute aucun point.

> **QUESTION DE SOUTENANCE**
>
> « Quelle observation nouvelle pourrait vous faire changer d’avis ? » Une bonne analyse peut proposer un prochain test au lieu de recommander immédiatement un déploiement.