UN JEU SYNTHÉTIQUE · AUCUNE DONNÉE CLIENT

Le dictionnaire des tickets

Colonne	Type / unité	Règle
ticket_id	integer / identifiant	Un ticket unique attendu
workflow	catégorie A/B	Procédure affectée aléatoirement
resolution_minutes	numeric / minutes	Délai strictement positif et fini
complexity	numeric / échelle 1–5	Mesurée avant traitement
satisfaction	ordinal / note 1–5	NA possible ; ne pas confondre avec 0
team	catégorie	Atlas, Boreal, Cedre

noria_reference.csv contient 240 tickets synthétiques avant anomalies de transmission. noria_dirty.csv contient 241 lignes reçues. Le générateur est documenté dans scripts/02_generate_data.R ; il conserve une graine et un algorithme explicites pour reproduire les CSV.

> L'UNITÉ COMPTE
>
> Les tickets sont indépendants par construction dans cette simulation. Dans un vrai service, plusieurs tickets d'un même client ou agent pourraient être corrélés ; le modèle simple devrait alors être réexaminé.

RÈGLES ANNONCÉES AVANT LE TEST

Un audit reproductible

Étape	Traitement	Effectif
Brut	Aucune modification	241
Catégories	trimws() sur workflow et team	241
Doublon	ticket 17 : première occurrence conservée	240
Délai absent	IDs 21, 87, 154 exclus du délai	237
Délai impossible	ID203 négatif exclu du délai	236

- Les espaces concernent sept cellules : trois de workflow et quatre de team.
- Après traitement : A =117, B =119 ; douze satisfactions manquantes demeurent, à comptabiliser séparément.
- Conserver un journal d'exclusions. Ne jamais écraser le CSV brut.
- Les exclusions ont des raisons explicites mais leur effet sur l'inférence doit être discuté : une analyse sur cas complets suppose plus qu'un fichier sans erreur.

PAS DE FUITE DE VÉRITÉ

Le fichier de référence aide à vérifier le générateur et les tests. Il ne faut pas remplacer les valeurs absentes du fichier reçu avec cette « vérité » fictive pour prétendre résoudre un vrai problème de données manquantes.

RÉFÉRENCES · VÉRIFIÉES LE 23 OCTOBRE 2026

Lire les sources primaires

- R — introduction officielle : https://cran.r-project.org/doc/manuals/r-patched/R-intro.html
- Documentation installée : ?mean, ?matrix, ?apply, ?t.test, ?lm, ?attributes, ?sessionInfo.
- RStudio — guide et téléchargements : https://docs.posit.co/ide/user/download.html
- HDFS — architecture : https://hadoop.apache.org/docs/stable/hadoop-project-dist/hadoop-hdfs/HdfsDesign.html
- MapReduce — tutoriel Apache : https://hadoop.apache.org/docs/stable/hadoop-mapreduce-client/hadoop-mapreduce-client-core/MapReduceTutorial.html
- rmr2 — tutoriel historique : https://github.com/RevolutionAnalytics/rmr2/blob/master/docs/tutorial.md
- RHadoop — installation historique : https://github.com/RevolutionAnalytics/RHadoop/wiki/Installing-RHadoop-on-RHEL
- R en contexte professionnel : https://rconsortium.github.io/submissions-wg/

PORTÉE DE LA PRÉPARATION

Le plan du coordinateur reste une source privée. Les exercices et données de ce dépôt ont été créés pour le cours. Les références techniques sont des ressources externes, pas des garanties de compatibilité de toutes leurs versions.