FACULTATIF · À VOTRE RYTHME

Vos cartes de révision

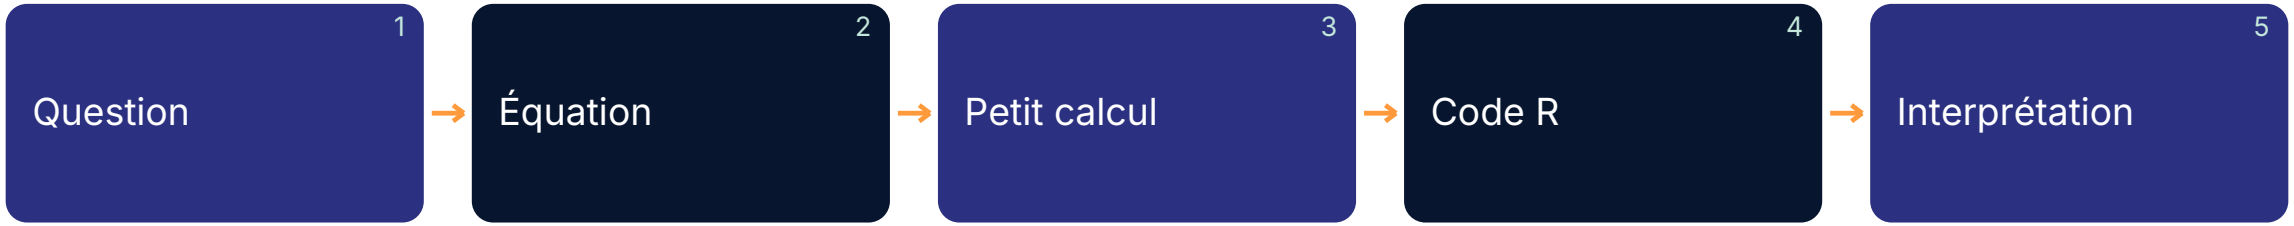
Choisissez une idée utile à votre niveau. Refaites un petit calcul, expliquez la figure puis reprenez votre propre script.

02_cours_visuel.pdf · explications et exemples

01_parcours_18h.pdf · choisir son prochain niveau

NOTRE MÉTHODE · REGARDER, CALCULER, CODER, EXPLIQUER

La question vient avant la commande



R : d'où vient cet outil ?

Repère	Ce qu'il signifie
Origine	Ross Ihaka et Robert Gentleman, département de statistique de l'Université d'Auckland
Inspiration	Le langage S, développé aux Bell Labs par John Chambers et ses collègues
1996	Les créateurs présentent R dans "A Language for Data Analysis and Graphics"
Depuis 1997	Une équipe R Core internationale contribue au développement

Pourquoi apprendre R aujourd'hui ?

Besoin	Ce que R apporte
Décrire une situation	Résumés, distributions et graphiques
Quantifier l'incertitude	Estimations, intervalles, tests et modèles
Reproduire une analyse	Le script conserve les étapes et règles
Échanger avec un collègue	Données, code, versions et sorties traçables

VOCABULAIRE · LE MÊME LANGAGE POUR TOUS

Donnée, variable, observation : donner du sens

Mot	Définition concrète	Dans Noria
Donnée	Une valeur avec un sens et éventuellement une unité	70,2 minutes pour un ticket
Observation / individu	L'unité sur laquelle on recueille les variables	Un ticket ; pas une ligne dupliquée
Variable	Caractéristique mesurée ou décrite pour chaque unité	Délai, procédure, satisfaction
Population cible	Ensemble que la question veut décrire	Tickets du processus et contexte concernés

VOCABULAIRE · STATISTIQUE ET INFORMATIQUE

Une variable a un sens et un stockage

Sens statistique	Exemple	Stockage R possible
Quantitative continue	Durée en minutes	numeric
Quantitative discrète	Nombre de tickets	integer ou numeric
Qualitative nominale	Procédure A/B	character ou factor
Qualitative ordinale	Satisfaction 1–5	numeric codé ou ordered factor

STRUCTURES · LIGNES ET COLONNES

Data frame : une table de variables

data.frame : une colonne par variable, une ligne par observation

	ticket_id : integer	workflow : character	resolution_minutes : numeric
ticket 1	1	A	10
ticket 2	2	B	20
ticket 3	3	A	30

QUESTION · Quelle durée entre dans le calcul ?

1 · Une ligne est-elle une observation valide ?

$$I = \{i : x_i \text{ est fini}, \; x_i > 0\}, \quad n = |I|$$

On définit les valeurs admises, puis on les compte.

QUESTION · Quel est le bon dénominateur ?

2 · Quelle proportion de tickets appartient à B ?

$$\hat{p}_B = \frac{n_B}{n}, \quad \text{pourcentage} = 100\hat{p}_B$$

Une part compare un nombre de tickets à une population clairement définie.

QUESTION · Quelle durée moyenne pour les tickets observés ?

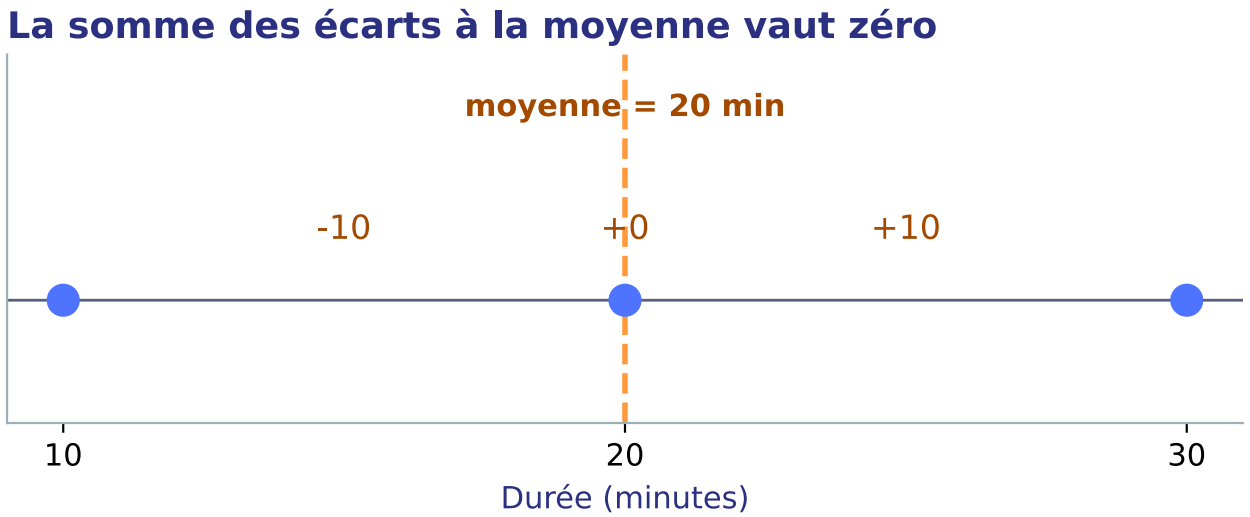
3 · La moyenne : un point d'équilibre

$$\bar{x} = \frac{1}{n} \sum_{i=1}^{n} x_i$$

Additionner les durées retenues, puis partager en n parts égales.

VOIR LE CALCUL

La moyenne comme équilibre



QUESTION · Quelle durée sépare les données en deux moitiés ?

4 · La médiane : le milieu des valeurs triées

$$n = 2k + 1 : \quad m = x_{(k+1)}$$

Nombre impair : prendre la valeur centrale après tri.

PASSER AU JEU DU PROJET · AVANT LE TP02

Recevoir Noria sans modifier le fichier

Le CSV reçu contient des anomalies de transmission. Gardez-le intact. On va compter les lignes, vérifier les unités et annoncer les règles avant d'interpréter un résultat.

QUESTION · Pourquoi Noria passe-t-il de 241 lignes à 236 tickets ?

5 · Compter les lignes, puis les tickets

$$n_{\text{analyse}} = 241 - 1 - 3 - 1 = 236$$

Un doublon de ligne, puis quatre tickets sans durée admissible.

QUESTION · Les durées sont-elles proches de leur moyenne ?

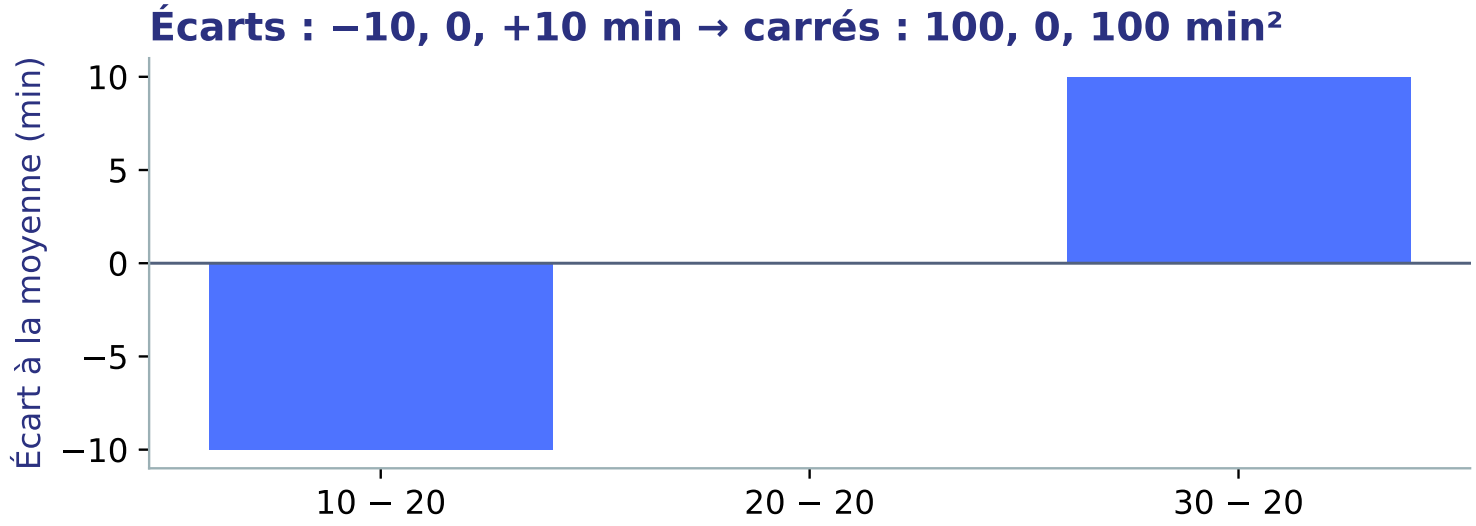
6 · Variance et écart-type : la dispersion des tickets

$$s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2, \qquad s = \sqrt{s^2}$$

R utilise n − 1 pour la variance et l'écart-type d'échantillon.

VOIR LES ÉCARTS

La dispersion se voit aussi



QUESTION · Où se situent les 25 %, 50 % et 75 % ?

7 · Quartiles et IQR : lire la moitié centrale

$$h = 1 + (n-1)p, \quad j = \lfloor h \rfloor, \quad g = h - j$$

Convention R type 7 : déterminer un rang et sa partie décimale.

GRAPHIQUES · AVANT LE TP02

Lire une boîte sans inventer ses moustaches

$$[Q_1 - 1.5\,IQR,\ \ Q_3 + 1.5\,IQR] = [-30, 130]$$

Les moustaches vont jusqu'aux valeurs observées dans ces limites : 10 et 80. Le point 150 est affiché séparément.

STRUCTURES · UN MÊME TYPE DANS TOUTES LES CASES

Matrice et array : des dimensions explicites

Matrice : 2 lignes × 3 colonnes

	col. 1	col. 2	col. 3
ligne 1	1	3	5
ligne 2	2	4	6

m[2, 1] = 2

m[ligne, colonne]

R remplit par colonnes par défaut.

Array : plusieurs feuilles du même tableau

array : deux matrices empilées — dimensions 2 × 2 × 2

jour 1 : a[, , 1]

1	3
2	4

jour 2 : a[, , 2]

5	7
6	8

STRUCTURES · CHOISIR L'OBJET SELON LA QUESTION

Liste, facteur et table : trois usages différents

Une list conserve des objets de formes et types différents

donnees	titre	valide
vecteur : 10, 20, 30	texte : "Noria"	logique : TRUE

PONT DE PROGRAMMATION · PETIT ET VÉRIFIABLE

Fonction, condition et boucle : une règle réutilisable

$$\bar{x}_{obs} = \frac{\sum_{i \in I} x_i}{|I|}$$

I contient les valeurs non manquantes ; vérifier les valeurs admissibles avant de résumer.

QUESTION · Que calcule apply selon son deuxième argument ?

8 · Matrice : lignes, colonnes, calcul par axe

$$\bar{x}_{i\,\cdot} = \frac{1}{c}\sum_{j=1}^{c} x_{ij}, \qquad \bar{x}_{\cdot j} = \frac{1}{r}\sum_{i=1}^{r} x_{ij}$$

Une moyenne par ligne utilise les c colonnes ; par colonne, les r lignes.

GRAPHIQUES · DES EFFECTIFS PAR INTERVALLE

Histogramme : compter avant de tracer

$$n_j = \sum_{i=1}^{n} \mathbf{1}\{a_j \leq x_i < a_{j+1}\}$$

n_j compte les valeurs dans la classe j ; l'indicatrice vaut 1 si la condition est vraie, 0 sinon.

QUESTION · B présente-t-il une durée moyenne différente de A ?

9 · Définir le sens de la différence

$$\hat{\Delta} = \bar{x}_B - \bar{x}_A$$

Une différence orientée : toujours B moins A.

QUESTION · Que deviendrait la moyenne si nous reprenions un échantillon ?

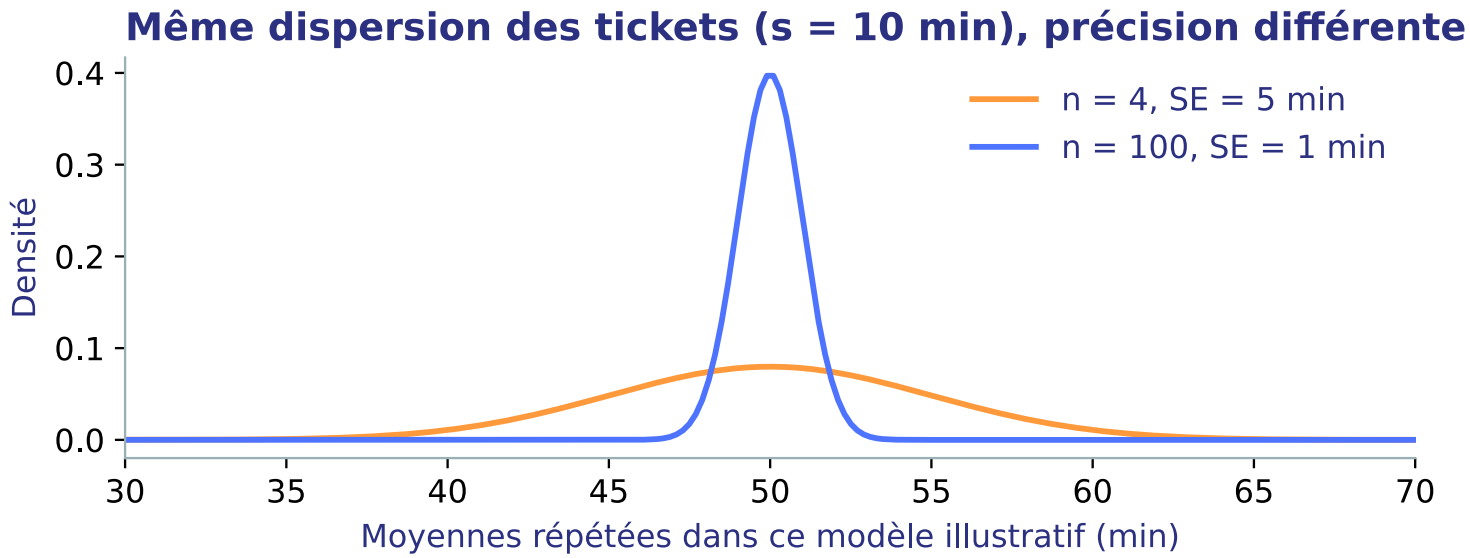
10 · Dispersion des tickets ≠ précision de la moyenne

$$\widehat{SE}(\bar{x}) = \frac{s}{\sqrt{n}}$$

L'erreur standard estimée décrit la variation de la moyenne entre échantillons.

SCHÉMA NORMAL · INDÉPENDANCE ET DISPERSION FIXÉE

Les moyennes deviennent plus précises



QUESTION · Quelle est l'erreur standard de B − A ?

11 · Welch : combiner deux incertitudes

$$\widehat{SE}(\hat{\Delta}) = \sqrt{\frac{s_B^2}{n_B} + \frac{s_A^2}{n_A}}$$

Les variances estimées des deux moyennes indépendantes s'additionnent.

QUESTION · L’écart observé serait-il surprenant si Δ = 0 ?

12 · Statistique t et p-valeur : mesurer l’incompatibilité

$$t_{\text{obs}} = \frac{\hat{\Delta} - 0}{\widehat{SE}(\hat{\Delta})}$$

Exprimer l’écart à zéro en nombre d’erreurs standards.

QUESTION · Quelles différences restent compatibles avec les données et le modèle ?

13 · Intervalle à 95 % : effet et précision sur la même ligne

$$IC_{95\%} = \left[\hat{\Delta} - t_{0.975,\,\nu}\widehat{SE},\ \ \hat{\Delta} + t_{0.975,\,\nu}\widehat{SE}\right]$$

Estimation ± marge : le multiplicateur vient de la loi de Student.

QUESTION · Que peut-on conclure sur B − A après les contrôles ?

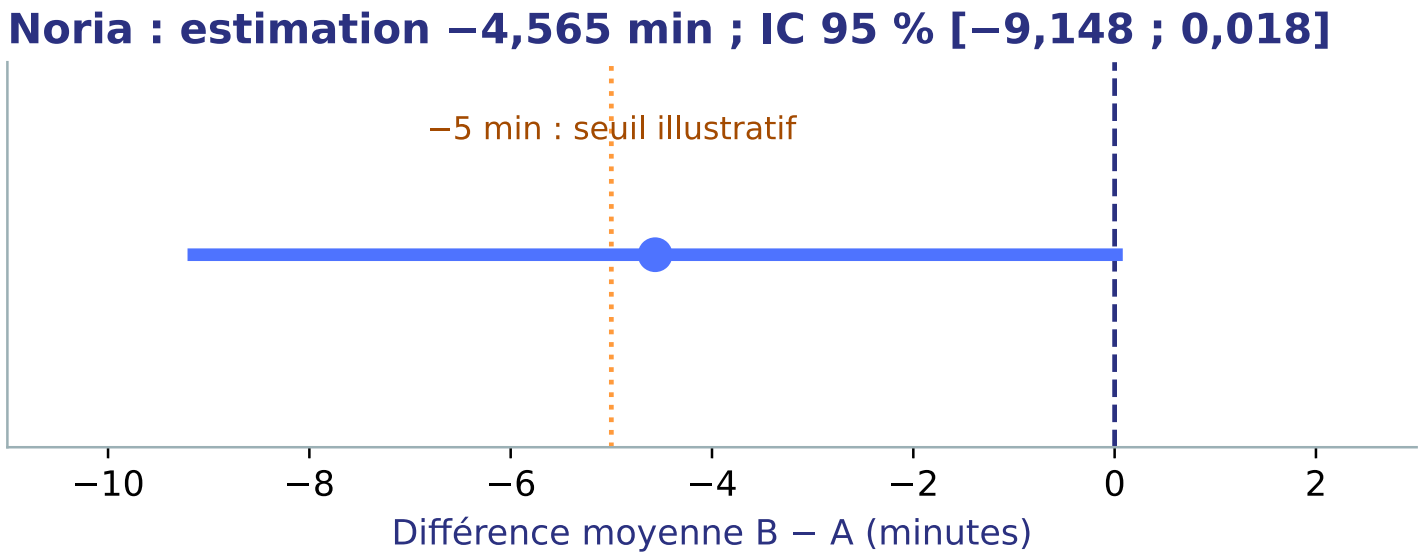
14 · Noria : effet proche du seuil, précision à montrer

$$\hat{\Delta} = -4.5648, \quad IC_{95\%} = [-9.1476,\ 0.0181]$$

Différence B − A et bornes de son intervalle, toutes en minutes.

LE ZÉRO ET LE SEUIL UTILE SONT DEUX QUESTIONS

Voir l’intervalle de Noria



Le résultat du test est un objet à lire

```
class(w)
names(w)
attributes(w)
w$estimate
w$conf.int
w$p.value
resultat <- data.frame(
  delta = mean(B) - mean(A),
  bas = w$conf.int[1], haut = w$conf.int[2], p = w$p.value)
```

PROJET FINAL · QUATRE PREUVES, UNE QUESTION

Rendre une décision que l'on peut discuter

1 Brut conservé → 2 Audit expliqué → 3 Effet + intervalle → 4 Action conditionnelle

SOURCES PRIMAIRES · LIENS ET DOCUMENTATION LOCALE

Pour vérifier et continuer

- R, définition et objectifs : https://www.r-project.org/about.html
- R, créateurs et équipe : https://www.r-project.org/contributors.html
- Chambers, S, R and Data Science : https://journal.r-project.org/articles/RJ-2020-028/index.html
- Introduction officielle : https://cran.r-project.org/doc/manuals/r-patched/R-intro.html
- R en pratique industrielle en 2026 : https://r-consortium.org/posts/submissions-wg-2026/
- Dans votre installation : ?mean, ?median, ?var, ?sd, ?quantile, ?matrix, ?array, ?data.frame, ?list, ?t.test.