TP02 · 120 MIN · 90 INDIVIDUELLES / 9 TRIADE / 21 RETOUR

Du brut aux règles

Cours p.13–24 : cours visuel

Voir le mini-exemple guidé

Ouvrir le fichier de travail

Ouvrez labs/TP02_preparer.R depuis le projet. Le CSV Noria contient 241 lignes enregistrées et six colonnes. Une unité statistique est un ticket indépendant ; ticket_id est un identifiant, pas une mesure.

```
raw <- read.csv("data/noria_dirty.csv",
  na.strings = c("", "NA"), stringsAsFactors = FALSE,
  colClasses = c("integer", "character", "numeric",
    "numeric", "numeric", "character"))
str(raw)
names(raw)
```

Colonne	Sens / type d'analyse
ticket_id ; workflow	Identifiant entier ; catégorie A/B.
resolution_minutes	Mesure quantitative en minutes ; variable principale.
complexity ; satisfaction	Scores 1–5 ; satisfaction ordinale et parfois inconnue.
team	Catégorie Atlas/Boreal/Cedre.

- Sur papier, annoncez le sort des espaces, doublons, durées absentes et durées négatives. Une satisfaction absente justifie-t-elle de supprimer une durée valide ?
- Lancez examples/mini_nettoyage.R sur six lignes : observez le masque d[lignes, colonnes], la virgule, le dossier créé et le PDF fermé par dev.off(). Les règles du TP restent à écrire par vous.

> **POINT DE VIGILANCE**
>
> Conservez raw intact. Une conversion factor() peut cacher un libellé inconnu en le remplaçant par NA : vérifiez les modalités autorisées avant de convertir.

02 / 03 · 40 min de nettoyage

Auditer après chaque règle

Étape	Action et point de contrôle
import	241 → 241 ; aucun retrait.
espaces	trimws sur workflow et team ; 3 et 4 cellules modifiées ; 241 lignes.
doublons	Le ticket 17 est répété ; valeurs identiques ; conserver le premier ; 240 lignes.
durees_absentes	Tickets 21, 87, 154 ; conserver les identifiants et motifs ; 237 lignes.
durees_invalides	Ticket 203 : durée négative ; 236 lignes.
facteurs	Niveaux explicites ; 236 lignes, 117 A et 119 B ; 12 satisfactions absentes conservées.

```
# Exemple sur une autre table :
t <- data.frame(id = 1:3, valeur = c(10, NA, 30))
masque <- !is.na(t$valeur)
t[masque, , drop = FALSE]
```

- Construisez audit avec etape, n_avant, n_apres, n_exclues, n_cellules_modifiees. Une ligne après chaque règle, même sans retrait.
- Créez exclusions avec ticket_id et motif : duree_absente ou duree_invalide. Le doublon est déjà compté dans l'audit.
- Nommez ids_doublons, ids_absents, ids_invalides, n_espaces_workflow et n_espaces_team. Affectez le tableau final à clean, puis n_satisfaction_absente.

JUSTIFIER LES EXCLUSIONS

Pas d'imputation de durée : inventer une valeur modifierait la moyenne et la variance. Si un doublon a des versions conflictuelles, il faut enquêter ; la règle de Noria ne suffit plus.

03 / 03 · 30 min décrire + 20 min exporter et contrôler

Décrire et livrer les preuves

$$s = \sqrt{\frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n-1}}$$

Écart type échantillonnal : sd() ; unité identique à la durée. n doit être au moins 2.

$$h = 1 + (n-1)p$$

Quantile de type 7 : trier, puis interpoler au rang h. Pour 10,20,30,40 et p=0,25 : h=1,75, donc Q1=17,5.

- Complétez resumer_durees(x) : n, moyenne, ecart_type, q1, mediane, q3. Reprenez le geste fonction(x) de examples/mini_structures.R ; appelez la fonction sur les durées de A, puis de B.
- Construisez descriptifs, deux lignes A/B : workflow, n, moyenne, ecart_type, q1, mediane, q3. Précisez type = 7 dans quantile().
- Exportez TP02_clean.csv, TP02_audit.csv, TP02_exclusions.csv et TP02_descriptifs.csv dans results/, sans noms de lignes.
- Produisez TP02_graphiques.pdf : boxplot par workflow et histogramme global. Titres, axes et unité minutes ; puis dev.off().

```
source("checks/TP02.R", encoding = "UTF-8")
```

VALIDATION

Message : TP02 : contrôles réussis. Relisez aussi les graphiques : le contrôle vérifie le fichier, pas la lisibilité. Écrivez deux phrases sur les moyennes, la dispersion et l'effet possible des exclusions.