TP04 · 150 MIN · 115 INDIVIDUELLES / 9 TRIADE / 26 RETOUR

Planifier une analyse reproductible

Cours p.31–34 : cours visuel

Voir le mini-exemple guidé

Ouvrir le fichier de travail

Ouvrez labs/TP04_projet.R dans une session R redémarrée. Le départ est data/noria_dirty.csv ; aucun objet de TP précédent ne doit être requis. Vous pouvez réutiliser VOS fonctions en les recopiant explicitement et en les relisant.

- Sur papier : unité d'observation, variable principale et unité, contraste B−A, règles de nettoyage, hypothèses et livrables. Utilisez le seuil fictif de 5 minutes fixé par le protocole pédagogique ; ce n'est pas un seuil validé pour une entreprise réelle.
- Complétez nettoyer_projet(brut) : renvoyer list(data, audit, exclusions). Les fonctions vides du script échouent volontairement avec un message TODO.
- Conservez raw4 intact. Créez clean4, audit4 et exclusions4 ; audit après espaces, doublon, durée absente, durée invalide et conversion des facteurs.
- Dans audit4 : 241 lignes importées, 7 cellules de libellés corrigées, un doublon puis quatre durées exclues ; 236 tickets analysables. Expliquez le risque de biais créé par ces pertes.

Point de passage	Preuve attendue
Source	raw4 et les six colonnes initiales.
Nettoyage	audit4 avec comptes à chaque règle ; exclusions4 avec identifiants et motifs.
Fonctions	Contrats lisibles, noms d'arguments explicites, aucun chargement du pipeline de référence.

TRAÇABILITÉ

La reprise de TP03 n'est pas une preuve de nettoyage ici. Ce projet relie lui-même le fichier brut à ses sorties. Aucune régression, matrice ni simulation MapReduce n'est exigée.

02 / 03 · 30 min décrire + 25 min inférence

Décrire, comparer, visualiser

- Complétez decrire_projet(donnees) puis créez descriptifs4 : lignes A/B, colonnes workflow, n, moyenne, ecart_type, q1, mediane, q3 ; quantiles type 7.
- Créez test4 par Welch indépendant (x=B, y=A). Construisez comparaison4 : contraste, delta_minutes, ic_bas, ic_haut, p_valeur.
- Produisez results/TP04_graphiques.pdf : boîte par workflow et histogramme des durées valides, avec titre et unité. Fermez le PDF avec dev.off().
- Exportez TP04_audit.csv, TP04_exclusions.csv, TP04_descriptifs.csv et TP04_comparaison.csv, sans noms de lignes.

$$\widehat{\Delta} = \bar{x}_B - \bar{x}_A$$

Une valeur négative indique un gain moyen avec B. Elle ne promet pas un gain identique sur chaque ticket.

Position de l'IC par rapport à −5 min	zone_decision4
IC haut < −5	gain_etaye : gain utile étayé, sous les hypothèses.
Sinon, IC bas < −5	gain_possible : gain utile possible, mais non établi.
Sinon	gain_non_etaye : le gain utile n'est pas étayé.

INTERPRÉTER SANS AUTOMATISER LE JUGEMENT

Cette règle force à distinguer incertitude et utilité. La décision finale doit aussi nommer les limites des données et une action proportionnée : suivi, pilote ou étude complémentaire.

03 / 03 · 30 min recommandation et contrôle

Une page pour un décideur

- Écrivez recommandation4 en phrases personnelles : source et effectifs, pertes, estimation B−A, IC95 et p, seuil utile de 5 minutes.
- Donnez la décision conditionnelle liée à zone_decision4. Dites ce qui reste incertain, les hypothèses et les limites (exclusions, simulation, transport à la pratique).
- Proposez une prochaine action concrète et ce qu'elle mesurera. Évitez « p>0,05 donc identiques » et « l'IC95 donne 95 % de probabilité à l'effet observé ».
- Exportez results/TP04_recommandation.txt et TP04_recommandation.pdf : UNE page de texte lisible ; les graphiques restent dans leur PDF séparé.
- Pour mettre vos phrases en PDF, voir le gabarit de examples/mini_note_pdf.R et le dernier mini-exemple guidé.
- Créez session4 <- sessionInfo(), puis writeLines(capture.output(session4), "results/TP04_sessionInfo.txt").

```
source("checks/TP04.R", encoding = "UTF-8")
```

Évaluation	Attendu
Traçabilité et qualité des données	Brut préservé, audit fidèle, exclusions justifiées.
Analyse	Descriptifs cohérents, signe B−A, Welch, intervalle et p correctement extraits.
Décision	Seuil prévu, conclusion conditionnelle et limites expliquées.
Reproductibilité	Session neuve, script de haut en bas, CSV/PDF réels et lisibles.

VALIDATION FINALE

Le contrôle doit afficher TP04 : contrôles réussis. Il ne remplace pas une relecture humaine : ouvrez tous les fichiers, vérifiez la page de recommandation et préparez une défense orale de 3 minutes.