MODE D'EMPLOI

Corriger une démarche

1 Tenter seul → 2 Conserver son essai → 3 Comparer une étape → 4 Expliquer l'écart

Les corrections sont publiques pour l'autoformation. La compréhension est évaluée par un script individuel relançable, un choix justifié et une défense, pas par la possession d'un chiffre secret.

TP	Corrigé exécutable
01 / Vecteurs	solutions/TP01_vectors_solution.R
02 / Qualité	solutions/TP02_cleaning_solution.R
03 / Matrices	solutions/TP03_matrices_solution.R
04 / Inférence	solutions/TP04_inference_solution.R
05 / Agrégation	solutions/TP05_mapreduce_solution.R
06 / Projet	solutions/TP06_capstone_solution.R

MÊME ENVIRONNEMENT

Exécuter depuis le projet, en UTF-8. Les scripts sont commentés ; les tableaux de cette brochure résument les sorties calculées et ne remplacent pas leur reproduction.

VECTEURS ET FONCTIONS

TP01 : le dénominateur change tout

```
delais <- c(42, NA, 35, 80, 55, NA, 20, 60)
sum(!is.na(delais))
mean(delais, na.rm = TRUE)
median(delais, na.rm = TRUE)
delais[!is.na(delais) & delais > 50]
```

Contrôle	Attendu
Taille / observés / absents	8 / 6 / 2
Somme observée	292 minutes
Moyenne / médiane	48,6667 / 48,5 minutes
Délai >50 sur observés	3 sur 6, soit 50 %
Filtre valide >50	80,55,60

CE QUE L'ON VEUT ENTENDRE

Le vecteur x[x > 50] peut contenir des NA parce que le masque contient des inconnus. Un compteur, un dénominateur et une règle explicites rendent la réponse défendable.

QUALITÉ · STRUCTURES · MARGES

TP02 et TP03 : des contrôles concrets

Audit	Attendu
Lignes brutes → uniques → délai valide	241 →240 →236
Libellés harmonisés	3 workflow +4 team
Exclusions délai	21,87,154 absents ;203 négatif
Groupes finaux	A117 ;B119
Satisfaction NA conservée	12 : A8 ;B4

```
m <- matrix(1:12, nrow = 3)
apply(m, 1, sum)  # 22 26 30
apply(m, 2, sum)  # 6 15 24 33
dim(m) <- c(4, 3)
rowSums(m)        # 15 18 21 24
```

DISTINGUER LES EXERCICES

Le cours montre aussi une matrice 2×3 sur 1:6, dont les sommes de lignes sont 9 et 12. Le TP03 utilise 1:12. apply sur une table mixte peut provoquer une coercition ; choisir des colonnes numériques.

WELCH PRINCIPAL · LM SECONDAIRE

TP04 : présenter les deux analyses prévues

Mesure	A	B
n	117	119
Moyenne / min	70,655	66,090
Écart-type / min	17,992	17,738
Médiane / min	68,2	66,9

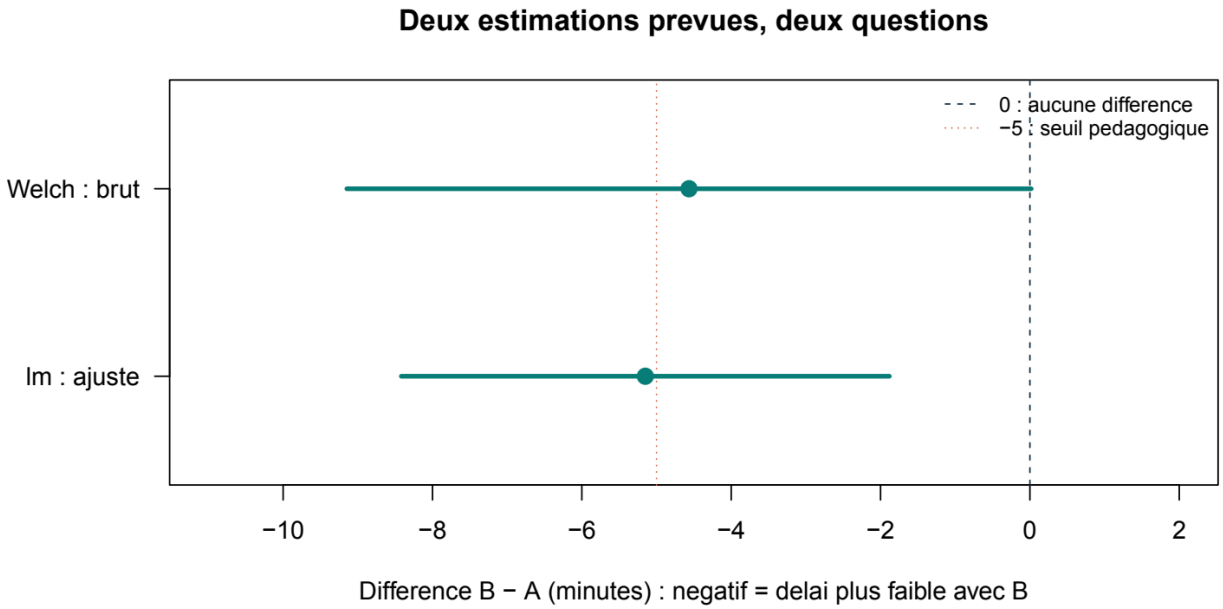
Analyse B − A	Estimation / min	IC95 % / min	p
Welch brut	−4,565	[−9,148 ;0,018]	0,0509
lm ajusté	−5,150	[−8,418 ;−1,882]	0,00214

Modèle secondaire fixé par le protocole : resolution_minutes ~ workflow + complexity + team. Référence A pour workflow et Atlas pour team. Complexité et équipe sont prétraitement ; ne pas sélectionner cette formule parce qu'elle donne une petite p-valeur.

> **INTERPRÉTATION ATTENDUE**
>
> Le brut favorise B, avec une incertitude incluant zéro : ce n'est pas une preuve d'égalité. L'ajusté estime une association conditionnelle plus précise. Aucun IC n'établit un gain minimal de 5 min ; tous deux traversent −5.

UNE MÊME ÉCHELLE POUR DEUX ESTIMATIONS

Voir l’incertitude



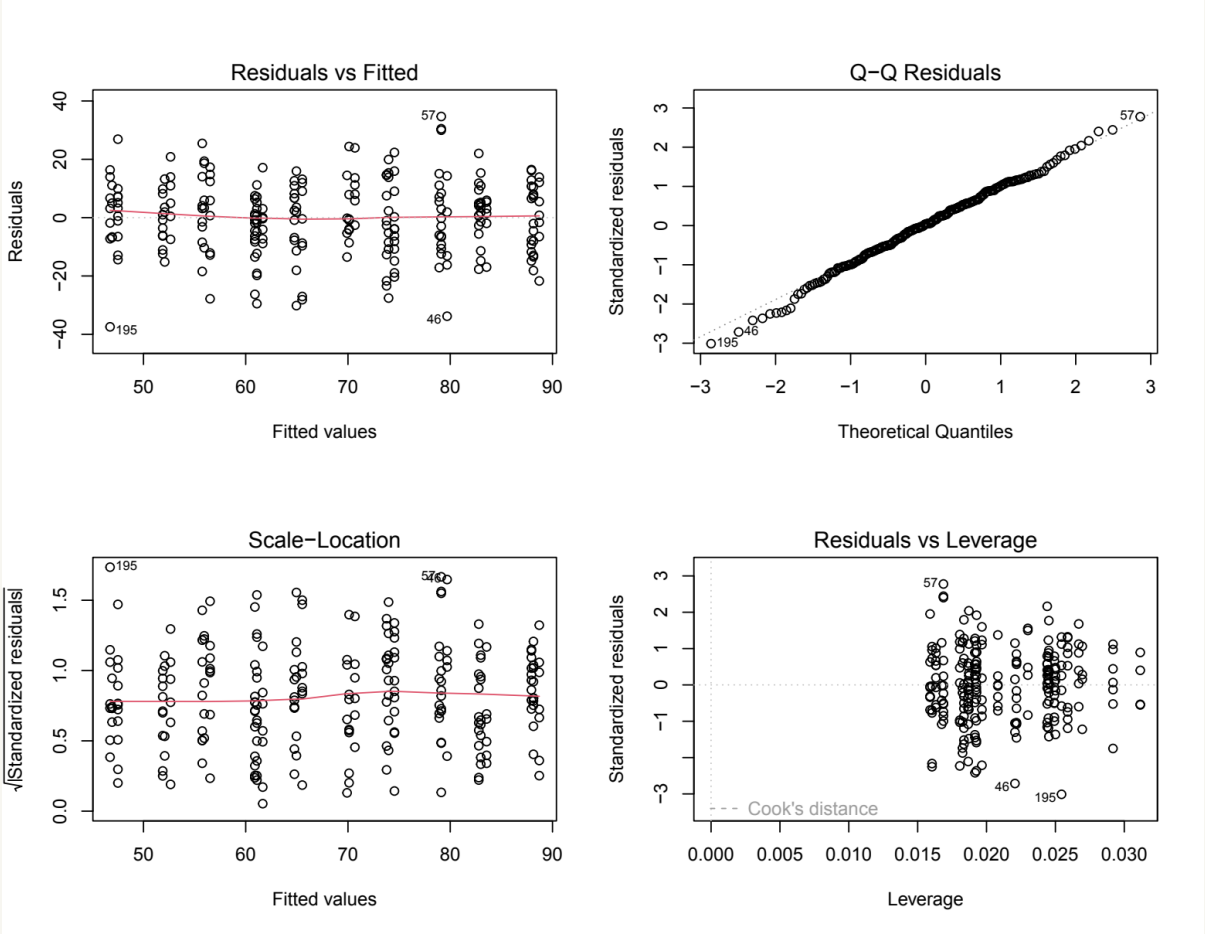
Le point est l’estimation, le segment un IC à 95 %. Le trait zéro indique l’absence de différence ;−5min est un seuil opérationnel d’illustration. Le segment brut recoupe zéro et les deux segments recoupent−5.

QUESTION POUR LE DÉCIDEUR

Quel gain minimal justifierait le coût de B ? Quelles mesures de qualité et de charge faut-il suivre en plus du délai ? Les données simulées ne donnent pas une politique commerciale réelle.

NE PAS CONFONDRE DIAGNOSTIC ET PREUVE

Les résidus invitent à enquêter



COMMENT LIRE

Décrire un motif concret avant de conclure : courbure, éventail, queue, point influent. Les graphiques ne testent pas la façon dont les tickets ont été collectés ni leur indépendance.

MAP · SHUFFLE PAR CLÉ · REDUCE

TP05 : garder la bonne information

Clé	Somme / min	Effectif	Moyenne / min
A	8 266,6	117	70,6547
B	7 864,7	119	66,0899
Global	16 131,3	236	68,3530

- Le mapper produit clé, somme et effectif. Le shuffle regroupe les mêmes workflows ; le reduce additionne les sommes et les effectifs.
- Sur les partitions inégales du kit, la moyenne naïve des moyennes vaut 68,0481 contre 68,3530 pour la vraie moyenne.
- Autre contre-exemple : deux tickets de moyenne 10 et huit tickets de moyenne 20 donnent 18, pas 15.
- Les contrôles comparent calcul direct et agrégation, plusieurs découpages, clés absentes localement et partitions vides.

PORTÉE

Le code est un traitement local séquentiel. Il ne démontre ni tolérance aux pannes ni performances Hadoop. Cette limite doit figurer dans la restitution.

EXEMPLE DE NOTE · PAS UNE PHRASE À RECOPIER

TP06 : une conclusion possible

Sur 236 tickets simulés analysables, B présente un délai moyen inférieur de 4,56 min à A. L'IC de Welch va de −9,15 à 0,02 min : il reste compatible avec un bénéfice important comme avec une différence quasiment nulle.

Le modèle secondaire prévu, ajusté sur complexité et équipe, estime −5,15 min [−8,42 ;−1,88]. Il apporte une comparaison conditionnelle sous ses hypothèses additives et linéaires ; nous présentons les deux résultats sans sélectionner selon leur p-valeur.

Si l'on exige un gain minimal de 5 min, ces résultats ne le démontrent pas. Pour cet exercice, poursuivre le pilote et préciser coûts/qualité est une recommandation cohérente. Il faut documenter les quatre exclusions, vérifier les diagnostics et éviter d'extrapoler cette simulation à une population réelle.

PREUVES À JOINDRE

Audit, graphique, deux estimations/IC, modèle et diagnostic, limites, commande de relance et sessionInfo. Une autre recommandation est acceptable si la règle annoncée et les preuves la soutiennent.