01 / Périmètre technique

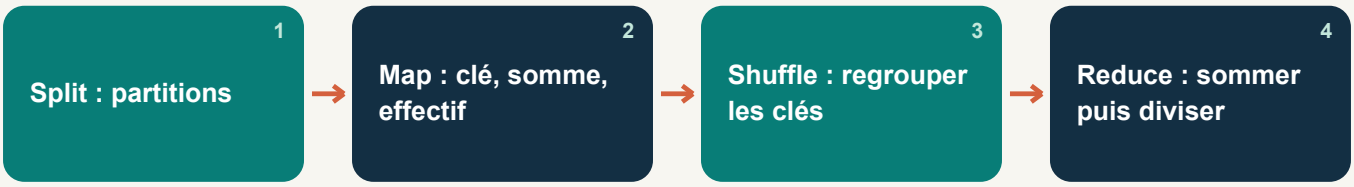
Ce que la simulation apprend

EXTENSION FACULTATIVE

Aucun point indispensable du barème ne dépend de cette activité. Les fichiers de première édition sont conservés dans legacy/ ; les lancer depuis la racine du projet.

- Prérequis : fonctions, listes, agrégations, table nettoyée. Départ : legacy/labs/TP05_mapreduce.R. Tout s'exécute localement en R de base.
- Question : calculer une moyenne par workflow depuis des partitions inégales sans transmettre tous les tickets à chaque agrégation.
- Cette activité simule split–map–shuffle–reduce ; elle n'installe ni Hadoop, ni HDFS, ni RHadoop et ne constitue pas une programmation RHadoop.

```
source('scripts/00_check_setup.R', encoding = 'UTF-8')
```



Temps	Étape
0–10 min	Architecture et contrats
10–65 min	Noyau individuel et contre-exemple
65–77 min	Défense en triades
77–80 min	Preuves et remise

POINT À ARBITRER

Si une programmation RHadoop réelle est obligatoire, cette substitution pédagogique doit être validée. Un environnement compatible, des accès et une séance dédiée restent nécessaires ; une réussite locale ne valide aucun déploiement.

Repère du kit : modules 7 · MapReduce. Les numéros de modules et de TP sont distincts.

02 / Noyau individuel · 55 min

La moyenne de moyennes peut tromper

- 1. Découpez les tickets en partitions inégales selon la stratégie du starter. Vérifiez présence de chaque identifiant une seule fois et tailles différentes.
- 2. Contrat map : pour chaque partition et workflow présent, émettre clé, somme des délais et effectif valide. Certaines partitions peuvent omettre un workflow.
- 3. Implémentez map, puis shuffle par clé. Implémentez reduce : sommer les sommes, sommer les effectifs, diviser à la fin.
- 4. Comparez au calcul central : effectifs et sommes, puis moyennes avec all.equal() et une tolérance annoncée.
- 5. Partitionnez autrement les mêmes tickets ; recommencez. Expliquez les invariants.
- 6. Contre-exemple : une partition de 2 délais de moyenne 10, une de 8 délais de moyenne 20. Comparez moyenne simple des moyennes et moyenne pondérée.

> **AUTO-CONTRÔLE APRÈS CALCUL**
>
> Le contre-exemple comporte 10 observations et une somme 180 ; moyenne globale 18. Les moyennes locales seules perdent les effectifs.

03 / Analyse et remise

Relier code et architecture distribuée

Élément	Rôle à expliquer
HDFS	Stockage en blocs répliqués, distinct du calcul
Moteur MapReduce	Planification, regroupement par clé, gestion des tâches
RHadoop	Famille historique d'interfaces R/Hadoop ; compatibilité à vérifier
Simulation R	Listes et fonctions dans un processus ; ni réseau ni reprise de panne

- Dessinez données, map, shuffle et reduce. Situez réseau, réplication et reprise de tâche ; dites ce que l'expérience ne mesure pas.
- Défi : partition vide ou clé absente ; rendez le code robuste. Détectez le double traitement d'une partition.
- Remise : script, tailles de partitions, tableau central/distribué/écart, contre-exemple commenté et schéma annoté.
- Partage de 3 minutes : pourquoi transmettre somme/effectif ? Citez une limite du passage à l'échelle.

> **INDICES GRADUÉS**
>
> 1. Une moyenne globale exige des poids. 2. ?split, ?lapply, ?aggregate. 3. Testez map sur une petite partition avant assemblage. Les temps locaux ne mesurent pas un gain de performance distribuée.