01 / Manipulations de base

Lire, inspecter et sélectionner

```
source('scripts/00_check_setup.R', encoding = 'UTF-8')
getwd()
list.files('data')
d <- read.csv('data/noria_dirty.csv',
              stringsAsFactors = FALSE)
str(d)
summary(d)
names(d)
dim(d)
```

Intention	Outil
Repérer les manquants	is.na(x) ; sum(is.na(x))
Effectif observé	sum(!is.na(x))
Comparer / combiner	==, !=, <, <=, >, >= ; !, &, |
Sélectionner	x[masque] ; d[masque, colonnes]
Espaces aux extrémités	trimws(x)
Répétitions d'une clé	duplicated(d$ticket_id)
Contrôle / aide	stopifnot(condition) ; ?mean

DÉBOGAGE

Lisez le message entier. Vérifiez nom, type, dimensions, NA et dossier. Testez un exemple minimal. = dans un argument n'est pas le test ==.

Un chemin relatif part de la racine du projet. read.csv() ne nettoie pas les règles métier. Gardez l'objet brut ; expliquez chaque transformation. Les numéros de TP et de modules R sont distincts : 0 setup, 1 import, 2 nettoyage, 3 langage, 4 matrices, 5 exploration, 6 Welch, 7 MapReduce, 8 modèle, 9 exports.

02 / Outils de travail

Résumer, programmer, dessiner

Besoin	R de base
Résumer	mean, median, sd, quantile, range
Compter	table(..., useNA = 'ifany')
Groupes	split puis lapply ; aggregate
Matrices	matrix, dim, rowSums, colSums, apply
Garder 2 dimensions	M[i, j, drop = FALSE]
Boucle / condition	for (i in seq_along(x)) {...} ; if (...) {...}
Fonction	nom <- function(x) {...}
Comparer des calculs	isTRUE(all.equal(a, b))
Exporter	write.csv ; png ; dev.off

```
hist(x, xlab = 'Délai (minutes)',
     main = 'Distribution des délais')
boxplot(resolution_minutes ~ workflow,
        data = d, ylab = 'Minutes')
```

- na.rm = TRUE retire les NA du calcul, pas de la table. Comptez les observations utilisées.
- mean(numeric(0)) donne NaN : annoncez le cas sans observation.
- Une matrice a un type commun ; un data.frame conserve des types par colonne.
- Graphique exporté : ouvrir png(...), tracer, fermer dev.off(). Créez le dossier avec dir.create(..., recursive = TRUE).

VÉRIFICATION

Une assertion doit contrôler le sens des données. Enregistrez puis relancez sans dépendre d'objets anciens ; un code qui tourne peut encore calculer une mauvaise quantité.

03 / Statistique et prudence

Estimer et lire des objets

```
test <- t.test(x_B, x_A, var.equal = FALSE)
class(test)
names(test)
str(test)
test$p.value
test$conf.int

# Après ajustement d'un modèle lm :
# coef(modele)
# confint(modele)
```

Objet / idée	À retenir
htest	Liste structurée renvoyée par t.test
lm	coef et confint : coefficients et leurs IC
Méthodes	methods(class = 'lm') ; dépend de la classe
Contraste	B − A négatif : délai moyen inférieur pour B
Welch	Variances non supposées égales ; indépendance à discuter
p-value	Compatibilité avec le modèle nul ; pas probabilité du nul
IC 95 %	Couverture de la procédure sur répétitions sous hypothèses

CONCLUSION UTILE

Donnez unités, n, estimation, IC, règle pratique et limite. Non-significatif ne démontre pas l'équivalence ; significatif peut être sans utilité pratique.

MapReduce : transmettre somme et effectif par clé, additionner puis diviser. La moyenne simple des moyennes locales oublie les poids. Une simulation locale ne valide pas un système Hadoop ou un programme RHadoop.