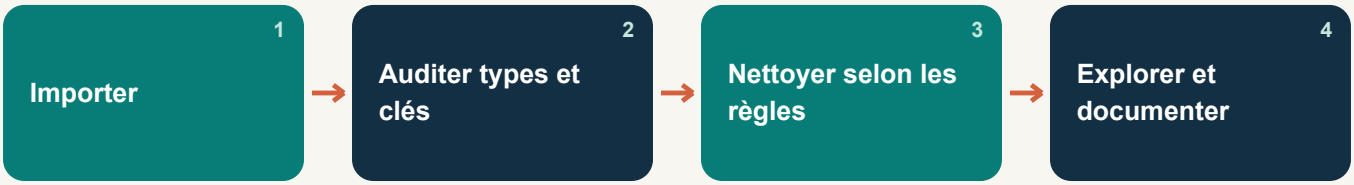
01 / Contrat de données

Du fichier reçu à la table analysable

Noria Services est fictive : tickets simulés, affectation aléatoire équilibrée aux workflows A/B. R de base uniquement ; aucun paquet à installer.

- Prérequis : TP01, filtres logiques et NA. Départ : labs/TP02_cleaning.R ; entrée : data/noria_dirty.csv. Ne modifiez pas le CSV source.
- Champs : ticket_id ; workflow A/B ; resolution_minutes ; complexity de 1 à 5 ; satisfaction ordinale de 1 à 5 ou NA ; team Atlas/Boreal/Cedre.
- 240 tickets sous-jacents : une ligne reçue n'est pas forcément une unité statistique.

```
source('scripts/00_check_setup.R', encoding = 'UTF-8')
```



Temps	Étape
0–10 min	Contrat et démarrage
10–75 min	Audit, nettoyage et exploration individuels
75–87 min	Triades : preuves et limites
87–90 min	Journal et remise

DÉCOUPAGE

L'import et l'audit commencent séance 1 (40 min) ; nettoyage et exploration continuent séance 2 (50 min). Sauvegardez votre script au point d'arrêt.

Repère du kit : modules 1–2–5 · import, nettoyage, exploration. Les numéros de modules et de TP sont distincts.

02 / Noyau individuel · 65 min

Justifier chaque ligne retirée

- 1. Importez avec read.csv(). Examinez dim(), names(), str(), head(), summary(). Comptez les NA par colonne et répétitions de ticket_id.
- 2. Auditez les modalités workflow et team avant transformation ; appliquez trimws() aux deux colonnes. Validez modalités, types et domaines ; arrêtez-vous si une anomalie inconnue subsiste.
- 3. Gardez la première occurrence de chaque ticket_id. Prouvez que les copies sont identiques ; des copies contradictoires nécessiteraient une investigation.
- 4. Excluez ensuite les délais absents ou négatifs. Conservez les NA de satisfaction : ils n'invalident pas un délai observé.
- 5. Journalisez chaque étape : avant, retirés, après, motif et identifiants. Vérifiez l'unicité finale.
- 6. Par workflow : n, moyenne, médiane, écart-type et quartiles. Tracez histogramme et boxplot lisibles ; décrivez forme, extrêmes et comparaison.

> **AUTO-CONTRÔLE APRÈS AUDIT**
>
> 241 lignes ; 1 doublon (17) ; 7 cellules avec espaces : 3 workflow, 4 team. Trois délais absents (21, 87, 154), un négatif (203). Après règles : 236 tickets ; 12 satisfaction manquantes.

03 / Indices, défis et preuves

Décrire n’est pas conclure

Indice	Piste graduée
1 · Préserver	Un objet brut, un objet nettoyé ; une règle par étape.
2 · Inspecter	?duplicated, ?trimws, ?table ; colSums(is.na(...)).
3 · Vérifier	Comparez les identifiants avant/après sans compter deux fois.

- Défi : comparez la suppression de toute ligne incomplète à votre règle ciblée. Mesurez l’impact ; quelle population décrit chaque analyse ?
- Défi : traduisez le contrat en assertions ; une modalité inconnue doit déclencher une erreur explicite.
- Remise individuelle : script, audit, CSV nettoyé et tableau descriptif dans results/ ; graphique PDF avec unités et effectifs. Créez le dossier si nécessaire.
- Ajoutez quatre phrases : unité statistique ; règles ; constat descriptif ; limite liée aux exclusions.
- Partage de 3 minutes : anomalie, règle et preuve de conformité finale.

> **SATISFACTION ORDINALE**
>
> Les modalités sont ordonnées ; leurs écarts ne sont pas garantis égaux. Une absence ne vaut ni zéro ni insatisfaction. Le résultat principal porte sur le délai.